令和 8 年度修士論文

執筆用草稿・題目仮案

音響によるプール沸騰の熱流束回帰と沸騰開始判定におけるモデル統合の効果と限界

予測誤差と入力特徴への依存に基づく検討

2026 年 10 月 23 日改訂

指導教員　植木祥高

東京理科大学大学院先進工学研究科
電子システム工学専攻植木研究室

8125517　柴崎陸

正式題目・表紙様式・提出年月は要確認．提出用完成稿ではない．

本草稿の位置づけ

本稿は，保存された研究計画，解析記録，実行条件，予測値および評価表に基づく修士論文の執筆用草稿である．2026 年 10 月 23 日の本人の指示により，最新の研究整理を基準として，熱流束全域の推定と ONB 判定を二つの主要課題に置き，改善・悪化の説明を含む三つの問いへ本文を対応づけた．当初の開始近傍・物理的説明の目標も回答対象に残す．この改訂は草稿の研究上の位置づけをそろえるものであり，教授の了承や提出用完成稿を意味しない．

本稿の主比較は，2025 年 6 月 11 日・6 月 18 日の既知録音に含まれる未使用 1 秒区間への適用である．未知の録音日や実機への一般化を検証した論文としては扱わない．また，著者は対象の実験・収録を実施していない．取得者・提供元および実験側の ONB 判定原資料には未確認事項があり，本文の赤字の**【要確認】**と付録の不足一覧で明示する．不足を隠す目的で章を省略したり，推測を観測事実に置き換えたりはしない．

数値の主系列は 10 月 15 日完了の clean_only 実行 143609 であり，10 月 14 日の保存予測分析と 10 月 7 日の入力対照は補助証拠として出典を分けた．新しい学習，モデル推論，音響入力の再生成は行っていない．既存の保存表・予測を組版用に再配置した図表を含む．引用資料の実験条件と本解析の対象条件を区別し，出典と対応関係を明記する．

> **【要確認：F01】**正式題目，学位・専攻の表記，指導教員の肩書，提出年月，所定の表紙・余白・引用形式を提出要領に照合する．現在は計画書・過去の学位論文の表記を参考にした仮組版である．

要旨

本研究は，音響による熱負荷と沸騰への移行の把握に向け，背景水流音下の熱流束推定誤差と，予測熱流束に基づく核沸騰開始（ONB）判定の見逃し・誤報を低減するモデル構成および統合条件を明らかにすることを目的とする．ナトリウム冷却高速炉での沸騰の早期把握を応用背景とし，水のプール沸騰の既存音響データを対象とする．全域熱流束推定と ONB 判定を二つの主要課題として評価し，その改善と悪化を誤差構造，入力依存および統合制約から分析した．

既存の 2025 年 6 月 11 日・6 月 18 日の計 36 録音から，各録音 60 個の 1 秒区間を作成し，45 区間を学習，15 区間を評価に用いた．評価は 540 区間であり，未知録音の評価ではない．3 kHz を上限とする STFT power を用いる従来 3 モデルに，34 個の音響要約特徴を用いる HistGradientBoosting と ExtraTrees を追加した．無雑音学習側の out-of-fold 予測で重みを求め，モデル，前処理および重みを無雑音と 6 段階の固定基準水流音付加条件で共通にした．全域回帰誤差，見逃し・誤報，ONB 近傍誤差，日別の検知到達熱流束を比較した．

5 モデル統合の全域 RMSE は，MSE 基準の従来 3 モデル統合に対して全 7 条件で小さく，無雑音で 34.07 から 27.80 $\mathrm{kW/m^2}$，基準 SNR -20 dB で 81.14 から 75.23 $\mathrm{kW/m^2}$ となった．総見逃し件数もそれぞれ 42 から 27，65 から 52 へ減少した．一方，無雑音から -20 dB への RMSE 増加量は 47.07 から 47.43 $\mathrm{kW/m^2}$ となり，この比較では悪化量の縮小は確認されなかった．記録上最初の ONB 段階に含まれる 30 評価区間のうち，5 モデル統合が陽性としたのは無雑音 8 区間，-20 dB で 0 区間であり，開始段階の十分な検知には至らなかった．

保存予測の誤差分解から，統合の利得には過大・過小予測の相殺に加え，同方向に外れた予測の誤差縮小が含まれた．共通入力の時間行並べ替えでは CNN 系が変化し，要約特徴を用いる 2 モデルは不変であり，入力依存の違いを確認した．また，元 3 内部比率と配分下限を維持する現制約では，-20 dB の開始段階 30 区間は重み変更だけで陽性化できないことが上限診断から分かった．以上より，対象条件での全域熱流束推定と総判定の改善を示すとともに，開始段階の限界と，入力情報・統合目的・制約を対応づける必要性を具体化した．入力依存から物理音源の因果は確定できず，未知日・独立雑音・実際の発生時刻への一般化には追加の根拠を要する．

キーワード：プール沸騰，ONB，音響，熱流束回帰，アンサンブル，入力依存

Abstract

This study aims to identify model configurations and integration conditions that improve heat-flux estimation and onset-of-nucleate-boiling (ONB) threshold decisions under added water-flow noise. Motivated by acoustic monitoring of coolant boiling in sodium-cooled fast reactors, the study uses existing water pool-boiling recordings. Overall heat-flux regression and ONB decisions are evaluated as two main performance tasks, and their gains and limitations are analyzed through residuals, input dependencies and integration constraints. Recordings from June 11 and June 18, 2025 were divided into one-second segments. Forty-five segments per recording were used for training and fifteen for evaluation, giving 1,620 training and 540 evaluation segments from 36 recordings. This design evaluates unused segments of known recordings rather than unseen recording days.

Two regressors using 34 acoustic summary features, HistGradientBoosting and ExtraTrees, were added to three existing models. The models, preprocessing and integration weights fitted on clean training data were fixed across clean and six reference-level water-flow-noise conditions. The five-model integration reduced overall RMSE relative to the MSE-weighted original-three integration in all seven conditions, from 34.07 to 27.80 kW/m^2 in the clean condition and from 81.14 to 75.23 kW/m^2 at a reference SNR of -20 dB. However, the clean-to-noisy RMSE increase was not reduced. Only 8 of 30 evaluation segments at the recorded ONB stages were detected in the clean condition, and none at -20 dB. These 30 segments came from two recordings and do not represent 30 independent onset events.

Residual analysis showed that error reduction involved both cancellation of opposite-sign errors and reduction within same-sign error groups. Common input perturbations demonstrated different dependencies on within-segment temporal arrangement. An upper-bound diagnosis showed that none of the 30 onset-stage segments at -20 dB could be made positive by reweighting under the current fixed-core constraints. These findings establish gains in overall regression and aggregate threshold decisions within the evaluated data, while identifying onset-stage limitations and the need to consider retained information, integration objectives and constraints together. Generalization to unseen days and independent noise, event-time detection, and identification of physical sound sources remain unverified.

目次

本草稿の位置づけ i

要旨 ii

Abstract iii

第 1 章　緒言 1

1.1　研究背景 1

1.1.1　沸騰開始を音響から捉える意義 1

1.1.2　雑音と統合に関する課題 2

1.2　音響による熱流束推定・沸騰検知に関する従来研究 2

1.2.1　音響による定量推定と状態判定 2

1.2.2　特徴利用の説明と未解決の位置づけ 3

1.3　本研究の目的 3

1.4　本論文の構成 4

第 2 章　使用データと解析条件 5

2.1　使用データの出典と本研究の対象 5

2.2　音響・熱計測データの概要 5

2.2.1　対象条件と収録単位 5

2.2.2　原実験条件と本稿で確認できた範囲 6

2.3　熱流束と ONB ラベルの根拠 6

2.3.1　熱流束ラベルの意味 6

2.3.2　ONB 閾値の値と出典の段階 7

2.4　解析対象データの構成 7

2.4.1　学習区間と評価区間 7

2.4.2 雑音条件と対象範囲 8

第 3 章 熱流束回帰と沸騰開始判定の手法 9

3.1 音響の周波数解析とスペクトログラムの作成 9
3.1.1 高域通過と時間周波数表現 9
3.1.2 モデルへの共通入力 10
3.2 回帰モデルへの入力特徴 10
3.2.1 PCA による圧縮表現 10
3.2.2 34 個の音響要約特徴 10
3.3 熱流束回帰モデル 11
3.3.1 従来 3 モデル 11
3.3.2 追加 2 モデル 12
3.4 学習・評価方法 12
3.5 アンサンブル学習による予測の統合 13
3.5.1 元 3 の重みと固定ブロック 13
3.5.2 比較構成と保存重み 13
3.6 雑音の付加方法と学習方針 14
3.6.1 固定基準による水流音付加 14
3.6.2 固定モデル評価と条件別再学習の違い 15
3.7 予測熱流束を用いた沸騰開始判定 15
3.8 予測性能の評価指標 15
3.8.1 回帰と領域別指標 15
3.8.2 見逃し・誤報と順位評価 16
3.8.3 検知到達熱流束 16
3.9 特徴利用と予測誤差の分析方法 16
3.9.1 領域分解と同方向・逆符号の比較 16
3.9.2 共通入力加工と特徴除去 17
3.9.3 統合制約下での判定可能性 17

第 4 章 単体モデル・統合モデルの性能評価 18

4.1 単体モデルの熱流束予測性能 18
4.2 アンサンブルによる熱流束予測性能 18
4.2.1 元 3 から 4・5 モデルへの変化 18

4.2.2 予測値の分布 19
4.3 雑音環境下における予測性能と耐性 19
4.3.1 雑音下の絶対性能 19
4.3.2 無雑音からの悪化量 21
4.4 沸騰開始判定性能 22
4.4.1 見逃しと誤報 22
4.4.2 日別の検知到達熱流束 24
4.5 ONB 近傍における予測性能 25
4.6 熱流束予測精度と沸騰開始判定性能の関係 25

第 5 章 統合効果の要因分析と特徴利用の考察 27
5.1 熱流束領域別の予測誤差と偏り 27
5.1.1 全域改善が生じた領域 27
5.1.2 近傍の回復と判定が一致しない理由 28
5.2 モデル間の予測誤差の関係と補完性 28
5.2.1 逆符号の相殺と同方向誤差の縮小 28
5.2.2 調整方向と大きさの分解 29
5.3 統合による誤りの改善と残存要因 29
5.3.1 訂正された判定と失われた判定 29
5.3.2 固定ブロック制約による開始段階の到達上限 29
5.3.3 4 モデルから 5 モデルへの追加効果 30
5.4 入力特徴に対するモデルの依存性 30
5.4.1 1 秒内の時間配置 30
5.4.2 強度と帯域への感度 31
5.5 入力表現・統合方法と予測特性の関係 31
5.5.1 絶対強度と相対形状を除去した対照 31
5.5.2 特徴変更と配分変更の区別 32
5.6 特徴利用の物理的解釈とその限界 32
5.6.1 モデル依存と物理音源をつなぐ条件 32
5.6.2 説明性の到達段階 33
5.6.3 現在の説明と追加検証を要する主張 33

第 6 章 結言 35

6.1 本研究で得られた結論 35
6.2 今後の展望 36

謝辞 37

参考文献 38

参考文献 38

付録 A 再現条件と補足事項 41
A.1 主比較の条件と根拠の対応 41
A.2 先行検討と現在の主条件の関係 42
A.3 IG を補助資料として扱う際の条件 43
A.4 実験装置の補足資料を追加する方針 44

付録 B 未確認事項と完成に向けた確認順序 45
B.1 出典・記述の完成に必要な事項 45
B.2 強い結論を採る場合にのみ必要な追加証拠 46
B.3 本文を完成させるための順序 47

図目次

4.1 元 3 MSE と 5 モデル統合の予測値．各日 270 評価区間を表示．同じ正解段階の点の重なりを軽減するため横座標に表示上のみ $\pm 0.8\,\mathrm{kW/m^2}$ を加えた．計算には元の正解を用いる． 20
4.2 固定学習済みモデルの全域 RMSE と基準 SNR の関係．同じ 540 区間の対応比較. 21
4.3 雑音条件別の FN と FP．同じ熱流束予測から回帰と判定を評価する． 23
4.4 日別 q_{100} の雑音条件依存．破線は各日の採用 ONB 値. 24

表目次

1.1 研究上の問いと本文での評価・回答の対応. 4

2.1 主比較に用いるデータの構成．熱流束は保存ラベルの範囲である. 6
2.2 日別 ONB 閾値として現在採用している値. 7

3.1 34 要約特徴の構成．帯域値は resize 後の近似周波数座標に基づく. 11
3.2 全 7 条件で固定する個別モデルの重み [%]．表示丸めにより総和が 100 とわずかに異なる場合がある. 14

4.1 無雑音における単体・統合の性能．RMSE の単位は $\mathrm{kW/m^2}$．近傍は 30 区間. 19
4.2 全 7 条件の集約 RMSE [$\mathrm{kW/m^2}$]．基準 SNR は各 chunk の実現 SNR とは異なる. 21
4.3 無雑音から基準 SNR $-20\,\mathrm{dB}$ への全域 RMSE 増加量 [$\mathrm{kW/m^2}$]. 22
4.4 日別閾値を用いた ONB 判定．全体の正例 315，負例 225 区間. 22
4.5 基準 SNR $-20\,\mathrm{dB}$ の単体・統合性能．RMSE の単位は $\mathrm{kW/m^2}$. 23
4.6 日別の検知到達熱流束 q_{100} と ONB からの差 g_{100} [$\mathrm{kW/m^2}$]. 24
4.7 5 モデル統合の記録上 ONB 段階における判定．2 WAV から各 15 評価区間，計 30 区間. . . 25

5.1 非重複な領域別の元 3 MSE から 5 モデルへの RMSE 変化 [$\mathrm{kW/m^2}$]. 27
5.2 元 3・HGB・ET の 3 予測群による誤差方向別の全体 MSE 減少への寄与．MSE 寄与の単位は $(\mathrm{kW/m^2})^2$. 28
5.3 現制約下の FN の上限診断．最右列は各標本だけに最適な配分を与えた場合の陽性化可能件数で，共通重みで同時に救済できる保証ではない. 30
5.4 固定モデルへの共通時間行並べ替え．全域 RMSE [$\mathrm{kW/m^2}$]．元の 10 月 7 日対照を用いる. . 31
5.5 特徴除去後に再学習した単体の端点性能．RMSE [$\mathrm{kW/m^2}$]，FN/FP は区間数. 32

A.1 主比較の再現に必要な保存条件. 41
A.2 過去の検討を本文の論理に置く場所. 42

B.1 本文の要確認 ID と必要な根拠. 45
B.2 追加検証の必要性を主張の強さと対応づける. 46

第 1 章

緒言

1.1　研究背景

1.1.1　沸騰開始を音響から捉える意義

沸騰を伴う熱流動系では，熱流束の変化とともに伝熱面上の気泡発生状態が変わる．核沸騰開始（onset of nucleate boiling：ONB）付近の状態を捉えることは，沸騰への移行を監視するための基礎的な課題である．本研究の応用背景は，ナトリウム冷却高速炉の炉心局所異常に伴う冷却材沸騰を早期に把握する音響監視技術である．この技術には，沸騰が十分に発達した状態を識別するだけでなく，背景音が存在する条件で開始付近の変化を捉えることが求められる．実際，常陽で行われた音響法による沸騰検出の予備試験では，ポンプ振動やナトリウム流動などによる背景雑音のため，音響信号による気泡発生の明瞭な識別が困難だったことが報告されている [6]．したがって，雑音下の見逃し・誤報と判断根拠を扱うことは，音響監視技術へ近づくための研究課題となる．

本論文は，この応用に向けた基礎研究として，水を用いたプール沸騰の既存音響データを対象とする．音響から連続的な熱流束を推定することは，熱負荷を定量的に把握する課題であり，ONB を基準とした判定は沸騰への移行を把握する課題である．両者を同じ予測から検討し，推定精度の改善が判定のどの範囲へ及ぶかを明らかにする．水とナトリウムでは物性，伝熱条件，音響伝播および背景音が異なるため，水の試験で得た推定精度を実機の検知性能へ直接読み替えることはできない．水の ONB 段階の判定結果から，実機での警報時間や事故防止効果を直接示すものではない．

音響計測は，気泡の発生に伴う圧力変動を観測できる一方，計測値には周囲の流動，装置の振動，伝達経路および収録系の影響も含まれる．特定の周波数に強い成分が現れたとしても，それだけで気泡の生成・凝縮や加熱体の共振を一意に同定できるわけではない．手塚の実験研究 [7] は，伝熱面形状，サブクール度，音響・画像同期計測を比較し，音源の解釈には条件を変えた実験的根拠が必要であることを示している．学習モデルがある帯域を利用することと，その帯域の音源が物理的に確定していることは，区別する必要がある．

また，沸騰が十分に発達した領域では，熱流束の違いに対応した音響変化を学習できても，ONB

直後の弱い音響変化を安定して検知できるとは限らない．全域の回帰誤差が小さくても，閾値近傍の過小予測が見逃しを生む可能性がある．したがって，早期検知への適合性を評価するには，熱流束推定の精度と ONB 付近の判定を，同じ予測値から別々に検討する必要がある．

1.1.2 雑音と統合に関する課題

音響に背景音が重なると，学習時と異なる入力分布が生じる．異なるモデルの予測を統合すれば誤差を抑えられる可能性があるが，モデルが同じ方向に大きく外れる場合には，単に平均するだけで誤差が解消するとは限らない．また，無雑音で良いモデルへ大きい重みを与えることが，雑音下でも有効とは限らない．統合の有効性は，個々のモデルの精度，誤差の方向・大きさ，入力に対する依存，重みの決め方に関係する．

雑音耐性の評価にも二つの問いがある．一つは，雑音を含む条件でどの程度小さい誤差が得られるかである．もう一つは，無雑音からどの程度悪化するかである．無雑音の精度が異なる方式では，雑音下の絶対誤差が小さいことと，悪化量が小さいことは一致しない．本研究では両方を示し，「雑音耐性」という語に異なる意味が混在しないようにする．

1.2 音響による熱流束推定・沸騰検知に関する従来研究

1.2.1 音響による定量推定と状態判定

Dunlap ら [1] は，ハイドロフォンで取得したプール沸騰音響を用い，特徴抽出と回帰器を組み合わせて熱流束を推定した．出版社掲載の要旨と Highlights では，音響区間長と周波数条件が予測に関係することが報告されている．この研究により，音響から熱流束を回帰する枠組み自体には先行研究があることが分かる．ただし，その結果を本研究と同じ ONB 判定，録音分割，付加雑音条件で得た成績として比較することはできない．本稿では数値の直接対決を行わない．

Barathula ら [2] は，プール沸騰音響から未沸騰，核沸騰，限界熱流束に関係する状態を機械学習で分類している．従って，「音響を使った沸騰検知」や「木モデルの利用」だけを本研究の新規性としては置かない．回帰を介した判定では連続量の誤差と閾値判定の誤りを同じ出力から調べられるが，これだけで直接分類に対する優位が証明されるわけではない．

Ueki ら [3] は，水のサブクール沸騰音響に CNN を適用し，状態分類，Grad-CAM による利用帯域の可視化，熱流束回帰を報告している．また，植木 [4] は，高速炉での沸騰把握という応用目標と，水を用いる音響検知の基礎検討を位置づけている．これらを踏まえると，回帰，判定および説明図を用いることに加え，モデル統合によって何が改善し，開始段階で何が残るかを明示する必要がある．

Huang ら [5] は，サブクール流動沸騰の音響を STFT へ変換して CNN 回帰を行い，白色雑音と運転条件変化の影響を検討している．従って，雑音下の音響回帰という課題自体にも先行研究があ

る．本研究は，プール沸騰の既存録音に対する固定基準の水流音負荷とモデル統合を扱う．対象，雑音種および SNR の基準が異なるため，論文間の誤差や SNR 値の大小をそのまま性能優位の根拠とはしない．

1.2.2 特徴利用の説明と未解決の位置づけ

回帰の精度が向上した理由を調べるには，モデルがどの入力に依存し，その依存が誤差の変化とどのように対応するかを確認する必要がある．勾配に基づく Integrated Gradients（IG）[8] は，入力と基準入力の間の出力差を特徴へ配分する方法である．しかし，寄与画像に強い領域が現れることは，その領域を除去したときの性能変化や，音源の物理的同定と同じ証拠ではない．本研究では，共通の入力加工と特徴除去後の学習も用いて，説明画像から言える範囲を補う．

以上を踏まえ，本論文が取り組む課題は，異なる表現・回帰器の統合による全域熱流束推定と ONB 判定の利得をそれぞれ確かめ，その成立範囲と残る誤りを，誤差構造，入力依存および統合制約から説明することである．従来研究に ONB 評価が存在しないと包括的に主張するのではなく，本研究のデータ・判定・雑音評価の範囲を具体的に定めて位置づける．

> **【要確認：L01】** Dunlap ら・Barathula らは出版社の要旨・公開抜粋，Ueki ら 2025 と植木 2026 は公開抄録・書誌までの確認である．これらの本文に基づく実験数，分割，録音長および ONB 評価の定義を補う．Huang ら 2026 は公開本文の回帰・分割・雑音評価を確認したが，本研究と同一条件の優位性比較ではない．

1.3 本研究の目的

本研究は，音響による熱負荷と沸騰への移行の把握に向け，水のプール沸騰の既存音響データを対象に，背景水流音下での熱流束推定誤差と，予測熱流束に基づく ONB 判定の見逃し・誤報を低減するためのモデル構成および統合条件を明らかにすることを目的とする．熱流束全域の定量推定と ONB 判定を二つの主要な性能課題とし，改善と悪化の理由を説明することによって，音響監視手法の設計と適用判断に必要な知見を得る．

このため，入力表現・学習方式の異なる回帰器を比較・統合し，同じ評価区間に対する全域回帰誤差と閾値判定を区別して検証する．判定では総見逃し・誤報に加えて，開始段階とその近傍を評価する．さらに，予測誤差の関係，共通入力加工，特徴除去後の学習および統合制約を用いて，どこで利得が生じ，どの誤りが残るかを分析する．性能評価と要因分析は，この目的へ回答するための手段として位置づける．

この目的に対し，次の三つの問いを設定する．

1. 異なる入力表現・学習方式のモデルの統合は，対象の測定熱流束範囲と付加水流音条件において，単体・基準構成に比べて全域の熱流束推定誤差をどこまで低減するか．

2. 同じ回帰予測の統合は，既知の日別 ONB 熱流束に基づく総見逃し・誤報をどう変え，その改善は記録上の開始段階と検知到達熱流束まで及ぶか.
3. 回帰・判定の改善と悪化を，予測誤差の方向・大きさ，入力特徴への依存および統合制約からどこまで説明でき，物理的解釈に何が残るか.

問い1では全域推定の誤差低減を，問い2では総判定と開始段階の利得・限界を独立に回答する．雑音時の絶対誤差と無雑音からの悪化量も区別する．問い3では，誤差の代数的な説明，モデルの入力依存，物理的な機構を段階に分けて考察する．異なる依存が観測されたことから，雑音下の利得の物理的原因が確定したとはしない.

本論文における「開始に近い検知」は記録上の熱流束段階について検討し，真の気泡発生時刻に対する検知遅延とは区別する．既知録音内の比較という範囲を明記したうえで，全域推定と総判定の成果，開始段階・劣化量・物理的対応に残る限界を結言で回答する.

表1.1: 研究上の問いと本文での評価・回答の対応.

問い	評価・分析	主な回答の配置
1	全域 RMSE，雑音時の絶対誤差と clean 差，領域別誤差	第 4 章の回帰・雑音評価，第 6 章
2	総 FN/FP，開始段階，近傍，日別 q_{100}	第 4 章の判定・近傍評価，第 6 章
3	誤差分解，入力加工，特徴除去，配分・上限診断	第 5 章の要因分析，第 6 章

1.4 本論文の構成

第 2 章では，使用データの出典，熱流束・ONB ラベルおよび解析対象を示す．第 3 章では，音響入力，回帰モデル，学習・統合，雑音の付加，ONB 判定および評価指標を定義する．第 4 章では，統合によって何が改善したかを，全域回帰から ONB 判定へ段階的に示す．第 5 章では，第 4 章の差を領域別誤差，予測の補完および入力依存から考察し，物理的な意味づけの限界を述べる．第 6 章では研究目的への回答と今後の展望を示す．計算条件，補助結果，未確認事項は付録にまとめる.

第 2 章

使用データと解析条件

2.1　使用データの出典と本研究の対象

本研究は，既存のプール沸騰音響・熱計測データを用いる解析研究である．主比較には，保存資料上で 2025 年 6 月 11 日および 6 月 18 日に対応づけられたデータを使用する．著者はこれらの実験・収録を実施していない．本章では解析に必要なデータとラベルを説明し，著者が実験装置を構築して計測したという記述は用いない．

> **【要確認：D01】**対象 2 日分のデータ取得者・提供元，原実験ノート，収録ファイルと原記録の対応を確認する．手塚の修士論文と実験対象が似ていることだけを理由に，手塚を取得者と記載してはならない．

> **【要確認：D02】**データ取得，熱流束算出，音響前処理，モデル実装・実行，評価・考察について，著者・共同研究者・既存コードの担当を確認する．本稿の解析上の貢献と，著者自身が実施した作業の範囲は最終稿で対応づける．

本稿で扱う解析上の内容は，学習と評価の条件整理，異なる表現を用いる回帰器の比較，統合による誤りの変化の分析，入力依存の検討である．既存データを用いることは解析研究の意義を否定しないが，計測の担当や測定上の確からしさを省略してよい理由にはならない．実験装置の詳細は，対象データに対応する原資料を確認した後に，出典を付して補足する．

2.2　音響・熱計測データの概要

2.2.1　対象条件と収録単位

データはサブクール度 20 °C，細線径 0.3 mm に対応する保存系列に置かれている．解析仕様 [16] による音響サンプリング周波数は 44,100 Hz であり，1 録音の 60 秒を 1 秒ずつ 60 区間へ分割する．本稿では元の録音ファイルを WAV，1 秒区間を chunk と呼ぶ．chunk は音響入力の単位であ

り，独立な沸騰実験の回数ではない．

表2.1: 主比較に用いるデータの構成．熱流束は保存ラベルの範囲である．

収録日	WAV 数	1 秒区間数	熱流束範囲 [kW/m^2]
2025 年 6 月 11 日	18	1,080	約 0–859.34
2025 年 6 月 18 日	18	1,080	約 0–873.64
合計	36	2,160	約 0–873.64

出典：保存予測の正解ラベルと主実行記録 [18].

表2.1の範囲は，現データに含まれる記録範囲を示す．最大記録熱流束を物理的な限界熱流束（CHF）と同一視しない．また，無加熱付近のラベルには計算丸めに相当するごく小さい値が含まれるため，範囲表では約 0 と表記した．ラベルを音響の大きさから作り直したり，静かな区間を未沸騰へ変更したりはしていない．

2.2.2　原実験条件と本稿で確認できた範囲

統合データの`source_metadata/` には，各日の電気計測 CSV，表計算ファイルおよびロガー出力の計 6 ファイルが保存されている．元の日別フォルダの同名 6 ファイルと SHA-256 が全て一致することを確認した [22]．CSV ヘッダーには所有者欄 `UekiLab`，ロガー型式 34972A，水温・シャント電圧・電極電圧等の計測項目があり，対象日の電気計測資料へ遡れる．ただし，所有者欄は実験実施者の氏名を示すものとは限らず，ロガー型式も音響収録器の型式ではない．この確認だけでは，録音区間と熱流束算出区間の対応，装置条件および ONB の観察根拠までは確定しない．

手塚 [7] は，白金細線を用いた水のサブクールプール沸騰装置，電圧・電流による熱量の評価，ハイドロフォンによる音響収録を記述している．ただし，その説明が 2025 年 6 月の各ファイルへどのように対応するかは，現時点で原記録による確認が必要である．従って，装置条件は対象日の原記録と照合して確定する．

> **【要確認：D03】**対象日の細線長・支持条件，作動流体と水量，圧力・水温，センサ型番・位置，収録ゲイン，校正の有無を原資料で確定する．同じ 0.3 mm 系列であることから全条件の一致を推測しない．

2.3　熱流束と ONB ラベルの根拠

2.3.1　熱流束ラベルの意味

各 WAV には一つの熱流束段階が対応し，その 60 個の chunk へ同じラベルを割り当てる．これは，録音段階に対応する熱流束を回帰の正解とする設定である．録音中の一秒ごとの熱流束を別々に測定したという意味ではなく，その一秒に気泡が発生しているかというイベント正解とも異なる．

同じ段階で音響が弱い chunk があっても，熱流束の存在自体が否定されるわけではない．

細線加熱の一般的な熱収支として，細線に加わる電圧を V，電流を I，伝熱面積を A とすると，熱流束を $q = VI/A$ で評価する考え方がある．ただし，実際のラベルについては，電圧の取り方，細線の有効長，損失の扱い，録音時刻との対応を確認して初めて再現可能な算出条件となる．この一般式を示しただけで，対象データの算出手順が確定したとはしない．

【要確認：D04】熱流束 CSV と原電気計測値，電流・面積・時間平均の計算法，音響ファイルとの対応を確認する．ラベルの不確かさを算出するための校正値・寸法誤差・計測誤差も未確認である．

2.3.2　ONB 閾値の値と出典の段階

主比較の判定には，日別の ONB 熱流束を用いる．現在使用している値を表2.2に示す．これらは 2026 年 9 月 24 日の本人確認を記録した現行値 [17] である．使用値が確認されていることと，原実験で ONB を決めた観察・熱計測の手順が確認できていることを区別する．

表2.2: 日別 ONB 閾値として現在採用している値．

収録日	保存値 [W/m^2]	表示値 [kW/m^2]
2025 年 6 月 11 日	221,505.1102	221.5051102
2025 年 6 月 18 日	271,677.6816	271.6776816

過去の自動解析には，抵抗と熱流束の関係において直線性が失われる候補点を ONB と呼んだ出力があったが，その値は現在の ONB とは異なる．本稿ではその自動候補を正解へ戻さない．また，2 日分の ONB の算術平均 246.5913959 kW/m^2 を用いる旧表示があるが，主比較の見逃し・誤報および到達熱流束には，平均閾値ではなく表2.2の日別閾値を適用する．

【要確認：D05】原実験で ONB を定めた資料，観察者，画像・沸騰曲線との照合，判定の分解能と不確かさを確認する．9 月 24 日の確認記録は採用数値の出典であり，実験的な判定根拠の代用にはならない．

2.4　解析対象データの構成

2.4.1　学習区間と評価区間

主比較では，各 WAV の 60 区間を shuffle によって 45 学習区間と 15 評価区間へ分ける．分割 seed は 42 であり，学習は $36 \times 45 = 1,620$ 区間，評価は $36 \times 15 = 540$ 区間となる．同じ評価区間 ID を全モデル・全雑音条件で共有する．ピーク高さなどによる区間選別は行わない．

この分割では，同じ WAV に属する兄弟 chunk が学習側と評価側の両方に含まれる．従って，評価の対象は既知の収録条件・熱流束段階に含まれる未使用区間であり，未知 WAV や未知日への外挿を試したものではない．区間の重複を防いでいることと，録音単位の独立性を確保していることは異なる．本稿はこの条件を主比較の成立範囲として明記する．

主評価集合には，日別 ONB 未満が 225 区間，ONB 以上が 315 区間ある．日別 ONB の $\pm 10\%$ を近傍とすると 30 区間となり，現在の離散的な熱流束段階では，両日の記録上 ONB 段階にある各 15 区間だけが該当する．つまり，この近傍評価には ONB 未満側の近接段階は含まれない．「ONB の両側を均等に評価した帯域」とは呼ばない．

2.4.2 雑音条件と対象範囲

無雑音入力に加え，水流音を付加した基準 SNR $0, -4, -8, -12, -16, -20\,\mathrm{dB}$ の 6 条件を用いる．ここで無雑音とは人工的な水流音を付加しない条件であり，元録音に背景音が全くないことを意味しない．7 条件は同じ録音を加工した対応のある比較であり，独立な 7 回の実験ではない．基準 SNR と区間ごとの実現 SNR の違いは第3章で定義する．

主結果には 10 月 15 日の完了実行を用い，10 月 14 日の誤り分解，10 月 7 日の入力対照を補助証拠として参照する．途中停止した条件別雑音学習の実行や，2026 年の新しい録音日の未評価結果を本稿へ自動的に加えない．一方，既存の異条件の診断から評価範囲を考察する場合は，主系列の数値とは区別して付録に示す．

本章により，研究が答えられるのは，日別の記録上 ONB を基準とした既知 WAV 内の回帰・判定であることを定めた．次章では，このデータと正解の範囲で，どの入力・モデル・統合・指標を用いるかを定義する．

第 3 章

熱流束回帰と沸騰開始判定の手法

本章では，問い1の全域熱流束推定と問い2の ONB 判定に共通する入力・モデル・学習条件を定める．全域誤差，雑音による悪化量および閾値判定を別々に定義し，問い3に対応する誤差・入力依存・制約の分析方法を示す．

3.1　音響の周波数解析とスペクトログラムの作成

3.1.1　高域通過と時間周波数表現

本研究では，保存版 `waterflow_20260817_1s` の線形 power 配列を用いる．生成仕様 [16] は，通過域端 500 Hz，阻止域端 400 Hz，通過域損失 1 dB，阻止域減衰 40 dB の高域通過処理を含む．この前処理により抑制された低周波の有用性を，現在の 3 kHz 入力の結果だけから判断することはできない．また，通過域端 500 Hz は完全な矩形除去の境界ではなく，フィルタの仕様値である．

1 秒の離散音響信号 $x[n]$ に対し，窓 $w[n]$ を移動しながら短時間フーリエ変換を行う．窓長を N_w，フレーム間隔を H とすると，

$$X(t,k) = \sum_{n=0}^{N_w-1} x[n+tH]w[n] \exp\left(-j\frac{2\pi kn}{N_w}\right) \tag{3.1}$$

と表せる．実装は Hann 窓とその振幅補正を用い，FFT の片側振幅を二乗した値を保存する．従って，本稿で STFT power と呼ぶ配列と，別の診断で用いた Welch 法による power spectral density（PSD）は，数値尺度を区別する．校正音圧に基づく絶対 PSD と同一視しない．

生成処理では 672 フレーム，FFT 窓長 1,344 点を用い，1 秒 44,100 点に対してフレーム間隔は 63 点となる．元の FFT 周波数間隔は約 32.81 Hz である．上限 3 kHz に対応する周波数範囲を切り出し，時間・周波数の 2 軸を 224×224 へ resize し，float32 で保存する．resize により画素数が増えても，元の周波数分解能が高くなるわけではない．後述の 34 要約特徴で用いる Hz 対応は，この resize 後配列に対する近似座標である．

3.1.2　モデルへの共通入力

各モデルへ渡す基礎配列を $P_i \in \mathbb{R}_{\geq 0}^{224\times 224\times 1}$ とする．第 1 軸は 1 秒内の時間フレーム，第 2 軸は周波数，第 3 軸は 1 チャンネルである．CNN 系では，

$$L_i = \log\left(1 + \frac{\max(P_i, 0)}{10^{-12}}\right) \tag{3.2}$$

をモデル内部で計算する．これは区間ごとの最大値を 1 にする正規化とは異なり，power の絶対的な大小関係を残した対数圧縮である．RF 系は配列の圧縮表現を，追加 2 モデルは同じ配列から計算した固定要約特徴を用いる．従って，同じ基礎音響を用いる一方で，モデルごとに入力表現が異なる．

3.2　回帰モデルへの入力特徴

3.2.1　PCA による圧縮表現

元 RF では，power 配列を平坦化し，学習側で求めた主成分分析（PCA）で 100 次元へ圧縮する．PCA の中心と主成分は各 fit 側だけから求め，held-out 側と評価側へ固定適用する．保存・再読込時の数値的な差による木の分岐変化を抑えるため，実装では主成分行列の配列配置を揃え，変換後を小数点以下 6 桁へ丸める．この処理は再現のための数値条件であり，音響的な重要度を定義するものではない．

3.2.2　34 個の音響要約特徴

追加 2 モデルは, 学習パラメータを持たない同じ 34 特徴変換を使用する. 各特徴の内訳は表3.1のとおりである．

帯域 B に対応する画素集合を $\mathcal{K}_B$ とし，時間平均も含む帯域平均を

$$p_B = \frac{1}{224|\mathcal{K}_B|}\sum_{t=1}^{224}\sum_{k\in\mathcal{K}_B} P(t,k) \tag{3.3}$$

とする．log-power には $\log_{10}\max(p_B, 10^{-20})$ を用いる．帯域画素の端点は $\mathrm{round}(224f/3000)$ で与える近似であり，理想的な帯域積分としては扱わない．重心と entropy では，時間平均スペクトルを総和で正規化した重みを用いる．entropy は $\log 224$ で規格化する．

時間 power 変動係数は，$a_t = 224^{-1}\sum_k P(t,k)$ の標準偏差を平均で除したものである．これは変動の大きさを表すが，時間の順番を保持しない．他の特徴も時間集約を用いるため，1 秒内の時間行を並べ替えても 34 特徴は不変となる．「時間に関する情報を全く含まない」表現ではなく，「時

表3.1: 34 要約特徴の構成．帯域値は resize 後の近似周波数座標に基づく．

特徴群	個数	定義・対象
帯域 log-power	4	512–1,000，1,000–2,000，2,000–3,000，2,100–2,500 Hz の配列平均の常用対数
全域 log-power	1	配列全体の平均の常用対数
帯域 log 比	2	1,000–2,000 Hz に対する 2,000–3,000 および 2,100–2,500 Hz の比の常用対数
周波数形状	2	周波数重心，正規化スペクトル entropy
時間変動	1	時間フレームごとの平均 power の変動係数
相対 log-power	24	0–3,000 Hz を 125 Hz 刻みにした各帯域の log-power から全域 log-power を引く

出典：特徴変換実装 [23].

間順序を捨てる」表現と位置づける．日付，熱流束ラベル，正解の雑音レベル，無雑音参照は特徴へ含めない．

3.3　熱流束回帰モデル

3.3.1　従来 3 モデル

本稿で元 3 と呼ぶのは, RF, CNN ＋ Transformer, AlexNet である. RF は一般的な呼称を引き継ぐが, 実体は PCA と XGBoost の `XGBRFRegressor`[9] であり, scikit-learn の RandomForestRegressor と同一の実装ではない．主比較では木数 100，最大深さ 12，subsample および colsample_bynode を 0.6 としている．

CNN ＋ Transformer は，式(3.2)の後に 5 つの畳み込み層と pooling を配置し，抽出特徴を時間軸の token 列へ変換する．各 token を 64 次元へ射影し，位置埋め込みを与え，4 head，key 次元 16，中間次元 256 の Transformer encoder を 2 段重ねる．最後に時間平均と線形回帰出力を用いる．attention の考え方は Transformer[10] に基づくが，過去の保存キー `conformer` だけから標準 Conformer の再現と説明してはならない．本稿では実装に即した名称を用いる．

AlexNet 系 [11] では，対数圧縮後の入力へ 5 つの畳み込み層を適用し，Flatten と 4,096 ユニットの全結合層 2 段から線形出力を得る．CNN ＋ Transformer と前段の構造が近いため，名称の違いだけで完全に独立な特徴を利用しているとは考えない．両モデルの依存差は，第 5 章の入力対照で確かめる．

3.3.2　追加 2 モデル

HistGradientBoosting（HGB）は，34 特徴に対する二乗誤差を逐次的に補正する木モデルである．histogram による分割を用いる実装 [12] とし，最大反復 150，学習率 0.05，最大葉数 31，最小葉標本数 20，L2 正則化 1.0，early stopping なしとする．要約特徴から非線形な関係を学習し，元 3 が残す誤差へ異なる予測を与えるかを調べる．

ExtraTrees（ET）は，特徴・分割位置のランダム化を用いる木の平均 [13] である．同じ 34 特徴に対し 256 本の木，最小葉標本数 2，max_features 1.0，bootstrap なしを用いる．HGB と入力を揃えることで，逐次補正とランダム化した木の平均という学習方式の違いを比較できる．ただし，元 3 との比較では表現と学習器を同時に変えるため，性能差を入力表現だけの効果と断定しない．

追加 2 モデルは既存の学習側比較を経て採用された条件 [20] であり，本稿の執筆にあたって候補探索を追加していない．採用理由は，少数要約特徴を用いて異なる予測を得るという仮説と，保存された比較結果の双方から説明する．モデル数が増えたこと自体は効果の証拠ではない．

3.4　学習・評価方法

第 2 章の 1,620 学習区間内を shuffle chunk 3-fold に分け，二つの fold で学習して残りの fold を予測する処理を 3 回行う．これにより，全学習区間に対する out-of-fold（OOF）予測を一つずつ得る．OOF は当該 chunk を fit に用いない予測であるが，同じ WAV の別 chunk が fit 側に入る．従って，OOF も未知 WAV 評価ではない．PCA および目的変数の scaler は，各 fit 側のみに基づく．

統合重みを OOF から決めた後，1,620 区間全体で最終モデルを学習し，540 評価区間へ固定適用する．CNN 系は内部 3-fold と最終 fit を含む計 8 学習で 200 epochs 完走した記録がある．学習率は CNN ＋ Transformer が 0.001，AlexNet が 0.003，batch size はそれぞれ 12，8 である [18]．目的変数の MinMax 変換は学習側で求め，予測を逆変換して保存する．保存予測の単位は $\mathrm{W/m^2}$，主表では 1,000 で除して $\mathrm{kW/m^2}$ とする．

全モデルのハイパーパラメータが十分に最適化されたとは主張しない．また，training loss の減少や 200 epochs の完走は，未知区間上の最良 epoch や過学習がないことの証拠ではない．本稿は保存された固定条件の比較を扱う．

評価区間は当該 fit へ入れていないが，研究の途中で結果を繰り返し参照し，モデル構成や方針を検討している．Cawley と Talbot[14] が論じるモデル選択と評価の関係を踏まえ，本稿の 540 区間を完全に未参照の最終試験とは呼ばない．本稿の数値は研究開発過程での対応比較として解釈する．

> **【要確認：V01】** 200 epochs が最良であるという主張を採る場合に限り，学習側で独立性を定めた validation 曲線と epoch 選択を要する．本稿の固定条件の比較を記述するために，追加学習を自動的な必須作業とはしない．

3.5　アンサンブル学習による予測の統合

3.5.1　元 3 の重みと固定ブロック

モデル m の OOF 予測を z_{im}，正解を q_i とする．元 3 MSE 統合は，

$$\min_{\boldsymbol{a}} \frac{1}{N_{\mathrm{tr}}} \sum_i \left(\sum_{m=1}^{3} a_m z_{im} - q_i \right)^2, \quad \sum_m a_m = 1, \quad a_m \geq 10^{-6} \tag{3.4}$$

で内部比率を求める．従来 performance 統合は，各モデルの OOF MSE を正解分散で割った誤差に対する逆数を規格化する方式である．元 3 MSE は予測を組み合わせた誤差を直接最小化し，performance は個別誤差から重みを与えるという違いがある．いずれも評価側の正解を重み fit に使用しない．

元 3 の重み付き予測を z_{i0} という一つのブロックとして固定する．5 モデルでは HGB と ET を加え，

$$\hat{q}_i = b_0 z_{i0} + b_H z_{iH} + b_E z_{iE} \tag{3.5}$$

とする．係数は clean OOF の全域 MSE を最小にするように求め，

$$b_0 + b_H + b_E = 1, \qquad b_0 \geq 0.25, \quad b_H \geq 0.05, \quad b_E \geq 0.05 \tag{3.6}$$

を課す．4 モデルでは対応する追加モデル一つだけを含める．この下限は元 3 と追加モデルを比較構成内に保持するための設計条件であり，25% や 5% が物理的・普遍的な最適値であることを意味しない．最適化は SLSQP で行い，制約と収束を確認して重みを保存する．

3.5.2　比較構成と保存重み

5 単体に加え，元 3 performance，元 3 MSE，元 3 ＋ HGB，元 3 ＋ ET，5 モデル統合，5 等重みの計 6 統合を比較する．単体と統合は同じ基礎予測を共有し，違いは保存された重みである．主比較の重みを表3.2に示す．

5 モデルの元 3 ブロックは 25%，HGB は約 27.25%，ET は約 47.75% である．元 3 ブロックの下限に達していることは，無制約なら同じ構成が選ばれるという保証ではない．元 3 比率を自由にする対照は第 5 章で扱い，構成保持の意図と数値上の最適化を分けて考察する．

表3.2: 全 7 条件で固定する個別モデルの重み [%]．表示丸めにより総和が 100 とわずかに異なる場合がある．

方式	RF	CNN+Tf	AlexNet	HGB	ET
3-perf	16.94	55.15	27.91	0.00	0.00
3-MSE	5.85	71.32	22.83	0.00	0.00
3+HGB	2.08	25.38	8.12	64.42	0.00
3+ET	1.46	17.83	5.71	0.00	75.00
5-model	1.46	17.83	5.71	27.25	47.75
5-equal	20.00	20.00	20.00	20.00	20.00

3.6　雑音の付加方法と学習方針

3.6.1　固定基準による水流音付加

水流音の元資料は `water_flow_125.wav` である．基準 SNR を s dB，切り出した雑音区間を n_i，その RMS を $R(n_i)$，共通基準 RMS を R_{ref} とすると，付加信号を

$$x_i^{(s)} = x_i + \frac{R_{\mathrm{ref}} 10^{-s/20}}{R(n_i)} n_i \tag{3.7}$$

とする．雑音区間を規格化するため，付加雑音の RMS は，元信号の熱流束や個々の RMS に依存しない．同じ chunk には雑音レベル間で同じ水流音区間を対応させる．

保存された R_{ref} は 0.0004822199855309985 であり，生成時に設定された 3 日分・49 WAV のフィルタ後 RMS の中央値である [16]．主比較はそのうち 6 月の 36 WAV を用いる．7 月 9 日の録音は雑音基準の算出母集団に含まれるが，本稿の性能評価へ追加したものではない．この基準はデータ生成時の共通負荷を定義するものであり，実運用で未知録音から何も参照せず設定できた校正値としては主張しない．また，校正音圧レベルではなく digital amplitude 上の値である．

各 chunk の実現 SNR は，

$$s_i = 20 \log_{10} \frac{R(x_i)}{R_{\mathrm{ref}} 10^{-s/20}} = s + 20 \log_{10} \frac{R(x_i)}{R_{\mathrm{ref}}} \tag{3.8}$$

となり，s と一致するとは限らない．基準 SNR -20 dB は，基準に対して雑音 RMS が 10 倍，power が 100 倍となる設定であり，全区間の実現 SNR が -20 dB という意味ではない．本稿の図表では基準 SNR と明記する．

旧生成の診断では，元音の強さに応じて付加雑音も変わり，付加処理が熱流束の手掛かりを持ち得る経路が確認された．現版の共通基準はこの経路を分けるための条件である．ただし，元信号の強さに依存する相対 SNR そのものを，全ての用途で不正な設計と一般化しているわけではない．本研究の目的に対して，付加負荷を明示的に統制する方式を採る．

3.6.2　固定モデル評価と条件別再学習の違い

本稿の主系列は clean_only であり，無雑音で学習した同じモデル，PCA，scaler，統合重みを全条件へ固定適用する．これは，学習時に含まれない水流音の付加に対して予測がどう変わるかという問いに答える．

一方，matched は各雑音条件で再学習する方式であり，雑音条件を学習した場合の性能を問う．matched 自体を不具合とはしない．旧入力生成の修正と，主評価として固定モデルを選ぶ判断は別である．また，単調に悪化する曲線が得られることを主系列の採用理由にはしない．

3.7　予測熱流束を用いた沸騰開始判定

収録日 d の区間 i に対し，日別 ONB を $q_{\mathrm{ONB},d}$ として，

$$y_i = \mathbf{1}(q_i \geq q_{\mathrm{ONB},d}), \qquad \hat{y}_i = \mathbf{1}(\hat{q}_i \geq q_{\mathrm{ONB},d}) \tag{3.9}$$

と定義する．閾値は実験側の採用値であり，評価側の見逃しを最小にするように後から選び直さない．式(3.9)は既知の日別閾値を用いる解析上の判定であり，未知の実験条件の ONB 閾値を音響だけから同定する問題とは異なる．

本研究は段階ごとに収録された区間を評価するため，真の ONB 発生時刻から何秒後に警報できたかを測定していない．「早期」の適合性は，開始段階の見逃しと，より高い熱流束まで進まないと全区間を陽性にできない程度から限定的に検討する．秒単位の遅延や実機での警報余裕とは区別する．

3.8　予測性能の評価指標

3.8.1　回帰と領域別指標

評価区間数を N とし，残差を $e_i = \hat{q}_i - q_i$ とする．

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_i e_i^2}, \qquad \mathrm{MAE} = \frac{1}{N}\sum_i |e_i|, \tag{3.10}$$

$$\mathrm{bias} = \frac{1}{N}\sum_i e_i, \qquad R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (q_i - \bar{q})^2} \tag{3.11}$$

とする．R^2 は負値を取り得る．全域 RMSE は 540 区間をまとめて求める集約値であり，fold 別 RMSE の単純平均とは区別する．近傍集合を $\mathcal{N} = \{i : |q_i - q_{\mathrm{ONB},d}| \leq 0.1 q_{\mathrm{ONB},d}\}$ とし，同じ式を集合内に適用する．ONB 以上全体と，近傍を除いた高熱流束側を区別する．

雑音条件 s の悪化量には，$D_m(s) = \mathrm{RMSE}_m(s) - \mathrm{RMSE}_m(\mathrm{clean})$ を用いる．異なるモデル間の雑音時の誤差差と，同じモデルの clean からの増加量を別々に示す．

元 3 から 5 への絶対誤差の低減を $G(s) = \mathrm{RMSE}_3(s) - \mathrm{RMSE}_5(s)$ とすると，

$$D_3(s) - D_5(s) = G(s) - G(\mathrm{clean}) \tag{3.12}$$

が成り立つ．従って，雑音時に元 3 より低誤差であることに加え，clean 時より改善幅が大きい場合に，その条件で悪化量も縮小したと判断できる．

3.8.2　見逃し・誤報と順位評価

式(3.9)の正解と予測から TP，FN，FP，TN を数える．ONB 以上を陰性とする誤りが FN，ONB 未満を陽性とする誤りが FP である．

$$\mathrm{Recall} = \frac{TP}{TP+FN}, \quad \mathrm{FPR} = \frac{FP}{FP+TN}, \quad F_1 = \frac{2TP}{2TP+FP+FN} \tag{3.13}$$

とする．全 ONB 以上の Recall に加えて，記録上 ONB 段階だけの検知件数を示す．陽性数が多い高熱流束側で良い成績を得ることによって，開始段階の未達が見えにくくなるのを避けるためである．

ROC-AUC は予測熱流束の連続スコアに対する順位性能として補助的に扱う．日別閾値が異なる集合を生の予測値でまとめた AUC と，日別固定閾値の判定件数は同じ指標ではない．AUC が高くても採用閾値の近傍で FN が残るため，AUC から開始段階の検知達成を結論しない．

3.8.3　検知到達熱流束

日 d に含まれる記録段階の集合を $\mathcal{Q}_d$ とする．

$$q_{100,d} = \min\{q \in \mathcal{Q}_d : \forall i \, (d_i = d,\, q_i \geq q) \Rightarrow \hat{y}_i = 1\} \tag{3.14}$$

を定義する．該当する段階がなければ未到達とする．さらに $g_{100,d} = q_{100,d} - q_{\mathrm{ONB},d}$ を示す．q_{100} は有限の評価集合について，それ以上の全区間が陽性となる最小の記録段階である．誤報ゼロは条件に含めない．常時陽性のモデルでも低い値を取り得るため，FN/FP と併記する．

この値を将来の 100% 検知保証や，連続的な真の ONB 推定値と解釈しない．段階間隔にも依存し，1 区間の予測変化で一段前進することがある．最大記録熱流束を CHF とした規格化も用いない．

3.9　特徴利用と予測誤差の分析方法

3.9.1　領域分解と同方向・逆符号の比較

元 3 と 5 の誤差差を，全域，ONB 前，近傍，高熱流束側に分ける．保存予測での元 3 残差を e_i，5 への調整を $\delta_i = \hat{q}_{5,i} - \hat{q}_{3,i}$ とすると，

$$\mathrm{MSE}_5 - \mathrm{MSE}_3 = \frac{2}{N}\sum_i e_i\delta_i + \frac{1}{N}\sum_i \delta_i^2 \tag{3.15}$$

が恒等的に成り立つ．調整が元の誤差と反対向きでも，調整量が大きすぎると悪化するため，符号と大きさの両方を見る．元 3・HGB・ET の 3 予測群について同方向群と逆符号を含む群に分け，群内の二乗誤差減少の総和を全 N で除して全体 MSE 減少への寄与を求める．これは予測値の損失分解であり，特徴や物理音源の因果寄与率ではない．

3.9.2　共通入力加工と特徴除去

既存の 10 月 7 日の対照 [20] では，同じ raw power 配列に時間行並べ替え，全域 power 0.5 倍・2 倍，対象帯域 power 0.1 倍などの加工を与え，モデルを固定した予測変化を保存している．1 秒内の時間配置，強度，周波数帯の依存を見る手順であり，熱流束の正解は変更しない．人工加工は元の音響分布から外れる場合があり，実際の水流音付加と同じ外乱ではない．

別の対照では，34 特徴から絶対強度 5 特徴だけ，または相対形状等 29 特徴だけを残して学習し直している．固定モデルの入力加工と，情報を減らした後の再学習は異なる比較である．さらに，特徴変更と同時に統合重みを再 fit すると二つの要因が混在するため，元の重みを固定する対照で分ける．第 5 章ではこれらの証拠を，誤差の説明，入力依存，物理的解釈の順に接続する．

3.9.3　統合制約下での判定可能性

残る FN を重み変更だけで訂正できる範囲を調べるため，保存予測に対する上限診断 [21] を用いる．区間 i の元 3 固定ブロック，HGB，ET の予測をそれぞれ p_{i0}, p_{iH}, p_{iE} とする．元 3 総量 0.25 以上，追加各 0.05 以上，非負・総和 1 という現制約で，その区間だけに最も有利な配分を与えた予測上限は，

$$U_i = 0.25p_{i0} + 0.05p_{iH} + 0.05p_{iE} + 0.65\max(p_{i0}, p_{iH}, p_{iE}) \tag{3.16}$$

となる．$U_i < q_{\mathrm{ONB},d}$ なら，元 3 内部比率と現下限を保つ重み変更だけではその区間を陽性化できない．逆に上限が閾値以上でも，共通する一組の重みで複数区間を同時に訂正できることや，他区間の FN/FP を増やさないことは保証しない．評価後の到達可能性の診断であり，評価正解から運用用の配分を選ぶ処理ではない．

第 4 章

単体モデル・統合モデルの性能評価

本章では, 10 月 15 日完了の clean_only 実行 143609 を主系列とする [18]. run hash は `da540f2d`, clean fit の識別子は `7560205f8feb` である．既存の検算記録では，全 7 条件で同じ 540 評価区間と clean fit を共有し，保存重みから 6 統合を再構成した結果が保存予測と一致している．本稿の表は保存 CSV から抽出し，図は保存表・予測だけから描画した．モデルの再学習や新しい推論によって得た結果ではない．

まず問い1に対して，全域回帰と雑音条件による差を示す．次に問い2に対して，総判定，開始段階および検知到達熱流束を示し，両性能の利得と交換を対応づける．

4.1　単体モデルの熱流束予測性能

無雑音条件の全方式を表4.1に示す．単体では ET の全域 RMSE が $28.40\,\mathrm{kW/m^2}$，HGB が $33.25\,\mathrm{kW/m^2}$ であり，CNN ＋ Transformer，AlexNet，RF とは差がある．34 要約特徴を用いた追加 2 モデルは，この条件の全域回帰において有効な予測を与えた．ただし，これは入力表現と学習器を組み合わせた比較であるため，要約処理だけの優位を示す結果ではない．

RF は，全域では CNN 系や追加 2 モデルより誤差が大きい．一方，雑音の影響や判定を含めて比較するには，この順位だけでは不十分である．単体である帯域や強度変化に反応しにくい場合でも，ONB 未満を過大予測すれば誤報が多くなる可能性がある．単体の特徴は，回帰と判定の両方を参照して評価する．

4.2　アンサンブルによる熱流束予測性能

4.2.1　元 3 から 4・5 モデルへの変化

無雑音の元 3 MSE の RMSE は $34.07\,\mathrm{kW/m^2}$，5 モデル統合は $27.80\,\mathrm{kW/m^2}$ であり，約 18.40% 小さい．従来 performance の $35.62\,\mathrm{kW/m^2}$ に対しても小さい．ET 単体の $28.40\,\mathrm{kW/m^2}$ も下回る．

表4.1: 無雑音における単体・統合の性能．RMSE の単位は $\mathrm{kW/m^2}$．近傍は 30 区間．

方式	RMSE	R^2	近傍 RMSE	FN	FP
RF (PCA+XGBRF)	71.71	0.9296	113.59	45	1
CNN+Transformer	35.34	0.9829	38.71	35	1
AlexNet	39.88	0.9782	36.85	39	1
HGB	33.25	0.9849	26.15	21	0
ET	28.40	0.9890	9.73	19	2
3-perf	35.62	0.9826	46.46	44	1
3-MSE	34.07	0.9841	39.58	42	1
3+HGB	29.64	0.9880	24.91	24	0
3+ET	27.35	0.9898	13.37	26	1
5-model	27.80	0.9894	16.45	27	1
5-equal	32.78	0.9853	37.02	43	1

一方，元 3 ＋ ET の $27.35\,\mathrm{kW/m^2}$ は 5 モデルの $27.80\,\mathrm{kW/m^2}$ より小さい．従って，追加モデルを用いた利得は示されるが，HGB と ET を両方加えた 5 モデルが無雑音で常に最良という結果ではない．

単体 ET が元 3 ＋ ET より悪いことは，元 3 を残した統合がこの条件で補う部分を持つことを示す．ただし，元 3 内の三つ全てが不可欠という結論にはならない．同様に，5 モデルが元 3 MSE より良いことから，5 というモデル数が最適であるとは言えない．構成，重み，入力の効果を一括して「モデル数の効果」と説明しない．

4.2.2　予測値の分布

図4.1に日別・端点条件での正解熱流束と予測値を示す．赤破線の縦線は記録段階の ONB，横線は予測値に対する判定閾値である．高い熱流束側で予測が対角線に近い場合でも，縦線付近の点が横線より下にあれば開始段階を見逃す．このため，予測分布の全体像と ONB 近傍の閾値通過を分けて読む必要がある．

4.3　雑音環境下における予測性能と耐性

4.3.1　雑音下の絶対性能

全 7 条件の RMSE を表4.2と図4.2に示す．5 モデル統合は元 3 MSE および元 3 performance より全 7 条件で小さい．元 3 MSE に対し，無雑音 34.07 から $27.80\,\mathrm{kW/m^2}$，$-20\,\mathrm{dB}$ で 81.14 から $75.23\,\mathrm{kW/m^2}$ である．後者の低減率は約 7.28% である．この範囲では，追加 2 モデルを含む統合

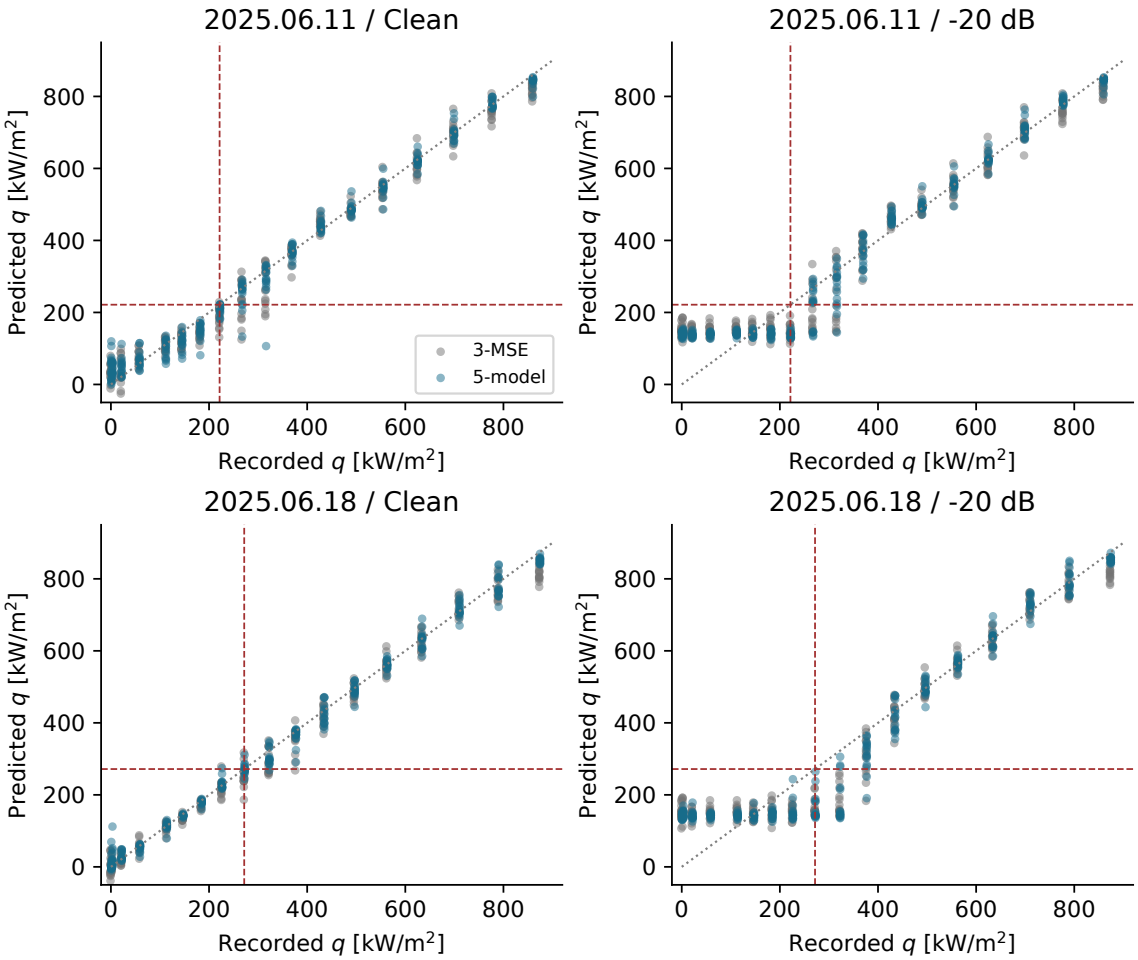


図4.1: 元 3 MSE と 5 モデル統合の予測値．各日 270 評価区間を表示．同じ正解段階の点の重なりを軽減するため横座標に表示上のみ $\pm 0.8\,\mathrm{kW/m^2}$ を加えた．計算には元の正解を用いる．

は雑音時の絶対誤差を改善する．

一方，$-20\,\mathrm{dB}$ では HGB 単体が $74.19\,\mathrm{kW/m^2}$ であり，5 モデル $75.23\,\mathrm{kW/m^2}$ より小さい．ET 単体は $75.43\,\mathrm{kW/m^2}$ で，5 モデルとの差は小さい．元 3 ＋ ET に対しても，5 モデルは無雑音，-4, $-8\,\mathrm{dB}$ では悪化し，他の 4 条件では改善する．従って，統合の有効性は比較相手と雑音条件を指定して述べる必要がある．

評価後に各条件の最良単体を探すと，無雑音から $-16\,\mathrm{dB}$ までは ET，$-20\,\mathrm{dB}$ では HGB となる．これは事後的な記述比較であり，入力の真の SNR を知って最良単体を選択できる運用方式を実装した結果ではない．

表4.2: 全 7 条件の集約 RMSE [kW/m^2]．基準 SNR は各 chunk の実現 SNR とは異なる．

基準 SNR	3-perf	3-MSE	3+ET	5-model	HGB	ET
無雑音	35.62	34.07	27.35	27.80	33.25	28.40
0	53.84	53.12	50.85	50.27	54.45	52.52
−4	62.85	62.76	61.31	61.95	69.02	62.44
−8	68.05	68.12	66.40	66.66	71.16	67.08
−12	71.73	72.37	69.13	69.01	70.93	69.24
−16	76.59	76.14	71.86	71.51	71.78	71.60
−20	84.30	81.14	76.11	75.23	74.19	75.43

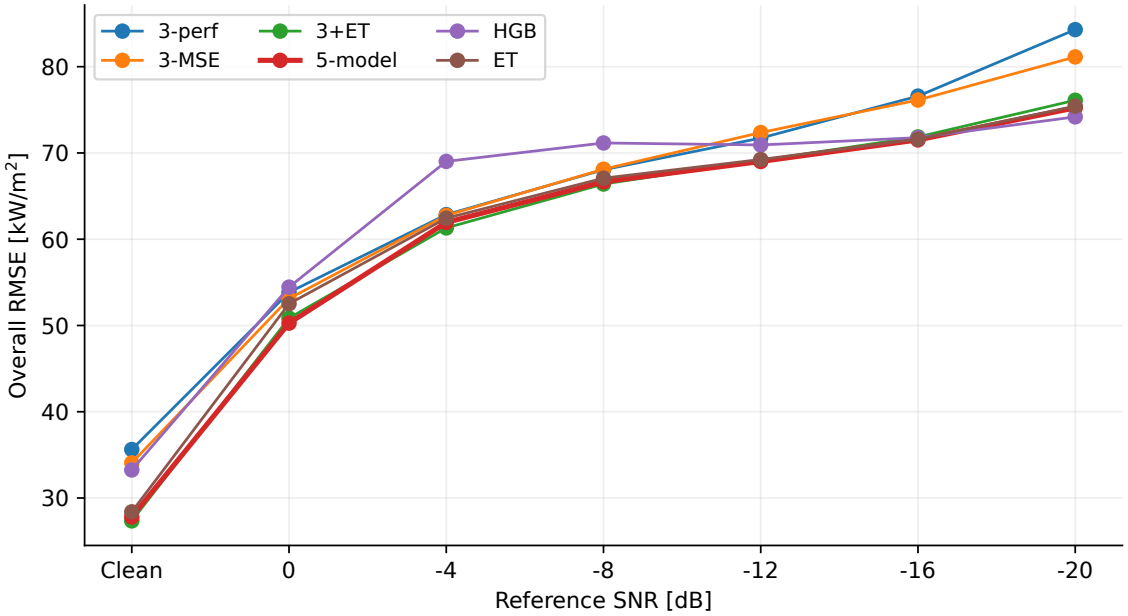


図4.2: 固定学習済みモデルの全域 RMSE と基準 SNR の関係．同じ 540 区間の対応比較．

4.3.2　無雑音からの悪化量

表4.3に無雑音から −20 dB への RMSE 増加量を示す．元 3 MSE は 47.07 kW/m^2，5 モデルは 47.43 kW/m^2 であり，5 モデルの増加量は小さくなっていない．一方，元 3 performance の 48.68 kW/m^2 と比べれば 5 モデルの増加量は小さい．従って，「雑音下の誤差が改善した」という結論と，「悪化量を抑えた」という結論は比較基準に応じて分ける．

元 3 MSE に対する 5 モデルの絶対 RMSE 低減幅は，無雑音の約 6.269 から −20 dB の約 5.903 kW/m^2 へ縮む．式(3.12)から，悪化量の低減は約 −0.366 kW/m^2 となる．保存表では付加雑音の全 6 条件で 5 の clean からの増加量が元 3 MSE より大きかった．元 3 performance に対して

表4.3: 無雑音から基準 SNR −20 dB への全域 RMSE 増加量 [kW/m^2].

方式	無雑音	−20 dB	増加量
3-perf	35.62	84.30	48.68
3-MSE	34.07	81.14	47.07
3+ET	27.35	76.11	48.76
5-model	27.80	75.23	47.43
HGB	33.25	74.19	40.93
ET	28.40	75.43	47.03

も，増加量が小さいのは −20 dB の端点だけであり，他の 5 条件では小さくない．全域推定の絶対誤差低減は確認された成果であり，無雑音からの劣化量抑制はこの比較では支持されなかった結果である．

4.4　沸騰開始判定性能

4.4.1　見逃しと誤報

日別閾値を用いた判定を表4.4と図4.3に示す．5 モデルの FN/FP は無雑音 27/1，−20 dB で 52/0 である．元 3 MSE は 42/1，65/0 であり，5 モデルは全 7 条件で総 FN が少なく，FP は同数である．無雑音では元 3 の 15 件の FN を訂正し，新しい FN は 0 件であった．−20 dB でも 13 件を訂正し，新 FN は 0 件である [18].

表4.4: 日別閾値を用いた ONB 判定．全体の正例 315，負例 225 区間.

基準 SNR	3-MSE FN/FP	3+ET FN/FP	5-model FN/FP	5 Recall [%]
無雑音	42 / 1	26 / 1	27 / 1	91.43
0	45 / 0	44 / 1	44 / 0	86.03
−4	52 / 0	45 / 1	45 / 0	85.71
−8	57 / 0	46 / 0	47 / 0	85.08
−12	60 / 0	48 / 0	48 / 0	84.76
−16	65 / 0	51 / 0	50 / 0	84.13
−20	65 / 0	52 / 0	52 / 0	83.49

単体 ET を基準にすると，無雑音では 5 モデルの FN は 19 から 27 へ増える．標本別には ET の FN を 2 件訂正する一方，ET で陽性だった 10 件を新たに FN とした．従って，平均化は良い判定

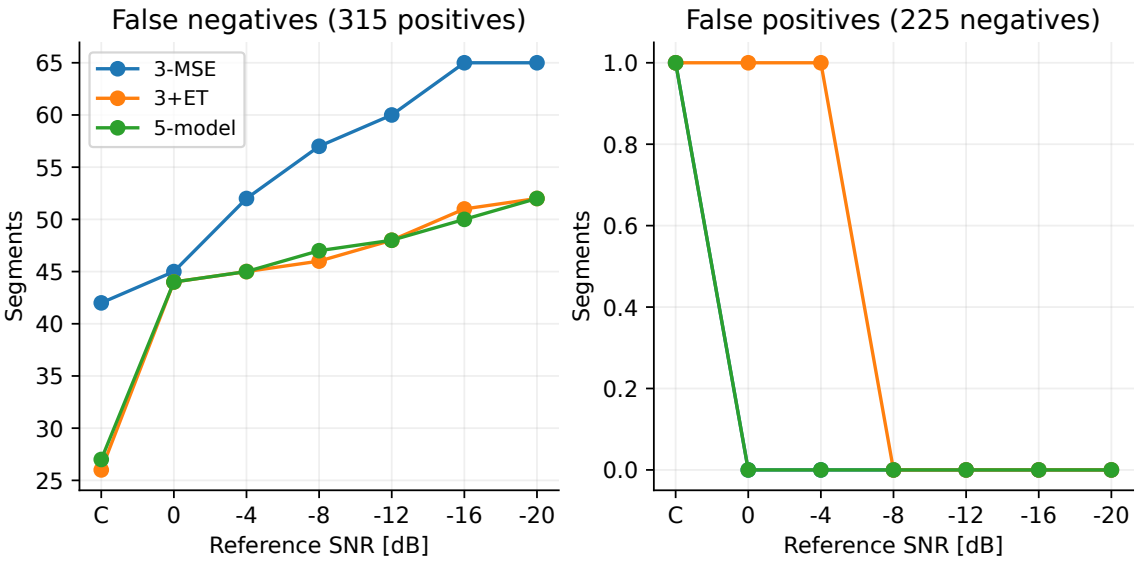


図4.3: 雑音条件別の FN と FP．同じ熱流束予測から回帰と判定を評価する．

を保存する処理ではない．ある単体の陽性が他の予測と混ざることで，閾値未満へ戻る場合がある．

表4.5: 基準 SNR -20 dB の単体・統合性能．RMSE の単位は kW/m^2.

方式	RMSE	R^2	近傍 RMSE	FN	FP
RF (PCA+XGBRF)	151.28	0.6865	61.98	0	217
CNN+Transformer	81.62	0.9088	96.37	68	0
AlexNet	81.66	0.9087	124.94	65	0
HGB	74.19	0.9246	107.28	49	0
ET	75.43	0.9221	100.34	50	1
3-perf	84.30	0.9027	79.16	62	0
3-MSE	81.14	0.9098	93.92	65	0
3+HGB	74.95	0.9230	100.74	55	0
3+ET	76.11	0.9207	98.38	52	0
5-model	75.23	0.9225	99.32	52	0
5-equal	82.42	0.9070	74.24	52	0

表4.5では RF 単体の FN が 0 である一方，FP は 217 である．これは負例 225 区間の大部分を誤報する状態であり，FN の少なさだけから早期検知に適すると判断できない．局所誤差や q_{100} も同様に，誤報との組合せで解釈する．

4.4.2　日別の検知到達熱流束

表4.6と図4.4に q_{100} を示す．6 月 18 日の無雑音では元 3 MSE の 434.02 kW/m^2 から 5 モデルの 376.32 kW/m^2 へ低下するが，元 3 ＋ ET は 322.11 kW/m^2 である．6 月 11 日は元 3 MSE，元 3 ＋ ET，5 モデルとも 368.98 kW/m^2 であり，総 FN が減っても到達段階は変わらない．

表4.6: 日別の検知到達熱流束 q_{100} と ONB からの差 g_{100} [kW/m^2].

日・条件	ONB	3-MSE	3+ET	5-model	g_{100} (5)
06.11 無雑音	221.51	368.98	368.98	368.98	147.47
06.11 −20	221.51	368.98	368.98	368.98	147.47
06.18 無雑音	271.68	434.02	322.11	376.32	104.64
06.18 −20	271.68	434.02	434.02	434.02	162.34

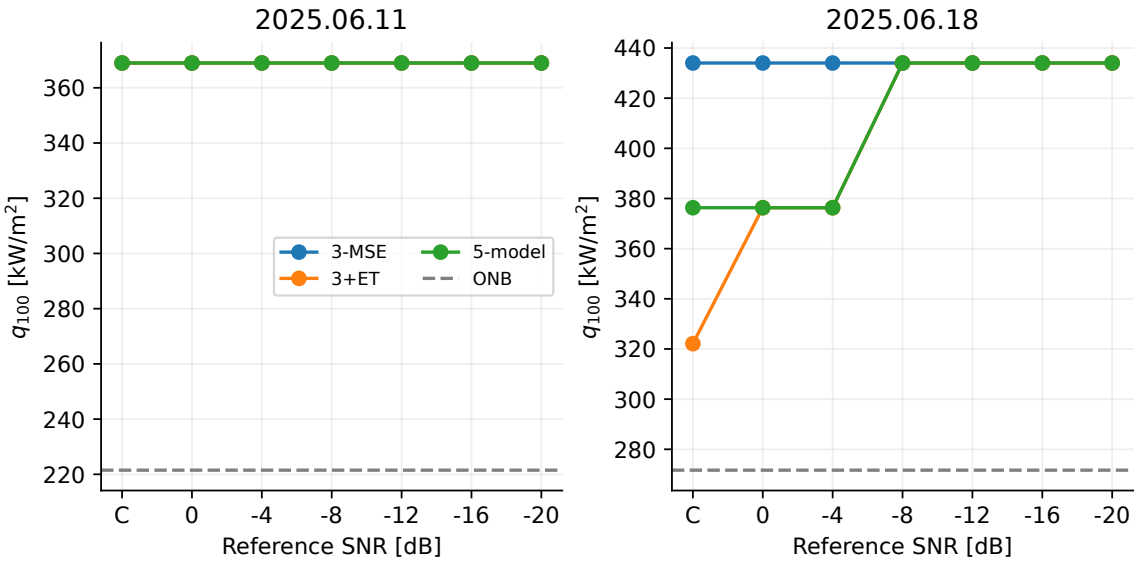


図4.4: 日別 q_{100} の雑音条件依存．破線は各日の採用 ONB 値．

q_{100} は最後に残る FN の段階へ強く依存する．他の段階で多数の FN を訂正しても，その最終段階に 1 件残れば値が変わらない．逆に 1 件の訂正で一段前進する場合もある．従って，FN 総数の改善と q_{100} の改善は矛盾する指標ではなく，判定の異なる側面を表している．

4.5　ONB 近傍における予測性能

5 モデルの近傍 RMSE は，無雑音では元 3 MSE の 39.58 から 16.45 kW/m^2 へ低下する．一方，−20 dB では 93.92 から 99.32 kW/m^2 へ増えた．全域 RMSE の全 7 条件での改善は，ONB 近傍まで一律に改善することを意味しない．

さらに，記録上 ONB 段階の 30 区間に対する検知を表4.7に示す．5 モデルは無雑音で 8 区間を検知し，22 区間を見逃す．−20 dB では全 30 区間を見逃す．全 ONB 以上 315 区間に対する Recall は無雑音 91.43%，−20 dB で 83.49% であるが，開始段階に限定した割合はそれぞれ 26.67%，0% となる．母数と対象段階を変えると見える結論が異なる．

表4.7: 5 モデル統合の記録上 ONB 段階における判定．2 WAV から各 15 評価区間，計 30 区間．

基準 SNR	記録上 ONB 段階	検知	見逃し	検知割合 [%]
無雑音	30	8	22	26.67
0	30	2	28	6.67
−4	30	2	28	6.67
−8	30	2	28	6.67
−12	30	1	29	3.33
−16	30	0	30	0.00
−20	30	0	30	0.00

この 30 区間は独立した 30 回の ONB 発生実験ではない．二つの段階録音から抽出された評価区間の判定であり，区間に真の気泡発生秒のラベルがあるわけでもない．この範囲でも，開始段階の十分な検知を達成したという結論は支持されない．

近傍 RMSE には非単調な変化もある．5 モデルでは −12 dB の 113.32 から −20 dB の 99.32 kW/m^2 へ小さくなる一方，総 FN は 48 から 52 へ増え，ONB 段階の見逃しも 29 から 30 へ増える．平均予測が上方へ動いて誤差が小さくなっても，閾値を超えない限り判定は訂正されない．局所回帰誤差の回復を，ONB 検知の回復と同義には扱わない．

4.6　熱流束予測精度と沸騰開始判定性能の関係

本章の結果は，熱流束回帰と ONB 判定が同じ予測を用いながら，異なる評価を必要とすることを示す．元 3 MSE から 5 モデルへの変更で，全域 RMSE と総 FN は改善した．しかし，無雑音の ET4 に対する優位，−20 dB の HGB に対する優位，ONB 近傍と最初の ONB 段階の十分な検知は得られていない．

全域 MSE は，全区間の二乗誤差を小さくする指標である．ONB 判定は，予測が閾値のどちらに

位置するかで決まる．そのため，近傍の小さな過小予測が検知上重大でも，高熱流束側の大きな誤差低減によって全域指標が改善することはあり得る．本研究ではこの関係を実際の保存予測で確認した．

問い1に対しては，対象の全 7 条件で元 3 MSE より全域推定誤差を低減したと回答できる．問い2に対しては，全 7 条件で総 FN を減らし FP を維持した一方，開始段階・近傍・日別 q_{100} への利得は限定的であったと回答できる．全域推定と総判定は独立した主要成果として述べ，開始段階の限界も同じ回答の中へ残す．次章では問い3に対して，どの領域・誤差群が変わり，どの入力と制約が関係するかを考察する．

第 5 章

統合効果の要因分析と特徴利用の考察

第 4 章では，全域回帰と総見逃しへの利得が，ONB 近傍や検知到達段階の一律改善にはつながらないことを示した．本章では，まず保存予測から直接確認できる誤差の変化を示し，次に入力依存との関係を考察する．最後に，モデル上の依存から物理的な音源へ説明を進めるために何が不足するかを明らかにする．保存予測の分析は 10 月 15 日の主実行と 10 月 14 日の接続分析 [19]，入力対照は 10 月 7 日の完了記録 [20] に基づく．

本章は問い3への回答を担う．出力上の損失分解，入力への依存，統合制約による到達範囲を区別し，第 4 章で観測したどの性能差を説明する証拠かを明示する．

5.1　熱流束領域別の予測誤差と偏り

5.1.1　全域改善が生じた領域

表5.1では，評価 540 区間を ONB 前 225，ONB 近傍 30，近傍を除く高熱流束側 285 区間の非重複な 3 領域へ分ける．無雑音では元 3 から 5 への変更により，近傍と高熱流束側の RMSE が小さくなる一方，ONB 前は 27.10 から 29.54 $\mathrm{kW/m^2}$ へ増えた．$-20\,\mathrm{dB}$ では ONB 前と高熱流束側が改善し，近傍は 93.92 から 99.32 $\mathrm{kW/m^2}$ へ悪化する．全域改善の内訳は雑音条件で異なる．

表5.1: 非重複な領域別の元 3 MSE から 5 モデルへの RMSE 変化 [$\mathrm{kW/m^2}$].

領域	n	無雑音・元 3	無雑音・5	-20・元 3	-20・5
全域	540	34.07	27.80	81.14	75.23
ONB 前	225	27.10	29.54	102.01	94.29
ONB 近傍	30	39.58	16.45	93.92	99.32
高熱流束側	285	38.14	27.33	57.70	51.63

出典：領域分けを明示した保存予測分析 [19]．ONB 以上全 315 区間の指標と混同しない．

非重複な領域 r の標本数を n_r とすると，$\mathrm{MSE}_{\mathrm{all}} = \sum_r (n_r/N)\mathrm{MSE}_r$ である．RMSE 自体の加

算ではない．近傍は全体の 30/540 であり，その領域が悪化しても，他の領域の二乗誤差減少が上回れば全域値は改善する．これは近傍を軽視してよいという意味ではなく，全域目的と検知目的の違いを理解するための関係である．

5.1.2　近傍の回復と判定が一致しない理由

主実行では，−12 から −20 dB へ進むと 5 モデルの近傍 bias は −107.52 から −94.79 $\mathrm{kW/m^2}$ へ変わる．過小予測が弱まることで近傍 RMSE は小さくなるが，予測が ONB 閾値に届かなければ FN は残る．さらに，他の ONB 以上の段階で FN が増えると総見逃しは悪化する．局所 RMSE と判定件数が異なる動きをすることは，指標の計算誤りを意味しない．

保存重みでモデルごとの平均予測変化を分けると，この近傍 bias の上方変化 12.72 $\mathrm{kW/m^2}$ に対し，ET の重み付き寄与は約 8.02 $\mathrm{kW/m^2}$ である [18]．これは固定予測の代数的な内訳であり，ET が気泡音を適切に取り出したことや，雑音が物理的に検知を助けたことの証明ではない．

全域 MSE で配分を決めていることと，近傍性能が一律には良くならない観測は整合する．ただし，全域目的だけが近傍の悪化を生んだと因果的に確定するには，入力・学習器・分割等を揃えて目的関数だけを変える比較が必要である．本稿では，観測事実とそれに整合する解釈の段階で述べる．

5.2　モデル間の予測誤差の関係と補完性

5.2.1　逆符号の相殺と同方向誤差の縮小

平均化の説明として，過大予測と過小予測の相殺が挙げられる．しかし，現在の統合効果はそれだけでは説明できない．元 3・HGB・ET の 3 予測群の誤差方向で分けた結果を表5.2に示す．無雑音では同方向群が全体 MSE 減少の 54.65%，−20 dB では 87.15% を占めた．

表5.2: 元 3・HGB・ET の 3 予測群による誤差方向別の全体 MSE 減少への寄与. MSE 寄与の単位は $(\mathrm{kW/m^2})^2$.

条件	誤差群	n	改善数	MSE 減少寄与	割合 [%]
無雑音	逆符号を含む	211	178	175.88	45.35
無雑音	同方向	329	204	211.97	54.65
−20 dB	逆符号を含む	112	86	118.61	12.85
−20 dB	同方向	428	271	804.44	87.15

例えば，三つの予測が全て過小でも，その中に正解に近い予測があれば，統合によって基準の大きな過小誤差を縮められる．正解を挟む予測がなければ誤差を完全に相殺できないが，基準モデルより良くなることはある．同方向群の改善を「相殺が働いた」と一括して呼ぶと，この違いが失わ

れる．

表の 87.15% は，同方向群の二乗誤差減少の総和を全体の二乗誤差減少で除した割合である．群内の 87.15% が改善したという意味ではなく，音響特徴の寄与率でもない．また，五つの単体全てが同方向という分類ではなく，実際の追加統合単位である三つの予測群の分類である．

5.2.2　調整方向と大きさの分解

式(3.15)による無雑音の MSE 差は，

$$-851.94 + 464.09 = -387.85 \quad [(\mathrm{kW/m^2})^2] \tag{5.1}$$

であり，$-20\,\mathrm{dB}$ では，

$$-1346.86 + 423.81 = -923.05 \quad [(\mathrm{kW/m^2})^2] \tag{5.2}$$

となる [19]．元誤差と調整の積による負の項が，調整自体の二乗による正の項を上回ったことが，全体改善の直接の説明となる．この分解は保存予測に対して恒等的に成立するため，性能差をどの調整が作ったかを追跡できる．一方，なぜその予測をモデルが出したかという入力・物理の説明は，別の証拠を要する．

5.3　統合による誤りの改善と残存要因

5.3.1　訂正された判定と失われた判定

元 3 MSE から 5 への変更では総 FN が減るが，ET 単体から 5 への変更では陽性が平均化で失われる例がある．この違いは，全域回帰に有利な出力調整と，閾値通過を保つ調整が同じではないことを表す．第 4 章の無雑音例では ET の 2 FN を訂正し，10 件を新たに FN とした．良い単体の判定をそのまま保持する規則として，現在の凸結合を解釈してはならない．

5 モデルで残る無雑音 27 FN のうち，11 件は五つの単体全てが陰性であり，16 件には少なくとも一つ陽性の単体があった [18]．前者は現在の単体群に共通した失敗，後者は単体の陽性が統合で残らなかった失敗である．ただし，この診断は正解を見た後の分類であり，16 件を運用時に自動的に見分けて全て救えることを示さない．

全単体共通の失敗も，入力に情報がないことの証明ではない．現在の表現，学習器，損失，学習標本では利用できなかった可能性が残る．入力除去後の別モデルで一部が訂正される例もあるため，「五つが失敗したから音響に原理的な限界がある」と断定しない．

5.3.2　固定ブロック制約による開始段階の到達上限

式(3.16)の上限診断 [21] を表5.3に示す．無雑音の総 FN 27 区間には少なくとも一つ陽性の単体がある 16 区間が含まれるが，元 3 内部比率と下限を維持したときに標本ごとなら陽性化できる上

限は 8 区間であった．単体の陽性が存在することと，現制約でその陽性を取り込めることは異なる．

表5.3: 現制約下の FN の上限診断．最右列は各標本だけに最適な配分を与えた場合の陽性化可能件数で，共通重みで同時に救済できる保証ではない．

条件	対象	FN	全 5 単体陰性	現制約で可能
無雑音	全 FN	27	11	8
無雑音	開始段階の FN	22	9	6
$-20\,\mathrm{dB}$	全 FN	52	0	2
$-20\,\mathrm{dB}$	開始段階の FN	30	0	0

$-20\,\mathrm{dB}$ の開始段階では全 30 区間で上限が ONB 閾値未満であった．この範囲は，現基礎予測，元 3 内部比率および配分下限を保つ重み変更だけでは改善できない．ONB 目的へ損失を変える比較を考える場合も，現制約のままこの 30 区間を救うことを期待する根拠は弱い．一方，別の入力・学習や制約変更まで不可能と示したものではなく，入力情報の不在を意味しない．

5.3.3　4 モデルから 5 モデルへの追加効果

元 3 ＋ ET から 5 への変更は，保存された配分において，概ね HGB と ET の予測差の 27.25% を加える調整である．10 月 14 日の保存予測では，無雑音の MSE 差が $+24.94\,(\mathrm{kW/m^2})^2$，$-20\,\mathrm{dB}$ が $-132.91\,(\mathrm{kW/m^2})^2$ となった [19]．前者は追加調整が誤差を大きくし，後者は誤差を減らす方向へ働く．

$-20\,\mathrm{dB}$ では改善区間 268 に対して悪化区間 272 であっても，全体 MSE は小さくなった．件数の多数決ではなく，各区間でどれだけ誤差が変わったかが二乗誤差を決めるためである．「改善した標本が多い」「モデルが一つ増えた」といった説明だけでは，追加効果の量は分からない．

5.4　入力特徴に対するモデルの依存性

5.4.1　1 秒内の時間配置

表5.4に，無雑音の共通時間行並べ替えの結果を示す．CNN ＋ Transformer の RMSE は 35.34 から $47.99\,\mathrm{kW/m^2}$，AlexNet は 39.88 から $56.45\,\mathrm{kW/m^2}$ へ増えた．HGB と ET は不変である．元 3 MSE は 34.07 から $47.52\,\mathrm{kW/m^2}$，5 モデルは 27.80 から $31.10\,\mathrm{kW/m^2}$ となった．

HGB/ET の不変性は，34 特徴が時間行の順番を保持しない構造と一致する．CNN 系の変化は，固定モデルの予測が 1 秒内の配置に依存することを支持する．ただし，並べ替えは連続した音響として不自然な配置を作り得る．その誤差増加を，実際の気泡成長・凝縮過程の情報を正しく使っている量としては解釈できない．

表5.4: 固定モデルへの共通時間行並べ替え．全域 RMSE [kW/m^2]．元の 10 月 7 日対照を用いる．

方式	元入力	時間行並べ替え後	増加量
RF (PCA+XGBRF)	71.71	71.21	-0.50
CNN+Transformer	35.34	47.99	12.65
AlexNet	39.88	56.45	16.58
HGB	33.25	33.25	0.00
ET	28.40	28.40	0.00
5-model	27.80	31.10	3.30
3-MSE	34.07	47.52	13.45

5 モデルの加工後の悪化が元 3 より小さいことには，固定配分による構造上の説明もある．HGB と ET の予測が不変で，元 3 内部比率を保つブロック重みが 0.25 であるため，時間行の並べ替えを π と書けば，

$$\hat{q}^{\pi}_{5,i} - \hat{q}_{5,i} = 0.25\left(\hat{q}^{\pi}_{3,i} - \hat{q}_{3,i}\right) \tag{5.3}$$

が成り立つ．これは構成式と不変性からの関係であり，RMSE 差そのものが 1/4 になることを意味しない．異なる入力表現と，それらへ与える配分を合わせて説明する必要がある．また，並べ替えと水流音付加は異なる加工であり，この式から水流雑音下の利得を生む因果割合まで確定することはできない．

5.4.2　強度と帯域への感度

全域 power を 2 倍にした対照では，HGB の RMSE は 33.25 から 71.33 kW/m^2，ET は 28.40 から 76.58 kW/m^2 へ増えた．2.1–2.5 kHz の power を 0.1 倍にした対照では，それぞれ 147.97, 133.15 kW/m^2 となった [19]．順序に不変であることは，強度や帯域の変化にも不変であることを意味しない．

この帯域には絶対 power と相対形状の複数の特徴が関係する．加工による悪化は，元モデルがその情報に依存していたことを示すが，その帯域だけが沸騰の情報を持つという証拠ではない．全域 gain と帯域加工が特徴分布を変える点，帯域座標が resize 後の近似である点にも留意する．物理周波数の精密な同定には，元波形・伝達特性との照合が必要である．

5.5　入力表現・統合方法と予測特性の関係

5.5.1　絶対強度と相対形状を除去した対照

34 特徴を絶対強度 5 特徴または相対形状等 29 特徴へ減らして再学習した結果を表5.5に示す．両モデルとも全 34 特徴が，全域回帰で削除表現より小さい誤差を与えた．この範囲では，強度と形

状を併用する表現が回帰精度を支える．

表5.5: 特徴除去後に再学習した単体の端点性能．RMSE [kW/m^2]，FN/FP は区間数．

モデル	入力	無雑音 RMSE	無雑音 FN/FP	−20 RMSE	−20 FN/FP
HGB	全 34	33.25	21/0	74.19	49/0
HGB	絶対 5	44.71	25/2	129.78	30/106
HGB	相対等 29	46.46	18/0	93.77	52/0
ET	全 34	28.40	19/2	75.43	50/1
ET	絶対 5	40.85	29/1	120.38	24/113
ET	相対等 29	41.77	23/1	80.09	51/0

出典：入力除去後の保存対照 [20, 19].

絶対 5 の HGB は −20 dB で全 34 より FN が少ない一方，FP が 106 へ増える．誤差や FN 一つだけで「情報を減らした方が検知に有効」と結論できない例である．また，相対形状等 29 には時間 power 変動係数も含まれるため，完全に周波数形状だけの対照と呼ばない．

5.5.2　特徴変更と配分変更の区別

HGB だけを相対等 29 へ変更した 5 統合では，元の重みを固定すると無雑音 RMSE が 27.80 から 29.06 kW/m^2 へ増え，6 月 18 日の q_{100} は 376.32 kW/m^2 のままであった．一方，OOF で重みを再 fit すると RMSE は 27.39 kW/m^2，q_{100} は 322.11 kW/m^2 となる．このとき HGB の配分は約 27.25% から 5% へ下がり，ET へ 70% が配分された [20].

従って，この q_{100} の前進を「相対形状を使ったため」と単独で説明することはできない．入力変更による clean MSE 差は元重みで $+71.78\,(\mathrm{kW/m^2})^2$，そこから重み変更で $-94.56\,(\mathrm{kW/m^2})^2$ であり，配分変更を伴う結果である．元 3 + ET にも既に同じ q_{100} の利点があるため，新表現だけの独自な検知利得とも断定しない．

元 3 内比率を自由にする既存対照では，無雑音 RMSE は 27.47 kW/m^2 となるが，−20 dB で FN は 52 から 53 へ増える．固定比率の解除にも交換関係がある．現在の構成は，全域回帰，判定，元 3 保持という比較意図を合わせた採用条件であり，全ての指標の普遍的最適解ではない．

5.6　特徴利用の物理的解釈とその限界

5.6.1　モデル依存と物理音源をつなぐ条件

ここまでの結果から直接言えるのは，モデル群が同じ入力変化に同じ応答をするわけではなく，統合による予測調整が領域ごとの誤差を変えることである．一方，帯域への感度が高いことだけでは，その帯域が気泡の成長・凝縮あるいは固体振動を表すと確定できない．原音の発生，伝達，収

録，前処理，学習という複数段階が観測特徴へ関係するためである．

手塚・植木らの 2024 年発表要旨 [15] には，細線径に伴う音響ピークの移動と加熱固体の共振帯との対応が記述されている．一方，手塚の 2026 年最終修士論文 [7] の第 5 章では，調査範囲で共振と重なる部分はあるが伝熱構造体振動との強い相関は確認できなかったと述べ，2 kHz 付近のピークを気泡凝縮に伴う圧力変動として考察している．対象と証拠の追加により解釈が変わり得るため，初期要旨だけを使って本研究の帯域を固体共振と断定しない．本データの音源を同定するには，装置・計測・前処理条件を照合し，その解釈に対応する独立した根拠を確認する必要がある．

Dunlap ら [1] では低周波特徴の重要性が報告される一方，本研究では 500 Hz 高域通過後の入力を用いる．異なる対象・装置・前処理の結果であり，一方が他方を直ちに否定する関係ではない．本研究のモデルが 3 kHz 以下を利用した事実を，低周波域が物理的に不要であるという結論へ広げない．

> **【要確認：L02】**手塚の最終修論の図 3.2.1，第 3 章のサブクール度比較，第 4 章の同期観測を，対象データの原条件と対応づけて検討する．必要に応じて引用元の査読論文まで確認する．現在の 2.1–2.5 kHz 帯を特定の音源へ確定できる根拠は不足している．

5.6.2　説明性の到達段階

説明性は，少なくとも三段階に分けると現在地を明確にできる．第一は，保存予測のどの調整が誤差を変えたかという出力上の説明であり，式(3.15)と誤り群の分解で直接確認できる．第二は，どの入力加工が出力や誤差を変えるかというモデル上の依存であり，共通加工と特徴除去の対照がこれを支える．第三は，その特徴がどの沸騰機構を捉えたかという物理的な説明であり，独立した観測と実験条件の照合を要する．

IG[8] を用いる場合にも，出力が回帰値であること，基準入力，積分近似の収束と寄与和の整合を確認する必要がある．数値的に収束した寄与画像であっても，それだけで物理音源を同定したことにはならない．本稿の中心結論は共通入力対照と保存予測で支え，未確認の IG 画像の印象によって補強しない．IG の位置づけと残る確認は付録に示す．

5.6.3　現在の説明と追加検証を要する主張

問い3に対しては，全域推定・総判定の利得を作った領域と予測調整，モデル群の入力依存差，現固定ブロック制約で訂正できない開始段階を具体化したと回答できる．これらは，保持する入力情報，統合の目的および配分制約を対応づけて設計する根拠となる．入力依存の差が水流音下の利得を生む因果割合，特定帯域の音源，実際の気泡発生秒に対する応答は未確定である．

> **【要確認：V02】**未知 WAV・未知日への一般化や統計的な優位を主張する場合は，分割単位と開発への参照履歴を定めた独立評価が必要である．540 区間を独立した 540 実験と見なす推定や，seed の反復だけで未知条件への一般性を代替することはできない．

【要確認：V03】時間配置への依存差が水流雑音時の利得の原因である，または特定帯域が特定の物理音源であると強く結論する場合は，表現・学習器を統制した比較や独立観測を要する．本稿の限定した結論を記述するために，これらを一律の追加実験として要求しない．

本章の考察により，何が改善したかに対しては出力上の説明とモデル上の依存差を示せるが，物理的な確定には不足が残ることを明らかにした．この区別を保つことで，第 1 章の目的に対する到達点と未達を，結言で過不足なく述べることができる．

第 6 章

結言

6.1　本研究で得られた結論

本研究では，1.3節の目的に対し，水のプール沸騰音響からの全域熱流束推定と ONB 判定を二つの主要課題とし，モデル統合の改善条件と限界を検討した．2025 年 6 月 11 日・6 月 18 日の計 36 WAV を用い，各録音内の 45 学習区間・15 評価区間という条件で，無雑音学習から無付加雑音および 6 付加雑音条件への固定適用を比較した．以下は，既知 WAV 内の未使用 540 区間，1 秒，3 kHz 上限，固定基準水流音，seed 42 という評価範囲で，三つの問いへ回答するものである．

1. **問い1：元 3 MSE に対し，全 7 条件で全域熱流束推定誤差を低減した．** 5 モデル統合の全域 RMSE は，無雑音で 34.07 から 27.80 $\mathrm{kW/m^2}$，基準 SNR -20 dB で 81.14 から 75.23 $\mathrm{kW/m^2}$ となった．これは対象範囲の定量推定に関する主要成果である．一方，無雑音の元 3 ＋ ET や -20 dB の HGB 単体より常に良い結果ではなく，全 5 モデルの必要性や唯一の最適構成は示していない．

   雑音時の絶対性能の改善と，clean からの悪化量の縮小は異なる．無雑音から -20 dB への RMSE 増加量は元 3 MSE の 47.07 に対し 5 モデル 47.43 $\mathrm{kW/m^2}$ であり，全 6 付加雑音条件でも増加量は縮小しなかった．この結果は，対象雑音下の絶対誤差低減を支持する一方，元 3 MSE 比の劣化量抑制という仮説は支持しない．
2. **問い2：総見逃しを減らし誤報を維持したが，開始段階への利得は限定的であった．** 元 3 MSE に対して全 7 条件で総 FN が減り，FP は同数であった．無雑音の FN は 42 から 27，-20 dB では 65 から 52 へ減少し，FP はそれぞれ 1 と 0 であった．この総判定の利得は，全域推定の利得とともに主要成果となる．一方，近傍 RMSE は無雑音で改善し -20 dB では悪化した．記録上 ONB 段階の 30 区間では，無雑音 8 区間，-20 dB 0 区間の陽性にとどまった．日別 q_{100} も一律に前進せず，総見逃しの減少は開始段階の十分な検知を保証しなかった．
3. **問い3：利得の出力上の内訳，入力依存差，現制約での訂正限界を示した．** 保存予測の分解により，元 3・HGB・ET が同方向に外れた区間群が，-20 dB の全体 MSE 減少の 87.15% を占めた．誤差の小さい予測へ調整する効果も大きく，逆符号の相殺だけでは補完性を説明

できなかった．この割合は予測上の損失分解であり，物理音源の寄与率ではない．
共通の時間行並べ替えで CNN 系の誤差が増え，順序を集約する HGB/ET は不変となった．一方，追加 2 モデルは全域 gain や対象帯域の減衰に敏感であり，全ての入力変化に頑健ではなかった．入力依存差と統合の誤差変化は示せるが，水流雑音時の利得の因果割合や，利用帯域の音源は現在の結果だけから確定できない．
また，元 3 内部比率と下限を保持する現制約では，−20 dB の開始段階 30 区間は標本ごとに最も有利な配分でも陽性化できなかった．これにより，重み目的の変更だけでは解決できない範囲を特定した．別の入力・学習や制約変更の可能性まで否定するものではない．

以上により，対象条件での全域熱流束推定と総判定の改善を示し，その利得と開始境界での限界を，誤差，保持する入力情報および統合制約へ対応づけた．モデル数の増加だけでなく，基礎予測の誤り，統合の目的および配分制約を合わせて設計する必要がある．この知見が本研究の目的への回答である．雑音による劣化量の抑制，開始段階の高い検知率，未知条件への再現性，物理的な音源の確定には限界・未確認が残り，実際の気泡発生時刻や原子炉での局所異常検知・事故防止効果を実証したものではない．

6.2 今後の展望

最初に整える必要があるのは，データ取得者，原計測条件，熱流束ラベルと ONB の原実験上の根拠である．これらは新しいモデルを導入しても補えず，解析の再現性と研究上の立場を定めるための確認事項となる．文献については，音響回帰・状態判定の先行研究の本文と，手塚の最終修論における物理的考察を，自研究の原条件と照合して補う．

構成選択の根拠を補う比較として，調整済み CNN 系 3 モデルと現構成の同一標本上の比較が考えられる．また，全域 MSE と判定目的の交換を識別するには，基礎予測・制約・選択規則を固定し，統合の目的だけを変える限定比較が候補となる．この場合も，現制約では訂正できない開始段階を先に区別し，FN/FP・回帰誤差を併記する必要がある．外側評価を使った重みや閾値の選び直しは行わず，係数等の選択に必要な独立性を学習側で設計する．

未知日・未知録音への適用を主張する場合は，未参照の独立データと，実運用で利用可能な閾値・雑音基準を定めた評価が必要となる．また，秒単位の検知遅延には気泡発生時刻に対応する正解が，物理音源の確定には同期画像や条件変更による識別根拠が必要である．これらは本稿の限定した結論を拡張するための条件であり，現在の執筆を停止して全て実行するという意味ではない．不足を主張の強さと対応づけ，中心結論に必要な確認から進める．

謝辞

【要確認：F03】指導，データ提供，計測，解析への協力者の氏名と役割を本人が確認して記入する．データ取得者が未確認のため，謝辞の相手や協力内容を推測では記載しない．

参考文献

[1] C. Dunlap, H. Pandey, E. Weems and H. Hu, “Nonintrusive heat flux quantification using acoustic emissions during pool boiling,” *Applied Thermal Engineering*, Vol. 228, 120558, 2023. https://doi.org/10.1016/j.applthermaleng.2023.120558.（本稿で確認した範囲：出版社の要旨・Highlights・公開抜粋.）

[2] S. Barathula, S. K. Chaitanya and K. Srinivasan, “Evaluation of machine learning models in the classification of pool boiling regimes up to critical heat flux based on boiling acoustics,” *International Journal of Heat and Mass Transfer*, Vol. 201, 123623, 2023. https://doi.org/10.1016/j.ijheatmasstransfer.2022.123623.（本稿で確認した範囲：出版社の要旨・公開抜粋.）

[3] Y. Ueki, I. Hirako, K. Tezuka, K. Aizawa and K. Ara, “Acoustic detection of boiling states by deep convolutional neural networks: Visual explanation of identification basis,” *AI Thermal Fluids*, Vol. 4, 100021, 2025. https://doi.org/10.1016/j.aitf.2025.100021.（確認範囲：公開抄録・JAEA JOPSS の書誌，2026 年 10 月 23 日参照．対象データの取得者の根拠には用いない.）

[4] 植木祥高,「音響応用による炉心内冷却材沸騰の検知手法創出研究」，混相流，Vol. 40，No. 2，pp. 125–130, 2026. https://doi.org/10.3811/jjmf.2026.T010.（確認範囲：J-STAGE 書誌・公開抄録，2026 年 10 月 23 日参照．PDF 本文は未確認.）

[5] P.-H. Huang, J. H. Seong, J. M. Castro-Aguilar, C. Vermeulen and E. M. O’Brien, “A non-intrusive framework using acoustic signals and deep learning for boiling diagnostics in visual-limited environments,” *Scientific Reports*, Vol. 16, 14934, 2026. https://doi.org/10.1038/s41598-026-41757-z.（公開本文の Acoustic signal regression，Noise interference 等を確認，2026 年 10 月 23 日参照.）

[6] “Preliminary experiment of boiling detection in the reactor vessel by acoustic method,” PNC TN9410 91-175, May 1991. https://jopss.jaea.go.jp/search/servlet/search?4034056=&language=1.（確認範囲：JAEA JOPSS の公開抄録・書誌情報，2026 年 10 月 19 日参照．背景雑音による識別困難の記述を参照し，報告書本文の全条件は未確認.）

[7] 手塚晃輔,『サブクール沸騰の音響特性に関する実験的研究』，東京理科大学先進工学研究科電子システム工学専攻，令和 7 年度修士論文，2026 年 1 月．特に第 3 章，第 4 章，第 5 章を参照.

[8] M. Sundararajan, A. Taly and Q. Yan, “Axiomatic Attribution for Deep Networks,” *Proceedings of the 34th International Conference on Machine Learning*, PMLR 70, pp. 3319–3328, 2017. https://proceedings.mlr.press/v70/sundararajan17a.html.

[9] XGBoost developers, “Random Forests(TM) in XGBoost,” official documentation. https://xgboost.readthedocs.io/en/stable/tutorials/rf.html.（参照日：2026 年 10 月 19 日．実行時のパラメータは保存条件を使用.）

[10] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser and I. Polosukhin, “Attention Is All You Need,” *Advances in Neural Information Processing Systems*, Vol. 30, 2017. https://arxiv.org/abs/1706.03762.

[11] A. Krizhevsky, I. Sutskever and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” *Advances in Neural Information Processing Systems*, Vol. 25, 2012. https://proceedings.neurips.cc/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html.

[12] scikit-learn developers, “HistGradientBoostingRegressor,” official documentation. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingRegressor.html.（参照日：2026 年 10 月 19 日．公開文書の既定値を当該実行条件として流用していない.）

[13] P. Geurts, D. Ernst and L. Wehenkel, “Extremely randomized trees,” *Machine Learning*, Vol. 63, pp. 3–42, 2006. https://doi.org/10.1007/s10994-006-6226-1.

[14] G. C. Cawley and N. L. C. Talbot, “On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation,” *Journal of Machine Learning Research*, Vol. 11, pp. 2079–2107, 2010. https://www.jmlr.org/papers/v11/cawley10a.html.

[15] 手塚晃輔，植木祥高，相澤康介，荒邦章，「サブクール沸騰の音響特性に関する実験的研究」，混相流シンポジウム 2024，2024 年 9 月．JAEA JOPSS 収録の発表要旨，登録番号 BB20240594．https://jopss.jaea.go.jp/search/servlet/search?5081809=.（要旨の解釈と 2026 年最終修論の結論を区別して参照.）

[16] 研究用データ仕様，waterflow_20260817_1s，2026 年 8 月 17 日生成，9 月 3 日構造確認．configs/datasets/waterflow_20260817_1s.yaml および生成時のglobal_reference_manifest.json（未公刊の保存資料）.

[17] 研究用確認記録,「元 WAV validation・音響選別・ONB・アンサンブル・IG の追跡監査」, 2026 年 9 月 24 日, 第 2 節. experiments/2026-09-24_selection_onb_ig_review/README.md（未公刊）．採用数値の確認記録であり，原実験の ONB 観察記録は別途要確認.

[18] 研究用保存実行・評価記録, clean_only, 200 epochs, 2026 年 10 月 15 日, 実行 143609, run hash da540f2d, fit ID 7560205f8feb. 主表・条件・検算：experiments/2026-10-15_clean_only_result_analysis/．元実行と CSV の識別情報は本稿のdata/source_manifest.json に記載（未公刊）.

[19] 研究用保存予測分析，「保存結果による誤り補完と特徴利用の接続」，2026 年 10 月 14 日.

experiments/2026-10-14_error_feature_linkage/（未公刊）．主実行と同じ条件・seed での保存結果の分析であり，独立試験とは数えない．

[20] 研究用入力対照記録，共通入力加工，元 3 比率の自由化，入力特徴除去と固定重み対照，2026 年 10 月 7 日．experiments/2026-10-07_onb_input_and_integration/（未公刊）．

[21] 研究用保存予測診断，固定元 3 ブロックと配分下限の下での ONB 見逃しの到達上限，2026 年 10 月 21 日．experiments/2026-10-21_research_logic_audit/onb_failure_feasibility.csv および同フォルダの検算記録（未公刊）．基礎モデルの再学習を伴わない保存予測の事後診断．

[22] 2025 年 6 月 11 日・6 月 18 日の電気計測保存資料，各日の CSV，XLSX およびロガー CSV．統合データのsource_metadata/ と元の日別フォルダの同名 6 ファイルを照合．確認記録：docs/thesis/2026-10-23_manuscript_alignment_audit/source_metadata_trace.json，2026 年 10 月 23 日（未公刊）．取得者および ONB 原観察の確認とは区別する．

[23] 研究用解析実装，音響要約特徴，回帰モデルおよび固定元 3 ブロック統合．code/utils/dataloading/acoustic_summary_features.py, code/utils/models/regression/base_regression.py, code/utils/models/regression/acoustic_regression.py, code/utils/ensemble/fixed_core_stacking.py. 2026 年 10 月 19 日の参照版の SHA-256 を本稿のdata/source_manifest.json に保存．後日変更された 2 コードは，同じ hash の参照版をdata/source_snapshots/2026-10-19/ に保存し，現行コードと区別した．この保存版は草稿参照時点の版であり，実行時の全ソースの復元を意味しない．

付録 A

再現条件と補足事項

A.1　主比較の条件と根拠の対応

本稿は元の大容量音響データと学習済みモデルを複製せず，本文の図表を得た小さい評価表，保存予測への参照，出典 SHA-256 を保持する．研究用の再学習・推論と，本稿を PDF へ変換する処理は別である．草稿の再組版には GPU を必要としない．

表A.1: 主比較の再現に必要な保存条件.

条件	値・範囲
対象	2025 年 6 月 11 日・6 月 18 日，36 WAV，1 秒，3 kHz，選別なし
外側分割	各 WAV 内 45 学習・15 評価，1,620/540 区間，test fraction 0.25，split seed 42
内部検証	学習側 chunk 3-fold，seed 42，OOF 予測で重み fit
学習方針	clean_only，モデル・PCA・scaler・重みを全 7 条件へ固定
CNN 学習	200 epochs．CNN ＋ Transformer：lr 0.001，batch 12．AlexNet：lr 0.003，batch 8
RF	PCA 100 次元，XGBRF，木数 100，最大深さ 12，subsample 0.6，colsample_bynode 0.6
HGB	34 特徴，150 反復，lr 0.05，最大葉 31，最小葉標本 20，L2 1.0，early stopping なし
ET	34 特徴，256 本，最小葉標本 2，max_features 1.0，bootstrap なし
統合制約	元 3 内部比率固定，元 3 総量 25% 以上，追加各 5% 以上，clean OOF 全域 MSE

条件	値・範囲
雑音	共通基準 RMS 0.0004822199855309985，水流音 1 系列，基準 SNR 0 から −20 dB の 6 段階
閾値	日別 221.5051102 および 271.6776816 kW/m^2．近傍は各値の ±10%
保存単位	元予測 W/m^2，主表 kW/m^2．異なる単位の CSV を加算しない
出典	実行 143609，run hash `da540f2d`，fit `7560205f8feb`

本文の 3-MSE，3-perf，3 ＋ ET，5-model は，保存表の方式キーと一対一に対応する．`data/source_manifest.json` には元 CSV とコードの hash を，`data/` には本文に使った小さい保存表のコピーを置く．10 月 14 日の誤差分解，10 月 7 日の入力対照を含めて，異なる実行が独立反復であると数えない．

草稿の 10 月 19 日時点の参照コードと，後日の CNN 構成比較のために変更された現行コードは区別する．`base_regression.py` と`fixed_core_stacking.py` は，旧 manifest の SHA-256 に一致する参照版を`data/source_snapshots/2026-10-19/` へ保存した．検査はこの保存版へ照合し，元の期待 hash は変更しない．これは草稿が参照したコードの追跡性を保つ処置であり，10 月 15 日の全実行環境・ソースを新たに復元したという意味ではない．

> **【要確認：D06】**主実行の Python，TensorFlow，scikit-learn，XGBoost，CUDA 等の正確な版と実行環境を保存記録で確認し，固定した環境定義として追記する．本稿を組版した環境の版を，過去の学習時の環境として代用しない．

A.2　先行検討と現在の主条件の関係

以前の検討では，別日への適用，ピーク高さに基づく学習選別，帯域上限の比較，条件別雑音学習および統合方式の比較を行っている．これらは現在の主比較条件を選ぶ経緯として重要であるが，データ分割，学習条件，モデル構成が同一とは限らない．主系列へ数値を混ぜる前に条件を明記する必要がある．

表A.2: 過去の検討を本文の論理に置く場所．

検討	現在の位置づけ	本稿への反映
元 WAV 分離・別日	同一録音内評価と異なる一般化の問い	第 2・3 章で現在の分割の限界を明記．旧別日値を現行 5 の成績にしない

検討	現在の位置づけ	本稿への反映
2.1–2.5 kHz 選別	弱音の ONB 以上区間を除くことが近傍を悪化させ得る検討	現行は選別なし．静かな区間を誤ラベルとはしない
3/22 kHz 比較	周波数上限と学習条件で性能・誤りが変わる補助比較	3 kHz が物理的に唯一の有効帯域という結論は採らない
旧雑音生成診断	元音強度と付加音強度の情報経路の確認	第 3 章で固定基準を定義．修正と clean_only 採用を分ける
追加モデル・特徴	異なる表現・学習器による予測の比較	第 3 章の理由，第 4 章の性能，第 5 章の依存へ配置
固定ブロック上限診断	現予測と配分制約で訂正できる範囲	第 3 章で上限を定義し，第 5 章で開始段階の失敗を説明
説明性の数値確認	可視化が出力できる状態と，収束・解釈の妥当性の区別	中心根拠は共通入力対照と保存予測．未確認画像へ強い主張を依存させない

この整理は，過去の作業を再実行する指示ではない．完了している検算と対照は既存の証拠として利用し，現在の結論が必要とする不足だけを次の検討対象にする．

CNN 系 3 モデルによる構成比較は，主系列とは別の補強課題である．採用条件と外側評価がそろうまでは，学習側の探索値を第 4 章の外側性能へ混ぜない．同じ 3 モデル数の比較でも表現・容量・学習方式が同時に異なるため，構成全体の対照として位置づける．

A.3　IG を補助資料として扱う際の条件

回帰関数 F，入力 x，基準入力 x' に対し，IG は，

$$\mathrm{IG}_j(x;x') = (x_j - x'_j)\int_0^1 \frac{\partial F(x' + \alpha(x - x'))}{\partial x_j}\, d\alpha \tag{A.1}$$

で定義される [8]．モデル出力が熱流束である場合，説明対象はその出力差である．分類の正解クラスの寄与と同じ意味へ置き換えない．出力をスケール変換する場合は，寄与値の単位も確認する．

基準入力と積分近似の選択を明記し，寄与和と $F(x) - F(x')$ の差を確認する．異なるモデルで同じ色が付いても，基準出力やスケールが異なるため，色の濃さだけから重要度を直接比較しない．収束していても，物理的に実現しない積分経路や基準に依存した説明である可能性は残る．

【要確認：L03】 IG を主図へ追加する場合は，対象 run・学習済みモデル・入力 ID・基準・収束診断を揃え，入力対照との対応を記載する．現在の草稿は未照合の画像を主証拠にしないため，追加画像なしでも中心結論は記述できる．

A.4 実験装置の補足資料を追加する方針

原実験資料の確認後，装置の模式図，センサ位置，電気計測からの熱流束算出，測定の不確かさを補足できる．引用または転載の場合は，原資料の著者，図番号，対象条件と必要な利用条件を明記する．既存文献の装置図については，対象日の原記録との対応を確認する．本文の出典・ラベル・担当範囲は第 2 章に残し，付録への移動だけで出典確認を完了した扱いにはしない．

付録 B

未確認事項と完成に向けた確認順序

本付録は執筆用の不足一覧であり，提出稿では解消した項目を反映して整理する．全域熱流束推定と ONB 判定を二つの主要課題として，出典・記述の確認不足，既に観測された性能上の限界，強い主張に必要な追加証拠を分ける．例えば ONB 段階の検知不足は，数値をまだ集計していない空欄ではなく，現在の結果が示した到達限界である．全域推定と総判定の成果を記すとともに，開始段階の限界も結論へ残す．

B.1　出典・記述の完成に必要な事項

表B.1: 本文の要確認 ID と必要な根拠．

ID	不足	完了に必要な確認
D01	データ取得者・提供元	原実験ノートと WAV を対応づけ，実施者・提供元を確認する
D02	著者等の担当範囲	計測，ラベル算出，前処理，実装，実行，解析・考察の担当を分ける
D03	対象日の実験・収録条件	寸法，水温・圧力，センサ位置，ゲイン，校正を原資料で確認する
D04	熱流束ラベルの算出と誤差	CSV を原電気計測値へ遡り，面積，平均時間，不確かさを確認する
D05	ONB 判定の原根拠	使用値の確認記録に加え，原観察，判定基準，分解能を示す
D06	学習時の環境版	主実行に対応するソフトウェア版・ハードウェア記録を確定する

ID	不足	完了に必要な確認
L01	先行研究本文の確認	Ueki ら 2025・植木 2026 を含め，公開抄録までの資料の対象・分割・ONB 評価を本文で補う
L02	物理考察の照合	手塚最終修論と原実験条件を対応させ，音源候補の根拠を整理する
L03	IG を追加する場合の根拠	対象モデル・入力・基準・収束を揃える．現在の中心結論の必須図ではない
F01	題目・提出書式	所定要領に表紙，余白，肩書，年月，引用形式を照合する
F02	要旨・用語の最終校閲	指導後に和英要旨と用語，本文・図表との整合を確認する
F03	謝辞	氏名・協力内容を本人が確認して記入する

【要確認：F02】和英要旨は現在の限定した結論に合わせて作成した．正式題目と指導後の本文に合わせ，専門用語，英文および提出時の字数条件を最終確認する．

B.2　強い結論を採る場合にのみ必要な追加証拠

表B.2: 追加検証の必要性を主張の強さと対応づける．

ID	採りたい強い主張	必要となる識別根拠
V01	200 epochs が最良・学習十分	学習側の validation 曲線と事前に定めた epoch 選択
V02	未知録音・未知日でも優位	開発に未参照の独立データ，分割単位，固定した選択規則
V03	入力依存差が雑音利得の原因・帯域の物理同定	表現・学習器を統制した比較，原実験条件と独立観測の照合
V04	ONB 発生段階の十分な早期検知	許容 FN/FP と対象母集団を定めた評価．秒単位を言うなら発生時刻の正解も必要

【要確認：V04】現在の 30 区間の結果は開始段階の検知未達を示す．到達熱流束を実時間遅延や実機の安全余裕へ換算できる根拠はない．現在の限定した結論では未達として記述する．

B.3　本文を完成させるための順序

まず D01–D05 により，データと正解の根拠および研究上の立場を明確にする．次に L01–L02 を補い，目的と物理考察の文章を根拠へ対応づける．併せて，第 1 章の目的と第 6 章の結論を読み合わせ，全域回帰，雑音耐性，早期検知，説明性という語の強さが揃っていることを確認する．

その上で, 指導により必要とされる達成範囲を定め, 現在の限定した結論を維持するか, V01–V04 のどの主張を強めるかを判断する．追加実行を行う場合は，比較対象，必要な独立性，改善対象，終了条件を先に記録する．モデル探索を広げることや過去の完了確認を繰り返すことを，執筆の前提にはしない．

最後に，本文で使う図表・引用の対応，実験資料の出典，謝辞および提出様式を整える．本稿は全章の文章化を行った状態であり，データ出典等の未確認，ONB 検知上の未達，指導・提出要領による修正が残る．修論の合格基準や教授の了承を満たした完成稿という意味ではない．