CNN に基づく気液二相噴流のパッシブ音響識別に関する研究 (ノイズ耐性の評価と Grad-CAM による視覚的説明)

機械工学専攻 マイクロ熱工学領域 芝原研究室 三上奈生

1 緒言

気液二相流の流動状態は熱・物質輸送と強く関係し, 構造物の疲労・腐食などの潜在的な問題を引き起こす場合もある [1]. 例えば, ナトリウム冷却高速炉 (SFR) では蒸気発生器 (SG) 内の伝熱管に貫通き裂が生じると, 水/蒸気がナトリウム中にリークし, 気液二相噴流による伝熱管の損耗 (ウェステージ) が生じる恐れがある. ウェステージ現象は水リーク率によって大別され, 微小の水リーク率では管壁の自己損耗 (セルフウェステージ) や高温化による強度低下が生じ, 水リーク率が増大すると隣接する伝熱管の二次的な破損が生じる. そのため, 気液二相噴流の流動状態を高速かつ高精度で検知・識別する手法の開発が求められている.

この識別手法として, 本研究では畳み込みニューラルネットワーク (CNN) とパッシブ音響法に着目する. 音響法は応答性に優れており, SG 内部のような不可視領域にも適用可能である. また, CNN は既存手法 [2] よりもノイズ耐性に優れており, 実機のような高レベルノイズ環境での識別にも対応できる可能性がある. さらに, 近年 AI には説明責任が求められており, CNN に対する入力と予測に対して局所的な説明を与える勾配加重クラス活性化マッピング (Grad-CAM) [3] の導入が進んでいる. しかし, ノイズ環境下で気液二相噴流の音響識別を行った例や Grad-CAM を応用した例は少ない. 以上を踏まえ, 本研究では CNN に基づく気液二相噴流のパッシブ音響識別手法のノイズ耐性の評価, および Grad-CAM による予測根拠の可視化を行う.

2 実験および時間周波数表現の作成

まず, バックグラウンド音を模擬した水流動音, 異常音を模擬した気液二相噴流音の測定実験を行った. 前者では配管内部の水流動音を 60 s 間測定し, 後者では孔径 0.15, 0.17, 0.20 mm のノズルからの気液二相噴流音をそれぞれ 60 s 間測定した. 各実験の詳細な条件や音源の物理については筆者らの文献 [2, 4] に記載されている. 次に, 得られた音響データに対して, 先行研究 [5] と同様に短時間フーリエ変換 (STFT), 連続ウェーブレット変換 (CWT), シンクロスクイーズドウェーブレット変換 (SWT) を用いた時間周波数解析を行い, CNN に入力する時間周波数表現 (TFR) を作成した. 各 TFR は 0.1 s の時間間隔で作成され, 0 ∼ 22.05 kHz の周波数帯における信号強度分布を表し, CNN に入力される際は縦・横 224 ピクセル, RGB3 チャンネルの画像情報に変換される. また, ノイズ環境下を再現するために信号対ノイズ比 (SNR) を $0, -4, -8, -12, -16, -20$ dB と変化させた場合について TFR の作成を行った.

3 CNN および Grad-CAM の理論

本研究では, 大規模画像認識コンテスト (ILSVRC) で優秀な成績を収めた AlexNet, VGG16, ResNet18 を分類器として用い, セルフウェステージ現象を想定して水流動音 1 種 (Class W) および気液二相噴流音 3 種 (Class J0.15, Class J0.17, Class J0.20) の計 4 種の音を分類するように CNN を構築した. 各 SNR において, AlexNet, VGG16, ResNet18 の CNN3 種と STFT, CWT, SWT の TFR3 種を組み合わせた全 9 手法の性能評価を行った.

また, CNN の判断根拠を可視化する手法として Grad-CAM を導入した. Grad-CAM では, CNN が予測したクラスが c であるときの出力を y_c としたとき, 出力 y_c に対する要素数 Z の特徴マップ A^k の勾配の平均 α_c^k を次式により求める.

$$\alpha_c^k = \frac{1}{Z} \sum_i \sum_j \frac{\partial y_c}{\partial A_{ij}^k} \tag{1}$$

この勾配の平均 α_c^k が大きいほど, 特徴マップ A^k が出力 y_c により大きな影響を与えたと考えることができる. そして, 次式のように勾配の平均 α_c^k と特徴マップ A^k の積に ReLU 関数を施すことで, 出力 y_c に対する判断根拠をヒートマップとして表す Grad-CAM が得られる.

$$L_c^{\text{Grad-CAM}} = \text{ReLU}\left(\sum_k \alpha_c^k A^k \right) \tag{2}$$

Tab. 1 Accuracy of ResNet18 with best TFRs for SNR $= 0, -4, -8, -12, -16,$ and -20 dB.

SNR	0 dB	−4 dB	−8 dB	−12 dB	−16 dB	−20 dB
Best TFR	STFT	STFT	STFT	STFT	SWT	SWT
Accuracy	$98.80 \pm 1.63\%$	$97.50 \pm 2.66\%$	$94.70 \pm 4.83\%$	$92.35 \pm 5.47\%$	$86.55 \pm 5.62\%$	$69.15 \pm 9.11\%$

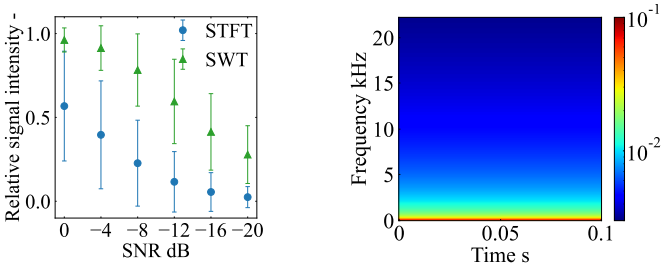


Fig. 1 Left: Maximum relative signal intensity of gas-liquid jet sounds of STFT and SWT; right: intensity distribution of scale parameter terms of SWT.

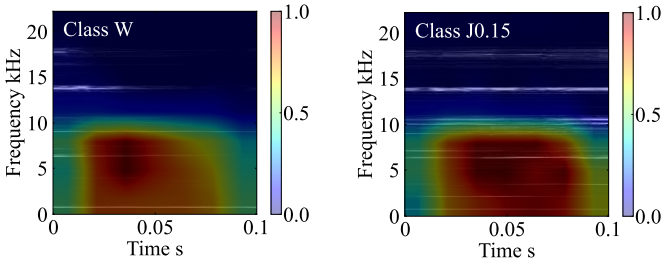


Fig. 2 Visual explanation of ResNet18 + STFT decision for SNR = −12 dB (left: Class W; right: Class J0.15).

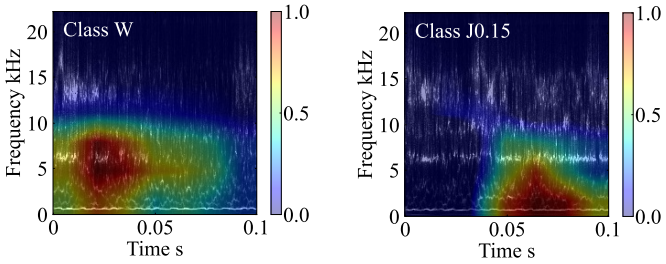


Fig. 3 Visual explanation of ResNet18 + SWT decision for SNR = −20 dB (left: Class W; right: Class J0.15).

4 結果と考察

4.1 ノイズ耐性の評価

Tab. 1 に全ての SNR で最良手法となった ResNet18 の精度を示す．SNR が小さいほど ResNet18 の精度は低下したが，これは SNR の減少に伴いノイズ強度が増大することを考えると妥当である．また，ノイズ強度が着目信号強度の 100 倍となる SNR = −20 dB の高レベルノイズ環境下においても，ResNet18 は 69.15% の精度を示した．この結果から，ノイズ環境下での気液二相噴流の識別において CNN の耐ノイズ性が機能していることが分かる．

また，Tab. 1 に示すように SNR = 0, −4, −8, −12 dB では STFT が最高精度に達した TFR となった．これは，元信号の周期性や STFT がもつ一定の時間・周波数解像度に起因すると考えられる．一方，SNR = −16, −20 dB では SWT が最高精度に達した TFR となった．これらの SNR では，支配的な水流動音に対する気液二相噴流音の信号強度が強く表れていることが重要であると考えられる．そこで，気液二相噴流音と水流動音の信号強度の差を気液二相噴流音の相対信号強度と定義し，気液二相噴流音の特徴周波数帯である約 1500 ∼ 5000 Hz における相対信号強度の最大値を計算した．その結果が Fig. 1 の左図であり，SWT は STFT よりも大きな値を示しており，特に SNR = −20 dB では約 10 倍の差となった．このことから，SWT は STFT よりも気液二相噴流音の信号強度を強く表していることが分かる．これは Fig. 1 の右図のように，本研究における SWT のスケール変数項の強度が周波数の減少に伴い増大することに起因する．

4.2 Grad-CAM による視覚的説明

代表例として，SNR = −12 dB における ResNet18 + STFT の Grad-CAM を Fig. 2，SNR = −20 dB における ResNet18 + SWT の Grad-CAM を Fig. 3 に示す．これらの図から，Grad-CAM は水流動音に対しては約 6000 Hz 付近，気液二相噴流音に対しては約 5000 Hz 以下で大きな値を示していることが分かる．このことから，ResNet18 は水流動音がもつ約 6000 Hz のピークに基づいて水流動音を識別し，気液二相噴流音の特徴周波数帯を含む約 5000 Hz 以下の信号強度に基づいて気液二相噴流音の識別および分類を行っていると考えられる．

5 結言

本研究では，CNN に基づくパッシブ音響識別法のノイズ耐性の評価および Grad-CAM による視覚的説明を行った．ノイズ耐性の評価では，ResNet18 の効率的な学習と耐ノイズ性が確認でき，STFT と SWT が高い性能を示すことが分かった．また，Grad-CAM による視覚的説明では，ResNet18 が水流動音と気液二相噴流音の特徴的な信号強度に注目していることが分かった．これらの結果は，SFR の安全性向上および説明可能な異常検知・事故進展分析に繋がる．一方，SNR = −16, −20 dB のような高レベルノイズ環境下での識別精度には改善の余地があるため，より層の深い CNN の導入やオートエンコーダによるノイズ除去を今後行う予定である．

参考文献

[1] T. Yao *et al.*, Exp. Therm. and Fluid Sci., 102 (2019), 189–204.
[2] N. Mikami *et al.*, Int. J. of Multiph. Flow, 159 (2023), 104340.
[3] R. R. Selvaraju *et al.*, ICCV2017 (2017), 618–626.
[4] N. Mikami *et al.*, J. Sound Vib., 561 (2023), 117797.
[5] L. Zhang *et al.*, AIChE J., 67 (2021), e17200.