

CNNアンサンブル学習に基づく音響 識別によるプール沸騰の発生検知

2026年1月7日

植木研究室 柴崎陸

Agenda

01 研究背景・目的

02 概要

- 実験
- CNNモデルとアンサンブル学習

04 結果

- アンサンブル学習による精度・ノイズ耐性評価
- 100% 分類性能の予測

05 修士論文に向けて

Agenda

01 研究背景・目的

02 概要

- 実験
- CNNモデルとアンサンブル学習

04 結果

- アンサンブル学習による精度・ノイズ耐性評価
- 100% 分類性能の予測

05 修士論文に向けて

研究背景

背景 – エネルギーセキュリティの重要性

- ロシアによるウクライナ侵攻の影響等による「**エネルギー資源の安定供給**」に対する懸念の増大 [1]
- 重要な電力エネルギーの供給源として「**原子力発電**」が位置付けられる [2]
- 中でも最も実用化に近い炉系

➡ **ナトリウム冷却高速炉(SFR)**：高効率・カーボンフリー・安定電源・構造材との共存性の高さ（右下図1）

ナトリウム冷却高速炉の課題

- 水と激しく反応する
- 不透明であるため工学的な手段での検査ができない
- 構造材料の腐食リスク
- 1966年のフェルミ炉事故における**炉心溶融**事故 [2]
 - 炉心溶融：過剰沸騰による内部壁の破損

➡ 沸騰現象の**早期検知**




図1. ナトリウム冷却高速炉

[1]佐藤 純一. カーボンニュートラルに向けた水素の役割と社会実装に向けた取り組み. 電気学会誌, 144(8):520–523, 2024.

[2]上出 英樹, 伊藤 隆哉, and 小竹 庄司. 第4世代原子炉の開発動向. 日本原子力学会誌ATOMO Σ, 60(9):562–566, 2018.

先行研究・目的

【先行研究】

- AI（機械学習）による沸騰・未沸騰の分類[3]
- 機械学習モデルの学習・予測根拠の可視化[3]
- 沸騰段階の，機械学習モデルを利用した高精度での予測検知[4]

【課題】

- 実機環境を想定したノイズ耐性の評価・精度向上
- 分類時のラベル付けに分類精度が依存する
- 単一モデルを用いた識別手法



目的

- 実機環境を想定したノイズ耐性の評価
- 「アンサンブル学習」による機械学習予測の安定性と精度の向上
- ラベル付与に依らない沸騰発生を検知する手法の構築

[3]平子樹, “深層学習に基づく音響識別によるプール沸騰の状態検出及び予測根拠の可視化に関する研究”, 2023年

[4] Christy Dunlap, Changgen Li, Hari Pandey, Ying Sun, and Han Hu. A temporal-spatial framework for efficient heat flux monitoring of transient boiling. IEEE Transactions on Instrumentation and Measurement, Vol. 73, pp. 1–12, 2024.

Agenda

01 研究背景・目的

02 概要

- 実験
- CNNモデルとアンサンブル学習

04 結果

- アンサンブル学習による精度・ノイズ耐性評価
- 100% 分類性能の予測

05 修士論文に向けて

実験概要

実験による沸騰・未沸騰音響データの取得

- 本研究は，SFRに機械学習を活用するための**基礎研究**

- ➡
- 実際のSFRで取得した音響データを使用 ×
 - ナトリウムで実験して音響データを取得 ×

超純水と白金細線を使用した
実験にて音響データを取得

※再現性を確保するため同一条件で
実験を**3回**実施




図2. 実験の概要図


機械学習モデル概要

深層学習モデルのアーキテクチャ

各モデルに対し，**実験で得たデータ**とそのデータの**沸騰段階の値（熱流束）**をペアとし，データを入力して熱流束を出力するように学習させる

AlexNet

層が浅いモデル




VGG-16

畳み込み層(13層)
全結合層(3層)



ResNet50

残差接続を用いて
勾配消失問題を解消



Input: 実験で得た
音響データ
Output: 沸騰段階
の数値

アンサンブル学習

上記3モデルの出力結果を重
み付き平均

AlexNet Output
VGG16 Output
ResNet50 Output

Weighted
Average

Final Output

Agenda

01 研究背景・目的

02 概要

- 実験
- CNNモデルとアンサンブル学習

04 **結果**

- アンサンブル学習による精度・ノイズ耐性評価
- 100% 分類性能の予測

05 修士論文に向けて

結果 – アンサンブル学習とノイズ耐性評価

2つの評価指標による各モデルの結果




図3. 各モデルに対するノイズごとの決定係数の比較




図4. 各モデルに対するノイズごとのAUCの比較

- 両指標について、アンサンブル学習の結果（濃青）が**高い精度**
- ノイズが増大しても、アンサンブル学習の結果は**減衰率が低い**

結果 - 100% 分類性能の熱流束予測


沸騰開始点を100% 検知できる値の特定

- モデルの予測値の中で、「以降の事象全ての予測が沸騰となる点（**検知下限**）を求める
- 沸騰の**開始点**と**限界点**の間に着目し，**検知下限の相対位置**を%で表す

結果

表1. 相対位置の計算結果

SNR	予測平均値 MW m^{-2}	相対位置 %
no_noise	0.3663	4.040
0	0.3386	2.523
-4	0.3429	2.763
-8	0.3675	4.113
-12	0.3932	5.522
-16	0.4266	7.358
-20	0.4078	6.318



- ノイズ環境下でも早期段階(限界の10% 未満)での検知が可能



- **限界点までの余裕が90% 以上**ある

Agenda

01 研究背景・目的

02 概要

- 実験
- CNNモデルとアンサンブル学習

04 結果

- アンサンブル学習による精度・ノイズ耐性評価
- 100% 分類性能の予測

05 修士論文に向けて

修士論文に向けて

1. より広範な実験条件下での性能検証

- 白金細線の形状パラメータ，溶存ガスの影響など

2. 100% 分類性能の向上

- ハイパーパラメータの最適化
- 最新モデル（EfficientNet・Transformer）の導入

3. アンサンブル学習の最適化

- 重み付け方法の最適化(決定係数以外の誤差率の計算)
- 深層学習以外のモダンな機械学習モデルと組み合わせた適応能力の向上

ご静聴ありがとうございました