
論文輪講

Anomalous Sound Event Detection Based on WaveNet

—WaveNetに基づく異常音イベント検出—

2025年4月4日

植木研究室

8125517

柴崎陸

Agenda

- 01 論文を選んだ理由
- 02 研究背景・目的
- 03 手法
- 04 結果・結論

Agenda

01 論文を選んだ理由

02 研究背景・目的

03 手法

04 結果・結論

論文を選んだ理由

自分の研究との関連性

- 自分：CNNアンサンブル学習による沸騰音の発生検知
- 発表論文：WaveNetによる公共空間における異常音検出



音響信号を通じた
異常検出

研究的・技術的に優れている

- 従来の特徴量に依存しない
- WaveNetによる高精度を達成

自分の研究への活用可能性

- WaveNetで時系列信号から直接異常を予測
- 教師なし学習の枠組みで異常検知

Agenda

01 論文を選んだ理由

02 研究背景・目的

03 手法

04 結果・結論

研究背景・目的

背景

- テロ対策，公共の安全確保
ex) カメラでは視野に限界
 - 従来の教師なし学習手法の限界
 - 多くの手法は**特徴量**ベース
 - 時間領域の波形を**直接**扱う手法は少なかった
 - 音響信号は非定常で高次元
- 死角のない音響監視の重要性
- 直接モデリングが難しい

目的

- WaveNetを用いて音の波形を直接モデリングし，異常音を検出
 - WaveNetを予測器として用い，以下を異常とする
 - 大きな予測誤差
 - 高エントロピーな出力
- 提案手法の有意性を明らかに

Agenda

- 01 論文を選んだ理由
- 02 研究背景・目的
- 03 **手法**
- 04 結果・結論

手法

システム概要




Fig. 1: System overview.

トレーニングフェーズ

- 特徴量抽出
 - 25ms刻みで分割（オーバーラップ率4%）
 - 40次元のログメルフィルタバンク
- 統計量の計算
 - Global normalization
- μ -law圧縮して1-hotベクトル化
 - μ -law圧縮：音声信号の振幅を対数スケールに変換．少ないビットで音の細かい違いを表現し，分類モデルとして学習させる

➡ 補助特徴量 + 波形を入力として
WaveNet学習

手法

WaveNetの構造

- WaveNet：音声波形を1サンプルずつ時系列予測することで音をモデル化する
深層畳み込みニューラルネットワーク




Fig. 1: System overview.


$$p(\mathbf{x}|\mathbf{h}) = \prod_{n=1}^N p(x_n|x_1, x_2, \dots, x_{n-1}, \mathbf{h}).$$

- 音声波形全体の生成確率は、過去の波形と補助特徴量に基づいて逐次的にモデル化

全体構造

- 音声波形を量子化
- 256次元のone-hotベクトル化（入力）
- Residual block × N層
- Softmax出力

➡ 次に出力される音声サンプルがどの値になるかの確率分布（256クラス）



手法

Residual Block (残差ブロック) の構造





Fig. 1: System overview.

1. Dilated Causal Convolution

- 通常の畳み込みに「間引き (dilation)」を追加したもの
- 有限長の受容野 R
- Causal: 時間的に前向きのみ見る

$$\text{WaveNet}(\mathbf{x}, \mathbf{h}) \simeq p(x_n | x_{n-R-1}, x_{n-R}, \dots, x_{n-1}, \mathbf{h}),$$

2. ゲート付き活性化関数

- $\tanh$ 出力 $\times$ sigmoid 出力

$$\mathbf{z} = \tanh(W_{f,k} * \mathbf{x} + V_{f,k} * f(\mathbf{h})) \odot \sigma(W_{g,k} * \mathbf{x} + V_{g,k} * f(\mathbf{h})),$$

W : DCC
 V : 1×1 conv

3. 学習時の損失関数

$$E(\Theta) = - \sum_{t=1}^T \sum_{c=1}^C y_{t,c} \log \hat{y}_{t,c}$$

$y_{t,c}$: 正解 (1-hot)
 $\hat{y}_{t,c}$: WaveNetの出力確率 (softmax)
クラス数 $C = 256$ (8bit量子化)

手法

システム概要




Fig. 1: System overview.

テストフェーズ

- 特徴量抽出＋統計量の計算
 - 学習時と同じ平均，標準偏差
- 予測処理
 - 次のサンプルの確率分布を出力
- ポステリオグラムの取得
 - 各時刻における出力分布（256クラスのSoftmax結果）を連続的に全て並べたもの



時系列の予測確信度

手法

システム概要




Fig. 1: System overview.

テストフェーズ

スコアリング

- ポステリオグラムからエントロピー（不確かさ）計算

$$e_t = - \sum_{c=1}^C \hat{y}_{t,c} \log_2 \hat{y}_{t,c}$$

- 正常音→シャープな分布→エントロピー小
- 異常音→フラットな分布→**エントロピー大**（≡異常）

異常とみなすかどうかの判断（閾値）

$$\text{しきい値} = \mu + \beta \cdot \sigma$$

μ : 訓練データの平均エントロピー
 β : 標準偏差
 σ : 調整パラメータ

手法

テストフェーズ


● 後処理

- エントロピーベースの異常検知
➡ 誤検出やノイズが残る可能性

- 一瞬だけ異常が立つ ➡ ギャップ補間

- 本来1つの異常イベントだが途中が正常と判断され2つに分離 ➡ 中央値フィルタ


- 本来は異常ではないが一瞬正常と判断する短時間誤検出 ➡ 短時間イベントの削除



(a) Application of median filter



(b) Filling gaps



手法

データセット

- 地下鉄駅構内で2週間連続で録音した実環境音声
 - 録音データを30秒単位のセグメントに分割して管理
 - 異常音の合成
 - ガラスの割れる音
 - 悲鳴
 - 唸り声
- 「Sound Ideas Series 6000」 ➡
- SNRを0, 10, 20dBに設定

評価指標

- F1スコア ➡ ➤ Precision（適合率）とRecall（再現率）の調和平均
- イベントベース評価（EB） ➡ ➤ 異常音の発生タイミングが正しく検出されたか
- セグメントベース評価（SB） ➡ ➤ 音声を固定長の区間に分け，その区間内で異常があったか

手法

比較対象のモデル

- Auto Encoder (AE) → 入力=出力となるように再構成学習→再構成誤差が大きければ異常
- Auto-regressive LSTM (AR-LSTM) → 過去の系列から次フレームを予測→予測誤差が異常指標
- Bidirectional LSTM Auto Encoder (BLSTM-AE) → 入力を前後から同時に処理→より文脈に強い再構成型AE

モデルの共通仕様

- 3層構成（各256ユニット）
- 入力は40次元のログメルフィルタバンク
- 最適化手法：Adam
- 実装環境：Keras+TensorFlow

Agenda

- 01 論文を選んだ理由
- 02 研究背景・目的
- 03 手法
- 04 **結果・結論**

結果・結論

結果


TABLE I: *Experimental results.*

Method	EB F1-score [%]	SB F1-score [%]
AE	65.8	68.2
AR-LSTM	61.5	64.3
BLSTM-AE	69.2	67.7
WaveNet	75.0	77.8

- 実際の公共空間で**高精度**の検出に成功
- 従来手法と比較して，**全ての評価指標**で上回った
- 雑音や多様な環境音の中でも安定した性能を示し，**実用性の高さ**を実証

結果・結論

結果



- スペクトログラムとWaveNetによる異常音（ガラスの割れた音）の検出比較

- スペクトログラム
 - 足音とガラスの割れた音の差が見えにくい
- エントロピー
 - オレンジ直線：閾値
 - ガラスの割れた音が「予測できない＝未知の音」なので高くなった



異常の最終予測ではガラスが割れたタイミングのみ反応

スペクトログラムでは見えにくい
異常音も高精度で検出できる

結果・結論

結論

- WaveNetを用いた「波形ベース」の異常音検出は、**特徴量ベースの限界を超える革新的な手法**
- 音を直接扱うことで、**より繊細で確実な異常検出が可能になった**
- 今後の研究や実用化に向けて、**柔軟なしきい値設定や応用範囲の拡大が期待される**