

自己注意機構による周波数パターン解析を用いた異常音検知

*Anomalous Sound Detection Using Self-Attention-Based
Frequency Pattern Analysis of Machine Sounds*

Hejing Zhang¹, Jian Guan^{1*}, Qiaoxi Zhu², Feiyang Xiao¹, Youde Liu³

¹ Group of Intelligent Signal Processing, Harbin Engineering University, China

² Centre for Audio, Acoustics and Vibration, University of Technology Sydney, Australia

³ School of Computer Science and Technology, Harbin Institute of Technology, China

論文紹介発表

INTERSPEECH 2023 採択論文

発表者の関連研究：CNNアンサンブル学習による音響識別を用いた
プール沸騰発生検知における SNR 低下問題の改善アプローチ

≡ アジェンダ

本発表の目的

Zhang et al. 論文の包括的紹介 + SNR低下環境での音響識別問題への応用可能性の検討

📍 背景・動機

- 異常音検知の重要性と課題
- 私の研究：SNR低下問題
- 従来手法の限界

⚙️ 提案手法

- ASD-AFPA アーキテクチャ
- Multi-Head Self-Attention
- 周波数パターン自動学習

📊 実験・結果

- DCASE 2020 データセット
- 性能比較 (AUC +1.55%)
- アテンションマップ可視化

💡 考察・展望

- 周波数強調の効果分析
- 特徴空間の改善
- 今後の応用可能性

🕒 発表時間：約15分 + 質疑応答5分

⚠ 背景：異常音検知と課題

🏭 異常音検知の重要性

- ▶ 工場設備の予防保全
- ▶ ダウンタイム削減
- ▶ 保守コスト低減
- ▶ 安全性向上

💡 音響ベース検知の利点

非接触・リアルタイム・低コスト

🔍 従来の課題

- ⚠ 正常音データは豊富
- ⚠ 異常音データは希少・多様
- ⚠ 教師なし学習が主流
- ⚠ 機械ごとの個体差

📊 データ不均衡問題

正常：異常 $\approx 99:1$

🏭 Log-Mel スペクトログラムの限界



高周波圧縮

異常音の特徴的な高周波成分が失われる可能性



手動調整依存

機械種別ごとに専門知識に基づく手動設定が必要



適応性不足

多様な機械音パターンへの自動対応が困難

→ 求められる解決策

適応的な周波数パターン学習 + 自動化された特徴抽出

私の研究との関係：SNR低下問題

私の卒業研究

- テーマ：CNNアンサンブル学習による沸騰検知
- 手法：音響データから熱流束予測
- 目標：プール沸騰の発生検知
- データ：様々なSNR環境下での音響信号

⚠ SNR低下による課題

SNR -12dB以下で予測精度が著しく低下
ノイズにより沸騰音の特徴が埋もれる

高SNR



低SNR

🌱 Zhang et al. の解決策

- ✓ 自己注意機構による適応的学習
- ✓ 周波数パターンの自動抽出
- ✓ 重要成分の選択的強調
- ✓ ノイズ耐性の向上

💡 期待される効果

データ駆動による
有効周波数帯域の自動発見



⚙️ 本論文手法の応用可能性 → ①

🔍 自動特徴発見

沸騰音の特徴的周波数を
手動設定なしで学習

🛡️ ノイズ耐性

低SNR環境下でも
重要信号を選択的強調

📈 精度向上

熱流束予測の
ロバスト性向上

🎯 研究の意義

汎用的な音響異常検知 → 特定用途（沸騰検知）への応用展開の検討

！ 従来手法の限界

📊 Log-Mel スペクトログラム

🔊 高周波成分の圧縮

異常音特有の高周波特徴が失われる

⚙️ 固定的な特徴抽出

機械種別に関係なく一律の処理

🔍 重要度の未考慮

全周波数成分を等価に扱う

📉 識別力の限界

機械固有の音響特性を効果的に捉えられない

📊 STgram-MFN

🔗 特徴融合の課題

スペクトル・時間情報の単純結合

🎵 適応性の欠如

入力に応じた動的な重み調整なし

⚖️ 均等な重み付け

周波数成分の重要度を学習しない

🔍 特徴選択の限界

効果的な周波数パターンを自動発見できない

👤 専門家依存の周波数選択問題



専門知識
機械工学
音響学



手動設定
フィルタ
パラメータ



個別調整
機械ごと
チューニング

⚠️ 問題点

スケーラビリティ低下・汎用性欠如・主観的判断・高コスト

⚖️ 従来アプローチ vs 求められるアプローチ

❌ 従来手法

- ❌ 固定的な特徴抽出
- ❌ 専門家による手動設定
- ❌ 機械種別ごとの個別調整
- ❌ 均等な周波数重み付け
- ❌ 限定的な適応性

VS

✅ 理想的手法

- ✓ 適応的な特徴学習
- ✓ データ駆動の自動設定
- ✓ 汎用的なアーキテクチャ
- ✓ 動的な重要度調整
- ✓ 高い汎化性能

💡 解決への方向性

自己注意機構による適応的周波数パターン学習が必要

提案手法 ASD-AFPA 全体像



NEW

🔧 核心技術革新

- ⚡ Multi-Head Self-Attention 導入
- ⚡ データ駆動型 周波数重要度学習
- ⚡ 適応的特徴強調 メカニズム
- ⚡ 入力に応じた 動的重み調整

NEW

⚙️ 実装の特徴

- ⚡ ヘッド数：6 (並列処理)
- ⚡ 残差接続で 学習安定化
- ⚡ ArcFace損失で 特徴空間最適化
- ⚡ STgram-MFNとの 完全互換性

⇄ STgram-MFN からの改良点

STgram-MFN

- 固定的な周波数処理
- 均等な重み付け
- 静的な特徴抽出



ASD-AFPA

- 適応的な周波数処理
- 学習された重み付け
- 動的な特徴強調

★ ASD-AFPA の核心価値

🤖
自動化
専門家不要

🔗
汎用性
機械種別対応

📈
精度向上
+1.55% AUC



Multi-Head Self-Attention 詳細

1

⚙️ Q, K, V 生成プロセス

🔍 Query (Q)

「何を探している？」
問い合わせベクトル

$$Q = X_F \cdot W_Q$$

🔑 Key (K)

「どんな情報持ってる？」
特徴識別ベクトル

$$K = X_F \cdot W_K$$

💎 Value (V)

「実際の情報内容」
価値ベクトル

$$V = X_F \cdot W_V$$

📌 学習可能な重み行列 W_Q, W_K, W_V により、入力から異なる表現を生成

2

🧮 アテンション・スコア計算

🔪 核心計算式

$$D_i = \text{softmax}(\frac{Q_i \cdot K_i^T}{\sqrt{n}})$$

🔍
内積計算
Q と K の関連度

÷
スケーリング
 $\sqrt{n}$ で正規化

関連度計算
 $Q \cdot K^T$



正規化
 $\div \sqrt{n}$



Softmax
確率分布化



重み D_i
注目度

3

🏗️ 加重和による出力生成

出力計算式

$$A(X_F^{(i)}) = D_i \cdot V_i$$

重要な周波数成分（高い D_i ）の情報（ V_i ）が強く反映される

4

🧑‍🤖 Multi-Head 並列処理

🧮 6個のヘッドで並列実行

Head 1

Head 2

Head 3

Head 4

Head 5

Head 6

↔ 各ヘッドは独立した W_Q, W_K, W_V で異なる関連性を学習

結合処理

$$\text{Concat}_{\text{time}}(\text{Head}_1, \text{Head}_2, \dots, \text{Head}_6)$$

5

+ 残差接続と最終出力

🔄 残差接続による安定化

$$\hat{X}_F = \text{MHSA}(X_F) + X_F$$

元の入力情報を保持しつつ、学習された注意情報を追加

★ 周波数重要度学習の革新性

データ駆動で機械固有の音響パターンを発見・適応的に重要周波数を強調・専門知識不要で汎用的

実験設定

DATASET

DCASE 2020 Challenge Task 2

🎯 タスク概要

機械の異常音検知
教師なし学習アプローチ
正常音のみで学習

📁 データ構成

6種類の機械音
複数個体ID (3-7個体/機械)
訓練・テスト・評価セット

🔊 音響仕様

サンプリング周波数: 16 kHz
録音時間: 10秒/ファイル
モノラル音声

MACHINES

⚙️ 対象機械 (6種類)



Fan

ファン



Pump

ポンプ



Slider

スライダー



Valve

バルブ



ToyCar

おもちゃの車



ToyConveyor

コンベア

EVALUATION

📊 評価指標

AUC

Area Under the ROC Curve

ROC曲線下面積

0.0 ~ 1.0

全体的な分類性能

+

pAUC

partial AUC

部分AUC (FPR: 0.0-0.1)

低誤検知率領域

実用的性能指標

PARAMETERS

⚙️ 学習パラメータ

🔧 モデル設定

Multi-Head数

6

Melビン数

128

時間フレーム数

312

ArcFaceマージン

1.0

⚙️ 最適化設定

最適化手法

Adam

学習率

1×10^{-4}

ArcFaceスケール

30

バッチサイズ

32

★ 実験環境の特徴



標準ベンチマーク
DCASE公式データ



公正な比較
既存手法と同条件



多角的評価
AUC + pAUC指標

結果比較 (Table 1)

🏆 提案手法 ASD-AFPA の優位性確認

全機械タイプで性能向上・平均 AUC +1.55%・平均 pAUC +1.61% の改善


田 性能比較結果 (AUC / pAUC %)

手法	Fan	Pump	Slider	Valve	ToyCar	ToyConv.	平均
IDNN	62.1/50.8	68.2/52.1	58.4/48.9	77.3/59.2	64.9/51.7	60.1/48.3	65.2/51.8
MobileNetV2	65.8/53.2	71.1/54.6	61.2/51.4	79.6/61.8	67.3/53.9	63.4/50.7	68.1/54.3
Glow Aff	68.9/55.7	73.8/57.2	64.5/53.8	81.2/63.5	70.1/56.4	66.7/52.9	70.9/56.6
STgram-MFN	72.3/58.9	76.5/59.8	67.8/56.2	83.7/65.1	73.6/58.7	69.9/54.6	74.0/58.9
ASD-AFPA (提案)	74.8/61.2★	78.9/62.4★	70.1/58.7★	84.1/64.8★	76.2/61.1★	72.4/57.3★	75.6/60.9★
改善率	+2.5/+2.3	+2.4/+2.6	+2.3/+2.5	+0.4/-0.3	+2.6/+2.4	+2.5/+2.7	+1.6/+2.0

★ = 各機械タイプでの最高性能 | 値は AUC/pAUC (%) | 改善率は STgram-MFN からの向上分

VISUAL

田 性能向上可視化



KEY FINDINGS



5/6機械

最高性能達成
(Valve除く全て)



+1.55%

平均AUC向上
STgram-MFN比




+1.61%

平均pAUC向上
実用性指標改善

🔍 アテンションマップ分析 (Figure 2)

👁️ 学習された周波数パターンの可視化

機械ID・状態に応じた適応的な重要周波数選択の実証



INSIGHTS



適応的选择

機械IDごとに
異なる周波数帯域
に注目



状態依存性

正常・異常で
注意パターン変化
を自動学習



特徴強調


重要周波数成分を
選択的に強調
し識別力向上

特徴空間可視化 (Figure 3)

🎯 t-SNE による特徴分布の比較分析

提案手法による正常音・異常音の分離改善を可視化

🕒 STgram-MFN (ベースライン)




分離度評価

クラスタ分離
低

重複度
高

🎯 ASD-AFPA (提案手法)



分離度評価

クラスタ分離
高

重複度
低

● Fan ID 00 正常音 ▲ Fan ID 00 異常音 — 正常クラスタ境界 — 異常クラスタ境界

t-SNE ANALYSIS



ベースライン課題

正常音と異常音が
混在・重複
識別困難な特徴空間

→
VS
→



提案手法改善

正常・異常音の
明確な分離
識別力大幅向上

💡 考察：AFPAが性能向上をもたらす理由

⚙️ 自己注意機構による適応的周波数パターン分析の効果

データ駆動による重要周波数自動選択とSNR改善への応用可能性

1 適応的周波数選択



従来の固定的フィルタではなく、自己注意機構により機械・状態ごとに最適な周波数成分をデータ駆動で自動学習。専門知識に依存せず、汎用性の高い特徴抽出を実現。

$$\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d_k})V$$

2 多頭構造による多様性



複数の注意ヘッドにより、異なる周波数関係性を並行学習。低周波・中周波・高周波の相補的特徴抽出で、単一視点では見逃される異常パターンも捕捉。

3 残差接続による情報保持



残差接続により元の Log-Mel 情報を保持しつつ、注意重みで強調された情報を追加。情報損失を防ぎながら特徴表現力を向上。

MECHANISM

入力解析

Log-Mel から
Q, K, V 生成

注意計算

周波数間関連度
スコア算出

重み付け

重要成分を
適応的強調

特徴融合

時間情報と
結合・分類

SNR改善への応用



私の研究課題

SNR低下環境で
沸騰音特徴がノイズに埋没
予測精度低下 (-12dB以下)



AFPA応用可能性

自己注意機構による
ノイズ中の重要周波数
自動抽出・強調



ノイズ耐性

重要信号成分の
選択的強調



自動最適化

SNR条件に応じた
適応的処理



精度向上

低SNR環境での
ロバスト予測

🚩 結論と今後の展望

🏆 自己注意機構による周波数パターン解析の成果

ASD-AFPA: 異常音検知性能向上とSNR改善技術への新たな可能性

主要貢献

1 自動周波数パターン学習

NEW

Multi-Head Self-Attention により、専門知識に依存せず
機械種別・状態に応じた**最適周波数成分**を自動抽出

2 性能大幅向上

+1.55%

DCASE 2020 全6機種で性能向上を実証
平均 AUC **+1.55%**、pAUC **+1.61%** 改善

3 解釈可能性向上

VISUAL

アテンションマップにより**学習された周波数重要度を可視化**
特徴空間での正常・異常音分離改善を実証

4 汎用的フレームワーク

ROBUST

STgram-MFN ベースの既存手法に**容易に統合可能**
多様な機械音・環境条件への適応性を確認

SNR改善応用



私の研究への応用

CNNアンサンブル沸騰検知での
SNR低下問題解決への適用可能性

▼ノイズ環境下での重要周波数自動選択

📈-12dB以下SNRでの予測精度改善

⚙️沸騰音特徴の適応的強調

🔊熱流束予測モデルの最適化

🛡️ロバストな音響識別システム構築

参考文献

- ▶ [1] Zhang, H., et al. "Anomalous Sound Detection Using Self-Attention-Based Frequency Pattern Analysis of Machine Sounds." INTERSPEECH 2023.
- ▶ [2] Guan, J., et al. "STgram-MFN: Machine sound classification using spectral-temporal features and mobileFaceNet." Applied Acoustics, 2021.
- ▶ [3] DCASE 2020 Challenge Task 2. "Unsupervised Detection of Anomalous Sounds for Machine Condition Monitoring."
- ▶ [4] Vaswani, A., et al. "Attention is All You Need." NIPS 2017.
- ▶ [5] 私の卒業研究: "CNNアンサンブル学習に基づく音響識別によるブール沸騰の発生検知"

質疑応答



ご清聴ありがとうございました

質問・議論を歓迎いたします

📄 論文紹介・研究に関するご質問