

中間発表

—CNNアンサンブル学習に基づく音響識別によるプール沸騰の発生検知—

2025年7月18日

植木研究室 8125517 柴崎陸

Agenda

- 01 | 背景・目的
- 02 | 今期実施した検証の全体像
- 03 | 新たなモデルアーキテクチャの導入と詳細
- 04 | 周波数帯域制限による精度と課題の検証
- 05 | 今後の計画

01 | 背景・目的

ナトリウム冷却高速炉（SFR）の安全性向上の必要性

燃料集合体内の「局所閉塞」は冷却材流量を低下させ、沸騰を引き起こす可能性がある。この沸騰音を早期検知できれば、1966年のフェルミ炉のような炉心溶融事故を未然に防げる。



先行研究と残された課題

■ 達成点

プール沸騰時の熱流束予測では、PCAやCNNにより高い精度が報告されている。

■ 課題

- **課題1: 分類精度の不足:** 早期検知に不可欠な「沸騰か、未沸騰か」の分類に特化した研究が乏しい。
- **課題2: ノイズ耐性の欠如:** 実機環境で想定される多様なノイズに対する頑健性の検証が必要。

01 | 研究目的

本研究のコア目的

-  • **【高精度分類】** 早期検知の鍵となる**沸騰-未沸騰の100%分類**が可能な手法を確立する。
-  • **【頑健性評価】** 実機環境を想定し、様々なノイズ条件下での**耐性を評価**する。
-  • **【安定性向上】** **アンサンブル学習**により、単一モデルを超える安定性と精度を実現する。

修士論文で目指す高度化

-  • 特徴量抽出手法の最適化
-  • 最新アーキテクチャによるモデルの高度化
-  • 多様な条件下での汎用性と頑健性の実証

02 | 今期実施した検証内容の概要

本期間では、モデルの内部挙動の理解と最適化に向け、以下の4点の検証を行った。

1

沸騰領域ごとのモデル予測挙動の可視化：モデルが各沸騰様相（未沸騰、核沸騰間開始近傍など）をどう捉えているか評価。

2

評価指標算出方法の変更：決定係数 (R^2) の算出範囲を「沸騰領域のみ」に限定し、精度変化を検証。

3

新規アーキテクチャ (AlexNet + Transformer) の導入：時系列情報を考慮可能なConformer型モデルを構築。

4

入力スペクトログラムの周波数帯域制限の検証：高周波成分をカットした際の影響を検証。


03 | 課題と解決策：CNNとTransformerの融合

課題：単一アーキテクチャの限界


- **CNN**（AlexNet等）：画像的な**局所特徴**（気泡発生の瞬間）の抽出は得意だが、**時間的な大局関係**（沸騰への推移）の把握は苦手。
- **Transformer**：長期的な時系列依存性（**大局**）の学習は得意だが、微細なパターン抽出（**局所**）はCNNに劣る。

解決策：ハイブリッドアプローチ

両者を組み合わせることで、沸騰音の「**突発的な変動**（局所）」と「**沸騰への推移**（大局）」の双方を捉える。音声認識分野で最高性能を記録した**Conformer**の設計思想を参照。



03 | 先行研究：Conformerのアーキテクチャ [Gulati et al., 2020]




概要


- Googleが提案した「Convolution-augmented Transformer」。
- 「マカロン構造 (Macaron-Net)」と呼ばれる独自のブロック構造を採用。
- **要点:** 「1つのブロック内で、常に局所と大局を混ぜ合わせる」のが Conformerの特徴。

03 | 提案手法：AlexNet + Transformerの設計思想


Conformerが「並列・融合型」であるのに対し、本研究では沸騰スペクトログラムの特性を考慮し「**直列型**」を採用。




03 | 提案手法詳細：処理フロー



11x11や3x3のフィルタで気泡音特有のエッジやテクスチャを検出。「どこに沸騰っぽい音があるか」という情報を256種類の特徴として凝縮。



空間情報を長さ49のシーケンスに展開。Self-Attentionにより、「ある瞬間の周波数変化」が「別の瞬間の変化」とどう関連しているか（大局的文脈）を学習。



単なる平均ではなく、「予測に重要なタイムステップ」を自動で重み付け。ノイズを無視し、沸騰音の瞬間を強調して熱流束を予測し、閾値判定で100%の分類を実現。

04 | 検証：周波数帯域制限による精度比較

目的：沸騰音響の主要成分は低周波に存在する。高周波をカットすることで精度向上が見込めるか検証する。

条件：従来設定 (22 kHz) vs. 主要成分に限定 (3 kHz) 。評価モデルはAlexNet+Transformerのアンサンブル。

決定係数(R²)比較：22kHz vs 3kHz


ノイズ量 (dB)	22 kHz R ²	3 kHz R ²
no noise	0.9113	0.9115
0	0.8909	0.8238
-4	0.9213	0.8130
-8	0.9302	0.9117
-12	0.9358	0.9377
-16	0.9440	0.9452
-20	0.9438	0.9445

結果: 静穏時と高ノイズ環境では両者の精度は同等以上だが、**中程度のノイズ(0, -4dB)**で3kHzモデルの精度が予期せず低下する現象を確認した。

04 | 考察：特定ノイズ環境における精度低下の要因

現象

中程度のノイズ環境（SNR 0, -4 dB）において、3kHz入力モデルの精度が22kHz入力モデルを著しく下回る現象を確認。



結論: 3kHz帯域のポテンシャルを正確に評価するためには、入力条件ごとの個別パラメータチューニングが不可欠である。

要因分析：パラメータの非最適化

本検証では、周波数帯域やモデル構造が異なる全条件に対し、**同一のハイパーパラメータ**を適用していた。これにより、特にConformer型モデルにおいてパラメータ不適合による精度劣化が著しく、アンサンブル全体の性能を押し下げる主因となった。

05 | 結論



モデル面

Conformer型アーキテクチャ（AlexNet+Transformer）を構築し、沸騰検知への有効性を確認した。



データ面

沸騰音の主要素は3kHz以下にあるが、中程度のノイズ環境下での頑健性を保つには、3kHzでは情報不足となる場合がある。



全体

アンサンブル学習の性能を最大化するには、モデルごとの特性に合わせた適切な帯域設定とチューニングが不可欠である。

05 | 今後の計画

入力データの改善

- **重要領域の強化:** 沸騰開始点 (ONB) 近傍のデータ密度を向上。
- **データ拡張:** 複数実験日のデータを使用して頑健性を向上。

モデルアーキテクチャの高度化

- **バックボーンの刷新:** AlexNetから最新のEfficientNet / ConvNeXtへ置き換え。
- **Attention Mapの可視化**により、モデルの判断根拠を解明。
- **Relative Positional Encoding**の導入。

学習手法と評価の深化

- **マルチタスク学習:** 「熱流束回帰」と「状態分類」の同時学習によるロバスト性向上。
- **アンサンブル手法の多様化:** Random Forest等モダンな手法を追加。

ご清聴ありがとうございました