

論文輪講

Explainable AI: Context-Aware Layer-Wise Integrated Gradients for Explaining Transformer Models

—Integrated Gradients を層・文脈方向に拡張した
Transformer の説明手法—

2026年6月5日

植木研究室

8125517

柴崎陸

Agenda

- 01 論文を選んだ理由
- 02 研究背景・目的
- 03 手法
- 04 結果・結論

Agenda

01 論文を選んだ理由

02 研究背景・目的

03 手法

04 結果・結論

論文を選んだ理由

自分の研究との関連性

- 自分：CNNアンサンブル学習による沸騰音の発生検知
- 今回選んだ発表論文：
 1. 「AE hit」を用いた音響イベントを離散的に取得
 2. 各hit波形をFFTで周波数特徴へ変換
 3. 複数hitを時系列化し，LSTMで熱流束を推定



「音響データからの熱流束予測」という部分で似ているため
活用の余地があるかも

自分の研究への活用可能性

- 沸騰開始直後の核沸騰による離散的な特徴を，画像全体の分類ではなく「イベント列」として扱える可能性

Agenda

01 論文を選んだ理由

02 研究背景・目的

03 手法

04 結果・結論

研究背景・課題

背景

- 高発熱密度デバイスでの熱管理の重要性
ex) 高出力電子機器，電気自動車，データセンター
- 従来の单相冷却では，高効率な冷却要求に対応しきれない
➡ 潜熱を利用できる二相冷却・プール沸騰が有効
- しかし，沸騰冷却にはCHFが存在するため、機器の過熱・焼損に繋がる恐れ



- CHFを避けつつ，冷却性能を最大限引き出すには，沸騰状態・熱流束をリアルタイムに監視する必要がある

従来手法の課題

従来の沸騰監視手法には限界があり，AEセンサは実用性が高いがデータ処理が難しい

手法	利点	課題
熱電対	温度を直接測れる	侵襲的・沸騰場を乱す
光学画像	気泡を見られる	視野・照明・気泡重なりに弱い
ハイドロフォン	連続音を取得できる	液中に設置する必要がある
AEセンサ	外部設置可能・非侵襲	Hitデータが不連続で扱いにくい

目的

AE hitの不連続性を，LSTMで扱えるイベント列に変換することがHit2Fluxの新規性

目的

AEセンサから得られるhit波形を用いて，プール沸騰中の熱流束を非侵襲的に予測する

新規性

- AE hitを熱流束予測に利用
- 各AE hitをFFTで周波数特徴に変換
- 複数hitをrolling windowで系列化
- LSTMでhit系列と熱流束変化の時間依存性を学習

Agenda

01 論文を選んだ理由


02 研究背景・目的

03 手法

04 結果・結論

手法 - 全体像


AEセンサは外部装置，ハイドロフォンは液中装置で，両者を比較している



手法 - 実験

実験装置の準備


(a) Experimental setup



- ステンレス製プール沸騰タンク
- 脱イオン水
- 加熱面：
 - マイクロチャネル加工された銅ブロック
 - 露出面積 1 cm^2
- 熱電対4本
- AEセンサ：
 - タンク底部に設置
 - 1 MHz
- ハイドロフォン：
 - 液中設置
 - $10,240 \text{ Hz}$

AE hitとは何か

AE hitは閾値超過時のみ記録される離散的な音響イベント



定義


1. AEセンサ信号が閾値を超えると記録開始
2. 一定時間閾値を超えなくなると1つのhitとして終了
3. 本論文では45 dBを閾値に設定

特徴量

- Amplitude : hit中の最大振幅
- Rise time : 閾値超過から最大振幅までの時間
- Count : hit中に閾値を超えた回数
- Duration : hitの継続時間

手法 – 熱流束ラベルの作成


AE hitの入力に対して，熱電対から計算した熱流束を教師ラベルとして対応付ける



1. 0~CHFまで加熱し
2. 4本の熱電対で銅ブロック内の温度分布を測定
3. 加熱面熱流束を外挿
 - 熱電対の位置と温度から温度勾配を推定
 - フーリエの法則により熱流束を計算
4. 各AE hitの終了時刻に対応する熱流束を線形補間でラベル付け
5. 入力：AE hit, 正解ラベル：同時刻の熱流束

手法 - データ前処理1

各AE hit波形をFFTし，周波数特徴ベクトルに変換する




1. 1つのAE hitは「短時間の高周波波形」
2. 時間波形のままではノイズなどの影響を受けやすい
3. FFTにより，周波数強度ベクトルに変換
4. N は窓長で，1つの入力データの大きさを表す


手法 - データ前処理2

Rolling samplingによるAE hit系列の作成

2. Build AE Dataset




3. Build AE Sequences for model input



- 窓長 : N
- スライド : α

手法 – Hit2Fluxモデル構造

Hit2Fluxモデルの構造について



- 入力：N個のAE hit周波数特徴
- Dense層：各hitの周波数特徴をモデル内部表現へ圧縮・変換
- LSTM層：hit列の順序・時間的变化を学習
- 出力：各時刻の熱流束を予測
- 評価：系列最後のhitに対応する熱流束を使用

手法 – Hit2Fluxモデル構造

Hit2Fluxモデルの構造について

Table 1

The architecture of the proposed Hit2Flux model.

Layer	Neurons/units	Activation function	Additional parameters
Input	–	–	shape=(N,FI)
Dense	3000	Relu	–
LSTM	2000	–	return_sequences=True
Dropout	–	–	rate=0.2
LSTM	1000	–	return_sequences=True
LSTM	500	–	return_sequences=True
Dropout	–	–	rate=0.2
Dense	2000	Relu	–
Dropout	–	–	rate=0.2
Dense	1000	Relu	–
Dense	600	Relu	–
Dropout	–	–	rate=0.2
Dense	1	Linear	–

- 入力：N個のhit×周波数特徴次元 FI
- Dense：特徴変換
- LSTM：時間依存性を学習
- 出力：予測熱流束

手法 – 実験条件・比較対象

本論文の提案と比較する対象の詳細

実験条件

- 4回分のプール沸騰実験データを使用し，3回分で学習・検証を，1回分でテストを行った

比較モデル

- MLP（多層パーセプトロン）
- RFR（ランダムフォレスト回帰）
- GPR（ガウス過程回帰）
- CNN
- LSTM

入力特徴


- Raw signal
- Spectrum
- Cepstrum
- AE features

Agenda

- 01 論文を選んだ理由
- 02 研究背景・目的
- 03 手法
- 04 **結果・結論**

結果・結論①


入力したhit数Nの影響度合いを表した散布図



- N = 3, 5, 10, 15, 20, 25で比較
- Nが大きくなるほど予測が真値に近づき，ばらつきが減る

結果・結論①

入力したhit数Nの影響度合いを表した定量評価



- $N = 25$ の各評価指標：決定係数→0.97，MSE→89
- この結果から，複数hitを用いることで，沸騰の時間的变化を捉えられると言える

結果・結論②

LSTMと他手法を比較したグラフ

Table 2


Performance summarization of models with different combinations of methods, feature extractions, and sequence lengths.

Method	Feature extraction	Hits per input (N)	R2	MSE
MLP	–	1	0.68	901
		25	0.12	2350
	Spectrum	1	0.89	308
		25	0.94	161
	Cepstrum	25	0.6	1083
RFR	AE Features	1	0.71	818
		25	0.69	809
GPR	Spectrum	1	0.82	518
	Cepstrum	1	0.77	665
CNN	–	1	0.52	1357
		25	0.71	766
	Spectrum	1	0.89	327
		25	0.95	142
	Cepstrum	1	0.69	878
		25	0.89	280
	–	25	0.84	406
LSTM (Ours)	Spectrum	25	0.97	89
	Cepstrum	25	0.95	126

- Spectrum特徴はCepstrumより全体的に高性能
- FFT+hit系列+LSTMが最も高性能

結果・結論③

AEとハイドロフォンの比較



- GPRではハイドロフォンのほうが高性能であり，AEは変動が大きく古典的な回帰では扱いにくい → しかし，Hit2FluxではAE入力がハイドロフォンを上回る
- AEは高サンプリングで高熱流束時の重要イベントを多く捉えられる

まとめ

自分の論文への活用について

- Rolling samplingによりイベント系列として音響データを扱うことで、初期沸騰の時間変化を捉えやすくなる可能性がある
- ノイズ環境下での初期沸騰検知への応用として、LSTMをアンサンブルの1つとして用いることができる可能性。
- ↑ Transformerは長距離依存，rolling sampling×LSTMなら隣り合った特徴hitを平均的に取れるのでアンサンブルに有効？