令和 7 年度 修士論文

深層学習に基づく気液二相噴流の音響識別：回帰分析とノイズ耐性評価

2026 年 1 月

指導教員

植木 祥高 准教授

東京理科大学大学院 先進工学研究科

電子システム工学専攻 植木研究室

8124507 奥村 修也

要旨

核燃料の効率的な利用が可能と見込まれるナトリウム冷却高速炉 (SFR) は，原子炉冷却材として液体ナトリウムを利用し，核分裂の増殖が可能である．SFR の安全性を高めるためには，蒸気発生器内の伝熱管が破損した際に生じる気泡噴流の発生を早期に検知し，その状態を把握する手法を開発することが重要である．この課題に対して，先行研究と同様の，時間-周波数表現 (TFR) と畳み込みニューラルネットワーク (CNN) を用いた分類問題に加え，回帰分析を行うことでさらに詳しい状態把握が可能かを実証する．本研究は 4 つの段階に分かれている．まず，概念実証を行うために，模擬流体として純水と空気を用い，孔径の異なる 6 種類のノズルから異常音を模擬した気泡噴流音を取得する．その後，実機環境で想定されるバックグラウンドノイズとして水流動音．ホワイトノイズを気泡噴流音に重畳させる．次に，短時間フーリエ変換 (STFT)，連続ウェーブレット変換 (CWT)，シンクロスクイーズドウェーブレット変換 (SWT) に基づいて，音響データから 3 種類の TFR を抽出する，最後に，AlexNet，VGG16，ResNet18 と，ResNet50 といった CNN を導入し，回帰分析を行った．その結果，水流動音ノイズの場合は SNR が-12 dB 以上の場合 0.8 以上の決定係数を示した．これらの結果は，深層学習に基づく我々の提案する手法が，実際の SFR における気泡噴流の状態把握に寄与する可能性を示している．

abstract

Sodium-cooled fast reactors (SFRs), which are expected to enable efficient nuclear fuel utilization, use liquid sodium as the reactor coolant and are capable of nuclear fission breeding. To enhance SFR safety, it is crucial to develop methods for early detection and monitoring of bubble jets that occur when heat transfer tubes in the steam generator rupture. To address this challenge, this study demonstrates whether regression analysis, in addition to classification using time-frequency representation (TFR) and convolutional neural networks (CNN) as in previous research, can enable more detailed state assessment. This research is divided into four stages. First, for proof-of-concept, bubble jet sounds simulating abnormal noises are acquired from six nozzles with different orifice diameters, using pure water and air as simulated fluids. Subsequently, water flow noise and white noise, representing background noise expected in actual plant environments, are superimposed onto the bubble jet sounds. Next, three types of TFR are extracted from the acoustic data based on Short-Time Fourier Transform (STFT), Continuous Wavelet Transform (CWT), and Synchro-Squeezed Wavelet Transform (SWT). Finally, regression analysis is performed using CNNs such as AlexNet, VGG16, ResNet18, and ResNet50. The results showed a coefficient of determination (R^2) of 0.8 or higher for water flow noise when the signal-to-noise ratio (SNR) was -12 dB or higher. These results indicate that our proposed deep learning-based method has the potential to contribute to understanding the state of bubble jets in actual SFR.

目次

第 1 章　緒言 **1**
1.1　研究背景 1
1.2　本研究の目的 3

第 2 章　音響データ計測 **5**
2.1　実験方法 5
2.2　臨界流の判定 7
2.3　時間-周波数解析手法 9
2.4　実験データの解析結果 12

第 3 章　深層学習 **15**
3.1　データセット構築手法 15
3.2　深層学習のモデル構築 16
3.3　データセット・ハイパーパラメータの設定 20

第 4 章　学習結果と考察 **27**
4.1　6 孔径の回帰分析 27
4.2　6 孔径 + バックグラウンドノイズの回帰分析 27

第 5 章　結言 **38**
5.1　まとめ 38
5.2　今後の展望 39

参考文献 **41**

第 1 章

緒言

1.1 研究背景

近年，地球温暖化の進行に伴い，温室効果ガス排出量の削減は人類共通の課題となっている．特に 2015 年のパリ協定の採択以後， 多くの国においてカーボンニュートラルの実現を目指し，再生可能エネルギーの導入拡大とともに，安定的な低炭素電源の確保が強く求められている． 再生可能エネルギーは低炭素社会の実現に不可欠であるが，その出力は気象条件に左右されるため，大規模導入に際しては電力の安定供給に課題が残る [1]．したがって，再エネを補完しつつ持続的な電力供給を可能とする次世代の低炭素電源技術が注目されている．その中でも，ナトリウム冷却高速炉（Sodium-cooled Fast Reactor: SFR）は，運転時に CO_2 を排出しない原子力技術であるだけでなく，高速増殖炉として核燃料を効率的に利用できる特性を持ち，資源の有効活用と廃棄物削減を両立し得る点で，カーボンニュートラル社会の実現に大きく貢献し得ると期待されている．SFR は高速の中性子による核分裂反応を利用してエネルギーを取り出しながら，核分裂に寄与しない余剰な中性子を利用し核燃料を増殖することが可能な原子炉である [2]．SFR の模式図は Fig.1.1.1 のようになっており，核反応により発生した熱は放射性物質を含む 1 次系ナトリウム, 放射性物質を含まない 2 次系ナトリウムを媒体として蒸気発生器内の伝熱管中の水に伝えられる．そして, 蒸気発生器内で生成した水蒸気がタービンを回転させることで発電する仕組みとなっている．

さらに SFR は，既存の軽水炉で発生した使用済み燃料を再利用できる閉じた燃料サイクルを構築できる点から，資源依存度の低減と放射性廃棄物の大幅削減の両立が可能とされる．このため，SFR は国際的にも次世代原子力技術の中核として位置づけられ，Generation-IV International Forum（GIF）において優先的開発対象とされている．一方で，SFR の安全性確保は最重要課題であり，とりわけ Fig.1.1.2 の左図に示すような蒸気発生器（SG: Steam Generator）の健全性維持は運転の信頼性に直結する．SFR の SG は一次系の液体ナトリウムと二次系の水・蒸気を熱交換させる役割を担うが，構造的に両者が伝熱管で隔てられている．このため，伝熱管の微小な損傷や劣化によって亀裂が生じ，水蒸気がナトリウム側に漏洩すると，ナトリウム - 水反応が生じる．この反応では一次反応として

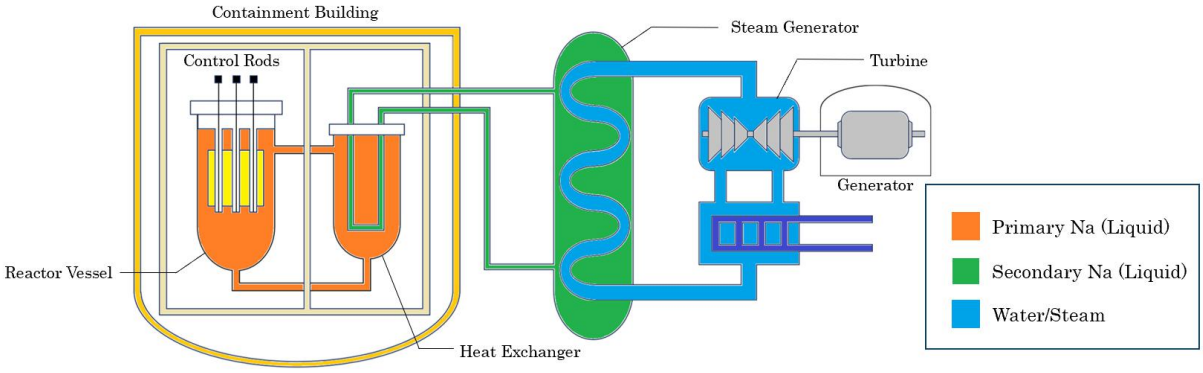


Fig. 1.1.1 Schematic diagram of Sodium-cooled Fast Reactor.

$$\mathrm{Na} \ + \ \mathrm{H_2O} \rightarrow \mathrm{NaOH} \ + \ \frac{1}{2}\mathrm{H_2} \tag{1.1.1}$$

二次反応として

$$2\mathrm{Na} \ + \ \mathrm{H_2O} \rightarrow \mathrm{Na_2O} \ + \ \mathrm{H_2} \tag{1.1.2}$$

の発熱反応が起こるため，SG 伝熱管破損は高温・強アルカリ性の気液二相噴流を伴い，Fig.1.1.2 の右図に示すように二次系配管や構造物を損傷させる恐れがある [3][4]．実機においても，過去にナトリウム - 水反応に起因するトラブルが報告 [5, 6, 7, 8] されており，漏洩の早期発見と適切な対応は SFR の安全確保における鍵となっている．

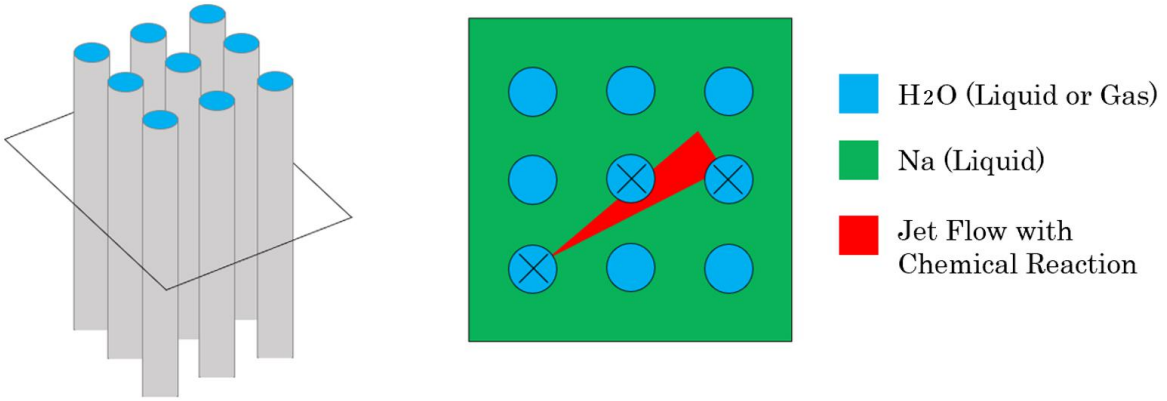


Fig. 1.1.2 Schematic diagram of steam generator.

このような背景のもと，これまでにさまざまな漏洩検知技術が検討されてきた．光学的手法はカメラ [9] を用いて気泡噴流の挙動を可視化するものであり，基礎研究段階では有用な情報を提供してきた．しかし，液体ナトリウムは不透明かつ高温であるため，実機環境において光学的観測は可視光では不可能である．また，SG 伝熱管群は複雑に入り組んだ構造を有しており，可視性に大きな制約があることから，光学的検知手法は実用上大きな限界を抱えている．一方で，音響的手法はこれらの課題を回避できる点で有利である．気泡噴流や Na–水

反応の発生時には特有の音響信号が発生し，これらは液体ナトリウムや構造材を介して良好に伝播することが予想される．この特性を利用することで，SG に設置したセンサから漏洩の兆候を非接触的に検出することが可能であると見込まれる．これまでの気液二相流実験においても，流動状態に応じた音響信号の違いが確認されており [10]，音響的指標が流体力学的状態を反映することが報告されている．すなわち，音響情報は流動の可視化が困難な不透明媒体においても，有効な状態同定の手段となり得る．近年では，センシング技術の進歩により，数百 kHz から MHz 帯域に至る広帯域音響信号の高精度計測が可能となり，微小な異常を検出する研究も進展している．さらに，これらの高次元かつ時間依存的なデータを効率的に解析する手法として，深層学習（Deep Learning）[11] が注目されている．ニューラルネットワークは，多数の人工ニューロンを層状に接続した情報処理モデルであり，誤差逆伝播法と勾配降下法に基づく学習アルゴリズムによって最適化される．これにより，大規模データから有用な特徴を自動的に抽出し，非線形かつ複雑な関係を高精度に近似できる点が特長である．入力データの形式は対象分野に応じて異なり，数値ベクトル [12]，画像 [13]，時系列信号 [14] などが利用される．音響信号の場合，時間領域の波形データをそのまま入力する [15] 方法に加え，周波数解析を経て得られるスペクトログラム [16] やメル周波数ケプストラム係数（MFCC）[17] を二次元画像として入力する方法が広く用いられている．これにより，時間的変化と周波数特性の両方を考慮した特徴抽出が可能となり，音響識別の高精度化に寄与している．特に畳み込みニューラルネットワーク（Convolutional Neural Network: CNN）は，局所的特徴を自動抽出する畳み込み層と，抽象化を進めるプーリング層を組み合わせ，空間的・時間的構造を持つデータから階層的特徴表現を学習することができる．CNN は画像認識だけでなく，音声認識 [18] や環境音識別 [19] など，時周波数特性を持つ信号解析にも高い性能を示しており，特に雑音環境下においても頑健な識別が可能である [20]．このノイズ耐性は，実際のプラント環境のような複雑な背景雑音を含む条件下で有用であり，SFR のような高騒音・高温環境での異常検知にも適していると考えられる．しかし，既存研究の多くは分類問題 [21] に基づいており，限られたクラス数の中での判別に留まっている．実際の SG における異常進展は，微小な損傷から徐々に拡大する連続的な変化であり，離散的な分類枠組みではこの過程を正確に追跡することはできない．すなわち，分類はある段階での異常の有無を判定するには有用であるが，漏洩規模の定量的評価や進展度の推定といった運転上重要な指標を与えることは困難である．

1.2 本研究の目的

以上を踏まえ，本研究では，様々な信号対雑音比（SNR：Signal to Noise Ratio）条件下において，畳み込みニューラルネットワーク（CNN）に基づく気液二相噴流音の回帰分析を行い，ノイズ環境下における異常状態の定量的把握に対する有効性を検証することを目的とする。提案手法により，騒音環境や不可視環境下においても，気液二相噴流の規模を高精度に推定できる可能性を示す．これらのことは, SFR の安全性向上や高速度, 高精度な異常検知お

よび事象進展分析に繋がる．本研究では，概念実証を目的として基礎的な空気–水系を対象とし，バックグラウンドノイズを模擬した水流動音および異常音を模擬した気液二相噴流音として取得された音響データを用いる．次に，SNR に基づいて増幅した水流動音およびホワイトノイズを気液二相噴流音に付加することで，ノイズ環境下における気液二相噴流音を模擬する．さらに，短時間フーリエ変換（STFT: short-time Fourier transform），連続ウェーブレット変換（CWT: continuous wavelet transform），およびシンクロスクイーズドウェーブレット変換（SWT: synchrosqueezed wavelet transform）といった異なる特性を持つ TFR 手法を用いて時間–周波数表現（TFR: Time–Frequency Representation）のデータセットを作成する。．最後に，AlexNet，VGG16，ResNet18，および ResNet50 の代表的な畳み込みニューラルネットワーク（CNN）を用いて回帰分析を行い，異常の規模を連続値として推定し，結果に基づいて TFR 手法およびネットワーク構造の違いがノイズ環境下での推定精度に及ぼす影響を評価する．本研究ではまず，気液二相噴流音から孔径を連続量として推定可能かを検証するため，6 種類の孔径データのみを用いた回帰分析を行った．本解析は孔径推定の原理的成立性を評価する基礎的検証として位置づけられ，最も基本的な時間–周波数表現である STFT によるスペクトログラムを用いた。これは，まず基本的な表現を用いて孔径推定が可能であるかを確認することを目的としたためである。次に，6 種類の孔径データにバックグラウンドノイズを異常なしデータとして加えた条件において回帰分析を行い，正常状態と異常状態が混在する状況下での孔径推定性能を評価する。これは，実環境においては異常の有無を含めたより包括的な評価が求められるためである．さらに，時間–周波数表現の違いが回帰性能に与える影響を明らかにするため，STFT，CWT，SWT の 3 種類の表現を用いてデータセットを構築し，推定結果を比較した．

第 2 章

音響データ計測

本章では, 実機 SFR のバックグラウンドノイズを模擬した水流動音と，伝熱管が破損した際に発生する音 (異常音) を模擬した気液二相噴流音についてまとめる.

2.1　実験方法

本節では, 気泡噴流音計測実験の実験方法について示す. まず, 実験装置を列挙し, 実際の実験環境を図を用いて説明した後, 最後に実験手順を述べる.

2.1.1　水流動音

本研究で用いた水流動音は，大阪大学において実施された水流動実験により取得されたサンプリング周波数 44.1 kHz，計測時間 60 s の音響データである．実験装置および計測条件の詳細は既報論文 [20] に示されている．本研究では，バックグラウンドノイズとして使用した.

2.1.2　気液二相噴流音

気液二相噴流音取得に用いた器具を Table 2.1.1 に示す．ここで，Table 2.1.1 に示す 6 種類のノズルの孔径は公称値であり, 光学顕微鏡で実測した孔径は，公称径 0.10 mm が 0.098 mm ，公称径 0.13 mm が 0.1336 mm ，公称径 0.15 mm が 0.1522 mm ，公称径 0.18 mm が 0.1843 mm ，公称径 0.20 mm が 0.196 mm ，公称径 0.25 mm が 0.252 mm となった．PC と A/D 変換器は USB ケーブル, A/D 変換器とハイドロフォンは BNC コネクタから 3P コネクタへの防水ケーブルで接続し，ハイドロフォンの録音操作は PC にインストールされたソフトウェアの Record Pad により行った．その際，サンプリングレートは 44.1 kHz に設定した．また, 流量計, 圧力計, 熱電対はデータロガーに接続した. 流量計, 圧力計へは電源を供給する必要があるため, 直流電源を用いて電力供給を行った.

Table 2.1.1 Experimental equipment of measuring the bubble jet sound.

装置	製造元	型式	備考
計測用 PC	DELL	Inspiron 15 3511	-
データロガー	GRAPHTEC	GL840 series	-
直流電源	MiSUMi	ESP10-15-12	定格電圧: 12 V, 定格電流: 1.3 A
AD 変換器	ACO	Spectra DAQ-200	ダイナミックレンジ:4〜92kHz
ハイドロフォン	ACO	TYPE 7800	サンプリングレート:44.2kHz
エアコンプレッサー	AirREX	FX7601	制御圧力 0.6〜0.8MPa
エアフィルター	KEYENCE	FD-C5	-
スピードコントローラ	KEYENCE	FD-C1	-
流量計	KEYENCE	FD-A10	検出レンジ:0.30〜10L
デジタルアンプ	KEYENCE	FD-V40A	-
圧力計	長野計器	GC31	検出レンジ:0〜1.0MPa
N 型熱電対	京都タカオシン	-	-
SUS304 角ノズル	有限会社エーサポート製作所	-	孔径:0.10,0.20,0.25 mm
水槽	-	-	内寸:W900 × D450 × H450 mm
超純水製造装置	Merck	Direct-Q UV	純度:18.2 M Ω・cm 以上
水質計	東亜ディーケーケー	MM-41DP	-

実験環境は Fig. 2.1.1 に示すとおりで, 斜線は注水部を表す. エアコンプレッサーで 0.7,0.6,0.5 MPa (絶対圧) まで圧縮された空気は，フィルター，調整弁，流量計，圧力計を介してノズルから水中に放出した. また, 水槽の水位は底から 300 mm とし，ハイドロフォンを気泡噴流の後方 170 mm に配置し，各ノズルからの気泡噴流音をサンプリングレート 44.1 kHz で 2 分間記録した. 各条件での測定を 5 回繰り返し，各圧力，各ノズル径につき計 10 分間のデータを取得した.

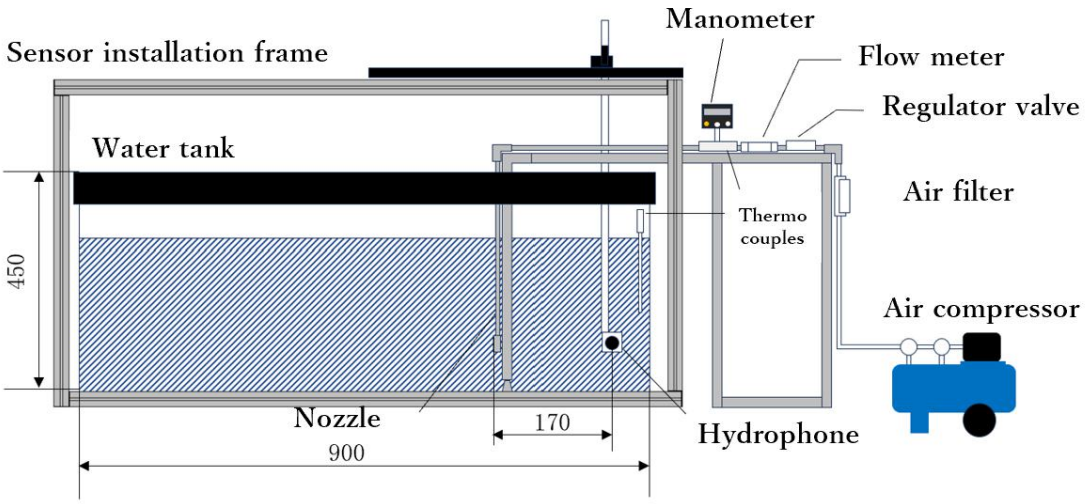


Fig. 2.1.1 Experimental conditions of measuring the bubble jet sound.

以下に, 気泡噴流音測定の実験手順を示す.

1. 水槽内の塵や埃をできる限り除去. (塵や埃が音の伝播を阻害する可能性があるため.)

2. 水槽内の水位が 300 mm になるまで超純水製造装置で製造した純水を注水.
3. 径が 0.10 mm のノズルを配管につなぎ, 水槽内へ設置.
4. ノズル孔から気泡噴流の後方への距離が 170 mm となるように, ハイドロフォンの位置および角度を調整.
5. 水質計で電気伝導率を測定.
6. エアコンプレッサーにより空気を圧縮.
7. 放出圧力が 0.70, 0.60, .0.50 MPa になるように, スピードコントローラで流量を調整.
8. 圧力が安定したら, 2 台の計測 PC で 2 分間同時に測定.
9. 他の放出圧力，孔径の場合についても, 上記 3〜7 の手順を反復.

なお，今回の実験では 5 回上記の測定を行い，各放出圧力，孔径の音データを計 8 分測定した．各回の電気伝導率や超純水の液温，放出気体温度のデータは Table 2.1.2 に示す通りである．

Table 2.1.2 Electrical conductivity before and after measurement.

実験回数	電気伝導率 mS/m	超純水の液温 °C	放出気体温度 °C
1	0.135	22.4 〜 22.9	23.9 〜 24.4
2	0.164	22.5 〜 22.8	24.0 〜 25.0
3	0.197	23.3 〜 23.6	24.3 〜 24.7
4	0.163	21.6 〜 23.2	22.3 〜 23.7
5	0.128	21.8 〜 22.4	22.7 〜 23.9

2.2 臨界流の判定

き裂からの流出流量は二相臨界流現象に支配されるため，ナトリウム冷却高速炉の蒸気発生器内における伝熱管破損を模する上で，臨界流が達成されているかを判定する必要がある．本節では，臨界流達成を判定するための理論を以下に記述する．
実機環境において，気相吹き出し流動が臨界流に達していることが見込まれているとき，ノズルでチョークした条件下での質量流量 m は次式で表される．

$$m = \frac{P_0 A}{\sqrt{RT_0}} \sqrt{\gamma} \left(\frac{\gamma + 1}{2} \right)^{-\frac{\gamma+1}{2(\gamma-1)}} \tag{2.2.1}$$

ここで，P_0 はノズルでのよどみ点圧力，T_0 はノズルでのよどみ点温度，R は一般気体定数，A はノズル断面積，γ は断熱比である．ここで連続の式

$$m = \rho_N v_N A \ = \ \rho v A \tag{2.2.2}$$

を考える．ρ は密度，ρ_N は標準状態の密度，v_N は流速，v_N は標準状態の流速である，標準状態で規格化した体積流量 Q_N は次式で表される．

$$Q_N = \frac{1}{\rho_N}\frac{P_0 A}{\sqrt{RT_0}}\sqrt{\gamma}\left(\frac{\gamma+1}{2}\right)^{-\frac{\gamma+1}{2(\gamma-1)}} \tag{2.2.3}$$

以上により，ノズルにてチョークした条件において，標準状態で規格化した体積流量 Q_N とノズルでのよどみ点圧力 P_0 は線形関係を有し，Q_N/P_0 は一定値を取る．

臨界流の判定の為，横軸に，標準状態で規格化した体積流量，縦軸に，標準状態で規格化した体積流量を圧力で割った値でプロットした図を Fig. 2.2.1 に示す．

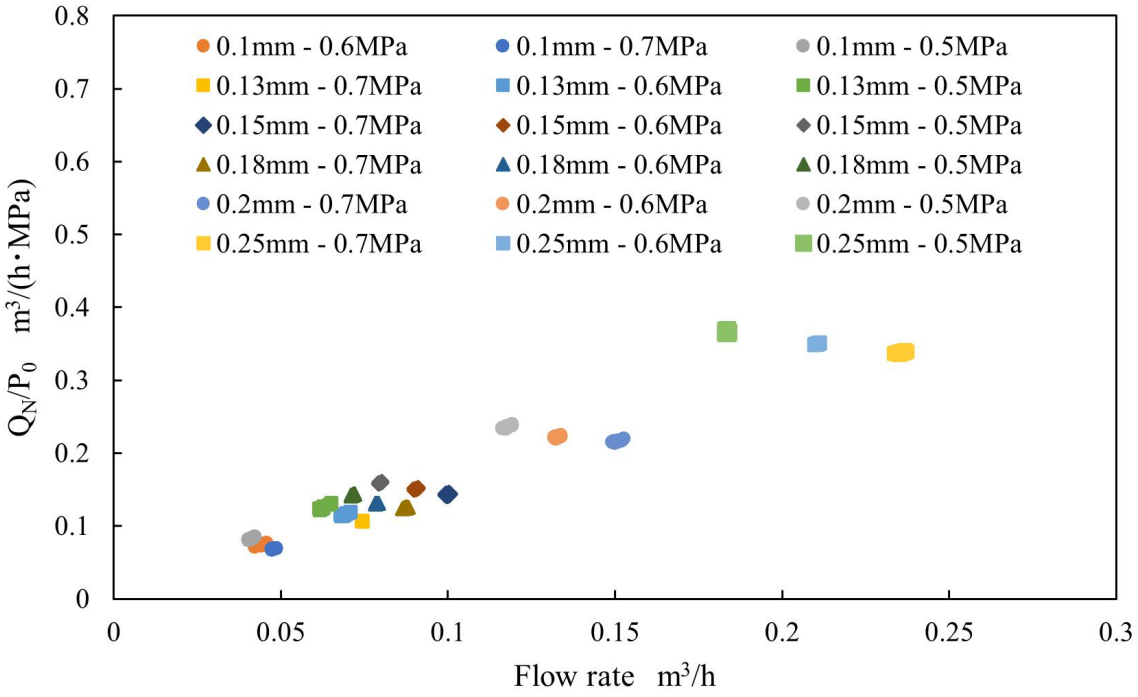


Fig. 2.2.1 Test of critical flow.

次に，各孔径における Q_N/P_0 の相対標準誤差を計算した結果を Fig. 2.2.1 に示す．

Table 2.2.1 Electrical conductivity before and after measurement.

ノズル径 mm	相対標準誤差 %
0.1	7.412
0.13	6.162
0.15	4.324
0.18	6.255
0.2	3.746
0.25	3.255

相対標準偏差は全孔径において 3〜8 % と小さいことから，全体的な傾向として Q_N/P_0 はほぼ一定値を取っていることが確認できたので，臨界流が達成できていると考えられる．

2.3 時間-周波数解析手法

一般に，非定常信号の周波数成分は時間とともに変化するため，従来のフーリエ変換による周波数解析では，時間変化を考慮した信号特性を十分に捉えることができない．そのため，時間領域と周波数領域の両方の情報を同時に表現する時間-周波数解析が広く用いられている．時間-周波数解析では，信号を時間軸上の局所区間に分解し，その各区間に対して周波数解析を行うことで，時間に依存したスペクトルの変動を可視化することが可能となる．時間-周波数解析の結果として得られる二次元分布は，時間-周波数表現（Time–Frequency Representation, TFR）と呼ばれる．TFR は横軸に時間，縦軸に周波数を取り，輝度または色で振幅またはエネルギーを示すものであり，信号のエネルギーがどの時間帯・周波数帯に集中しているかを視覚的に表す．TFR は画像データとして扱うことができるため，畳み込みニューラルネットワーク（CNN）との組み合わせにも適しており，音響や振動などの非定常信号解析で頻繁に利用されている．本研究では，基本的な時間-周波数解析手法である STFT に加え，異なる周波数・時間解像度を持つ CWT , 周波数解像度に優れた SWT を用いて TFR の作成を行う. 以下に STFT, CWT , SWT の定義と性質について述べる．

2.3.1 短時間フーリエ変換（STFT）

STFT は，信号を短い時間窓で区切り，各区間に対して高速フーリエ変換を行うことにより，時間的変化を伴う周波数成分を抽出する手法である．時間信号 $s(t)$ に対する STFT は，次式で定義される．

$$\mathrm{STFT}(t,\omega) \;=\; \int_{-\infty}^{\infty} s(\tau)h(\tau-t)e^{-j\omega\tau}\,d\tau \tag{2.3.1}$$

ここで，$h(t)$ は窓関数，ω は角周波数を表す．また，窓関数として，次式で定義されるハニング窓を導入する．

$$h(x) = \frac{1}{2} - \frac{1}{2}\cos(2\pi x) \;\; (0 \le x \le 1) \tag{2.3.2}$$

式 2.3.1 に示すように，STFT は時間信号と，時間シフトした窓関数の積のフーリエ変換を計算する [22].

2.3.2 連続ウェーブレット変換（CWT）

ウェーブレット変換は，時間-周波数解析手法として局在化した小さい波（ウェーブレット）を用いる．ウェーブレット変換では，ウェーブレット信号のスケールと時間シフトを変化させ，ある時点の信号を解析できる [23]．連続時間信号 $s(t)$（t は実数）は，絶対 2 乗積分可能であるとする．いま，ψ をマザーウェーブレットと呼び，ψ をスケール a，時間シフト b を変化させたウェーブレットの集合を式（2.3.3）のように定義する [24].

$$\psi_{a,b}(t) = \frac{1}{\sqrt{a}}\psi\left(\frac{t-b}{a}\right) \tag{2.3.3}$$

ただし，a，b は実数である．

このとき，$s(t)$ の CWT $W_s(a,b)$ は，式（2.3.4）で定義される．

$$W_s(a,b) = \int_{-\infty}^{\infty} s(t)\frac{1}{\sqrt{a}}\overline{\psi\left(\frac{t-b}{a}\right)}dt \tag{2.3.4}$$

ただし，$\overline{\psi(t)}$ は $\psi(t)$ の共役である．

ウェーブレット $\psi_{a,b}(t)$ は，マザーウェーブレット ψ を b 時間シフトし，a スケール（拡大縮小）したものである．マザーウェーブレット ψ 及び 2 つのパラメータ a，b を選ぶことにより，信号 $s(t)$ を局所的に解析できる．本研究では，解析対象とする周波数帯域をあらかじめ設定し，周波数 f に対応するスケールを

$$a = \frac{f_c f_s}{f} \tag{2.3.5}$$

により算出した．ここで，f_s はサンプリング周波数，f_c は Morlet ウェーブレットの中心周波数であり，本研究では $f_c = 1$ とした．b は解析区間内の時刻を表し，解析区間長そのものを意味するものではない．周波数 f は $f_{\min}$ から $f_{\max}$ までを等間隔に分割した周波数配列として与え，これに対応するスケール配列を用いて CWT を実施した。本研究ではマザーウェーブレットに複素 Morlet ウェーブレット [25]

$$\psi(t) = \frac{1}{\sqrt{\pi f_b}}\exp\left(2\pi i f_c t\right)\exp\left(-\frac{t^2}{f_b}\right) \tag{2.3.6}$$

を用いた．ここで，f_b は周波数の分散の逆数である帯域幅変数，f_c は複素 Morlet ウェーブレットの中心周波数である．また式（2.3.4） に示されるように，CWT はスケール変数と時間シフト変数の関数であるため，CWT は時間-スケール解析と呼ばれる．その一方，周波数位置の特定のためには時間-スケール空間から時間–周波数空間に変換する必要がある．本研究では，次式を用いてスケール変数を疑似周波数 f_{pseudo} に変換する [26, 27].

$$f_{\text{pseudo}} = \frac{f_c f_s}{a} \tag{2.3.7}$$

ここで，f_s はサンプリングレートである．

2.3.3 シンクロスクイーズドウェーブレット変換（SWT）

時間信号 $s(t)$ が振幅 A，角周波数 ω の高調波信号

$$s(t) = A\cos(\omega t) \tag{2.3.8}$$

で表され，マザーウェーブレットのフーリエ変換 $\hat{\psi}(\xi)$ が 0 Hz 以上にのみ強度をもつ，つまり

$$\hat{\psi}(\xi) = 0 \qquad (\xi < 0) \tag{2.3.9}$$

であると仮定すると，式 (2.3.4) は次式のように変形できる．

$$\begin{aligned} W_s(a,b) &= \frac{1}{2\pi} \int \hat{s}(\xi)\, a^{1/2}\, \overline{\hat{\psi}(a\xi)}\, e^{\mathrm{i}b\xi}\, d\xi \\ &= \frac{A}{4\pi} \int \left[\delta(\xi-\omega) + \delta(\xi+\omega)\right]\, a^{1/2}\, \overline{\hat{\psi}(a\xi)}\, e^{\mathrm{i}b\xi}\, d\xi \\ &= \frac{A}{4\pi}\, a^{1/2}\, \overline{\hat{\psi}(a\omega)}\, e^{\mathrm{i}b\omega} \end{aligned} \tag{2.3.10}$$

ここで，$\hat{s}(\xi)$ は時間信号のフーリエ変換，$\overline{\hat{\psi}(a\xi)}$ は $\hat{\psi}(a\xi)$ の複素共役，δ はデルタ関数である．式 (2.3.10) より，$\hat{\psi}(\xi)$ が $\xi = \omega_0$ の近傍で強度をもつとき，$W_s(a,b)$ は $a = \omega_0/\omega$ の近傍で強度をもつことがわかる．本研究で用いた複素 Morlet ウェーブレットは中心周波数の近傍においても強度をもつため，$W_s(a,b)$ は $a = 2\pi f_c/\omega$ の近傍で帯状の信号強度を示すことになる．そのため，時間信号がもつ $2\pi\omega$ の周波数成分の近傍にも信号強度が表れてしまう．この問題に対し，瞬時周波数の近傍で $W_s(a,b)$ を再計算することにより，マザーウェーブレットの影響で帯状に広がった信号強度を押し込める手法である SWT が考案された．その定義は次式で表される [28].

$$T_s(\omega_l, b) = \frac{1}{\Delta\omega} \sum_{a_k:\, |\omega(a_k,b)-\omega_l| \le \Delta\omega/2} W_s(a_k, b)\, a_k^{-3/2}\, (\Delta a)_k \tag{2.3.11}$$

ここで，$a_k - a_{k-1} = (\Delta a)_k$，$\omega_l - \omega_{l-1} = \Delta\omega$ であり，式 (2.3.10) より時間信号の瞬時角周波数は

$$\begin{aligned} \omega_s(a,b) &= -\mathrm{i}\left(W_s(a,b)\right)^{-1} \frac{\partial}{\partial b} W_s(a,b) \\ &= \left(\frac{2\pi f_c}{a} - \frac{2\mathrm{i}}{a^2 f_b}\right) \cdot \frac{\displaystyle\int s(t)\, \overline{\psi\left(\frac{t-b}{a}\right)} (t-b)\, dt}{\displaystyle\int s(t)\, \overline{\psi\left(\frac{t-b}{a}\right)}\, dt} \\ &= \left(2\pi - \frac{2\mathrm{i}}{f_b} \cdot \frac{f_{\mathrm{pseudo}}}{f_c^2 f_s}\right) \cdot \frac{\displaystyle\int s(t)\, \overline{\psi\left(\frac{t-b}{a}\right)} (t-b)\, dt}{\displaystyle\int s(t)\, \overline{\psi\left(\frac{t-b}{a}\right)}\, dt} \cdot \frac{f_{\mathrm{pseudo}}}{f_s} \end{aligned} \tag{2.3.12}$$

で求められる．ただし，f_c，f_s，f_{pseudo} の単位が [1/s]，f_b の単位が [s^2] であることから，式 (2.3.12) により得られる瞬時角周波数は無次元となるため，式 (2.3.11) を用いて $T_s(\omega_l, b)$ を求める際は，式 (2.3.12) に f_s を掛けて瞬時角周波数を計算する必要がある．

ここで，式 (2.3.8) において $A = 1$，周波数 $f = 10\,\mathrm{kHz}$（角周波数 $\omega = 2\pi f$）の正弦波を用いて，STFT，CWT，SWT による時間周波数表現の比較を行った結果を Fig.2.3.1 に示す．STFT と比較すると，CWT の信号強度分布が帯状に広がっていることが分かる．一方，SWT の信号分布は CWT の信号強度分布を再計算しているため，STFT 同様に 10000 Hz に信号強度が表れていることが分かる．

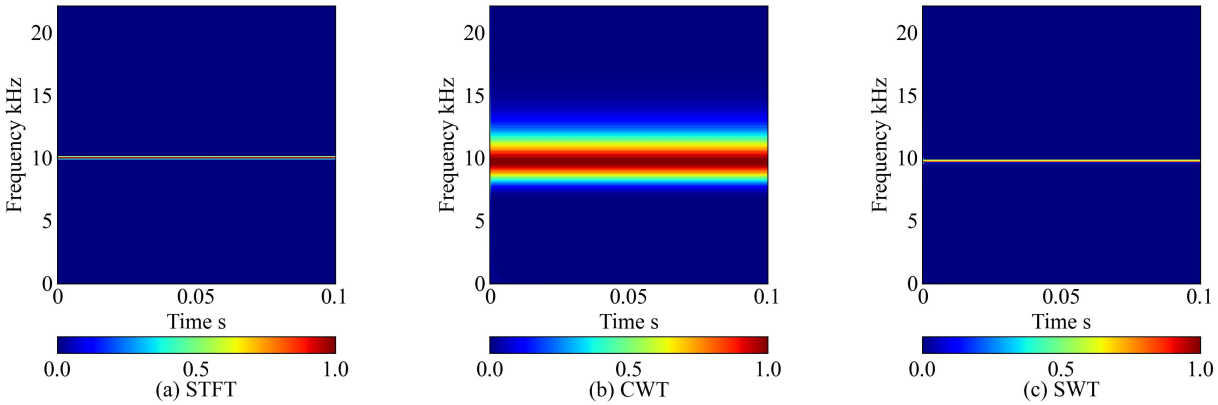
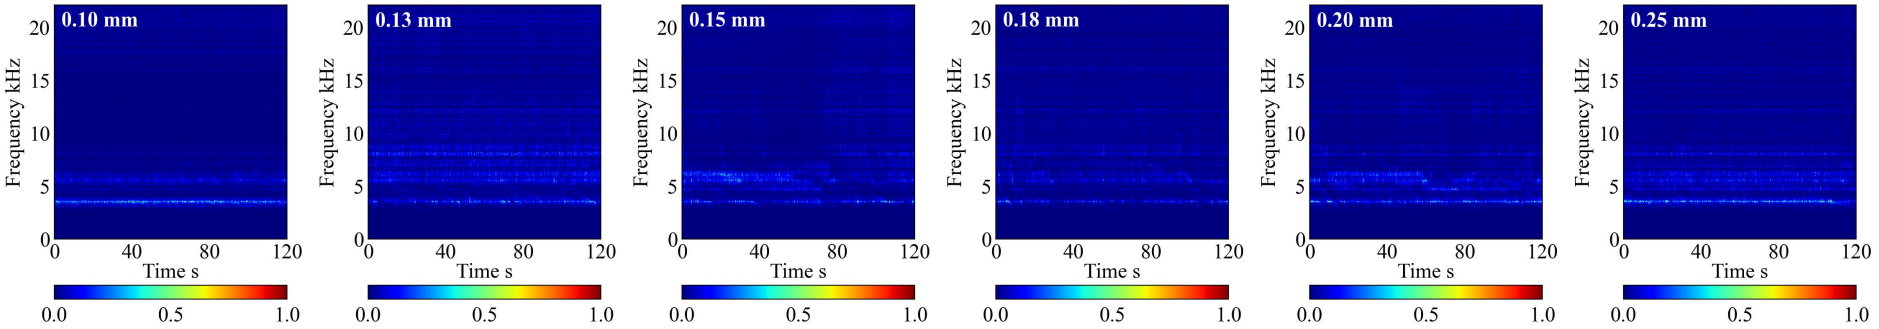


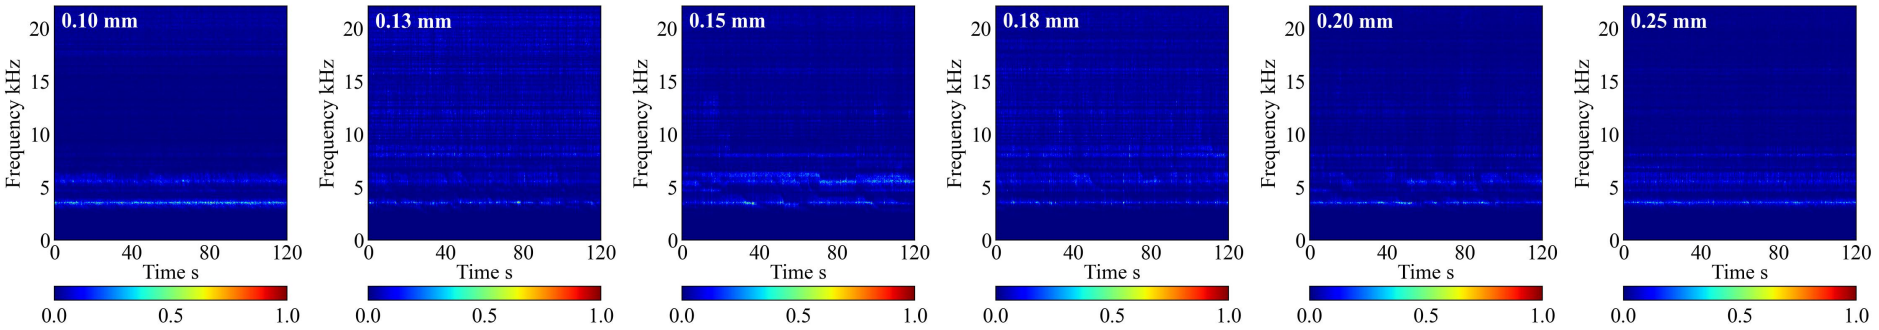
Fig. 2.3.1 Time-frequency analysis results of the purely harmonic signal of s(t) = cos(20000 π t) using STFT, CWT, and SWT.

2.4　実験データの解析結果

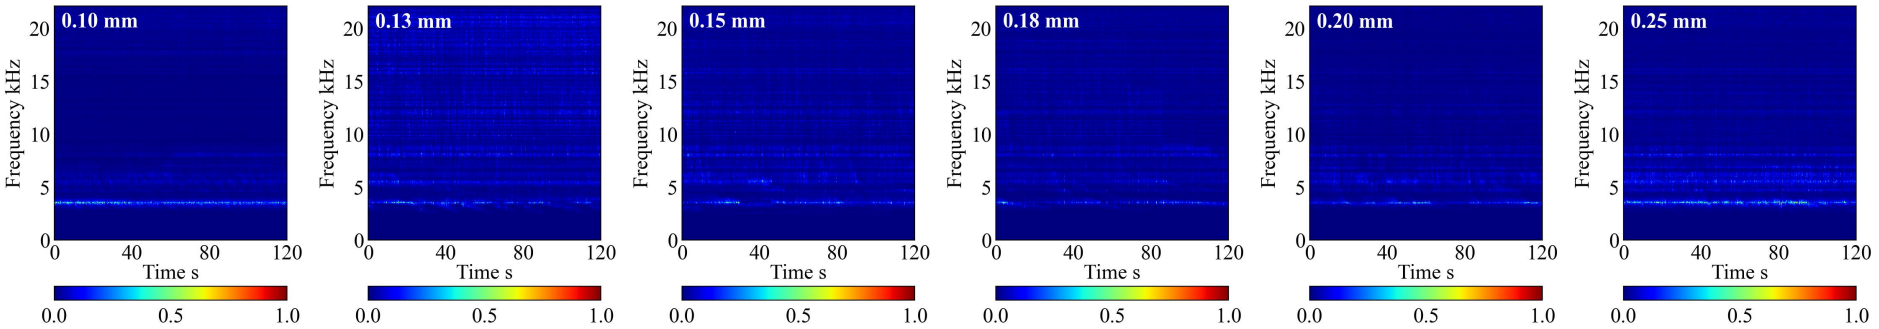
本節では，基本的な時間-周波数解析手法である STFT を用いて TFR を生成し，取得した音響データの解析を行う．解析用スペクトログラムの生成にあたっては，時間分解能と周波数分解能のバランスを考慮し，フレーム長を 1024 点，シフト幅を 256 点に設定した．気液二相噴流音については，測定系由来の低周波ノイズの影響を低減するため，時間-周波数変換に先立ち，カットオフ周波数 3 kHz のハイパスフィルタを適用した．一方，管内流動音については，低周波帯域に顕著な機械的ノイズが認められなかったことから，ハイパス処理は行わず，取得信号をそのまま解析に用いた．解析対象とする時間データ長は，気泡噴流音については 2 分間，管内流動音については 1 分間とした．上記の手順で作成したスペクトログラムを Fig.2.4.1，Fig.2.4.2 に示す．



(a) 0.5 MPa



(b) 0.6 MPa



(c) 0.7 MPa

Fig. 2.4.1 圧力条件ごとの孔径別スペクトログラム（左から 0.10, 0.13, 0.15, 0.18, 0.20, 0.25 mm）

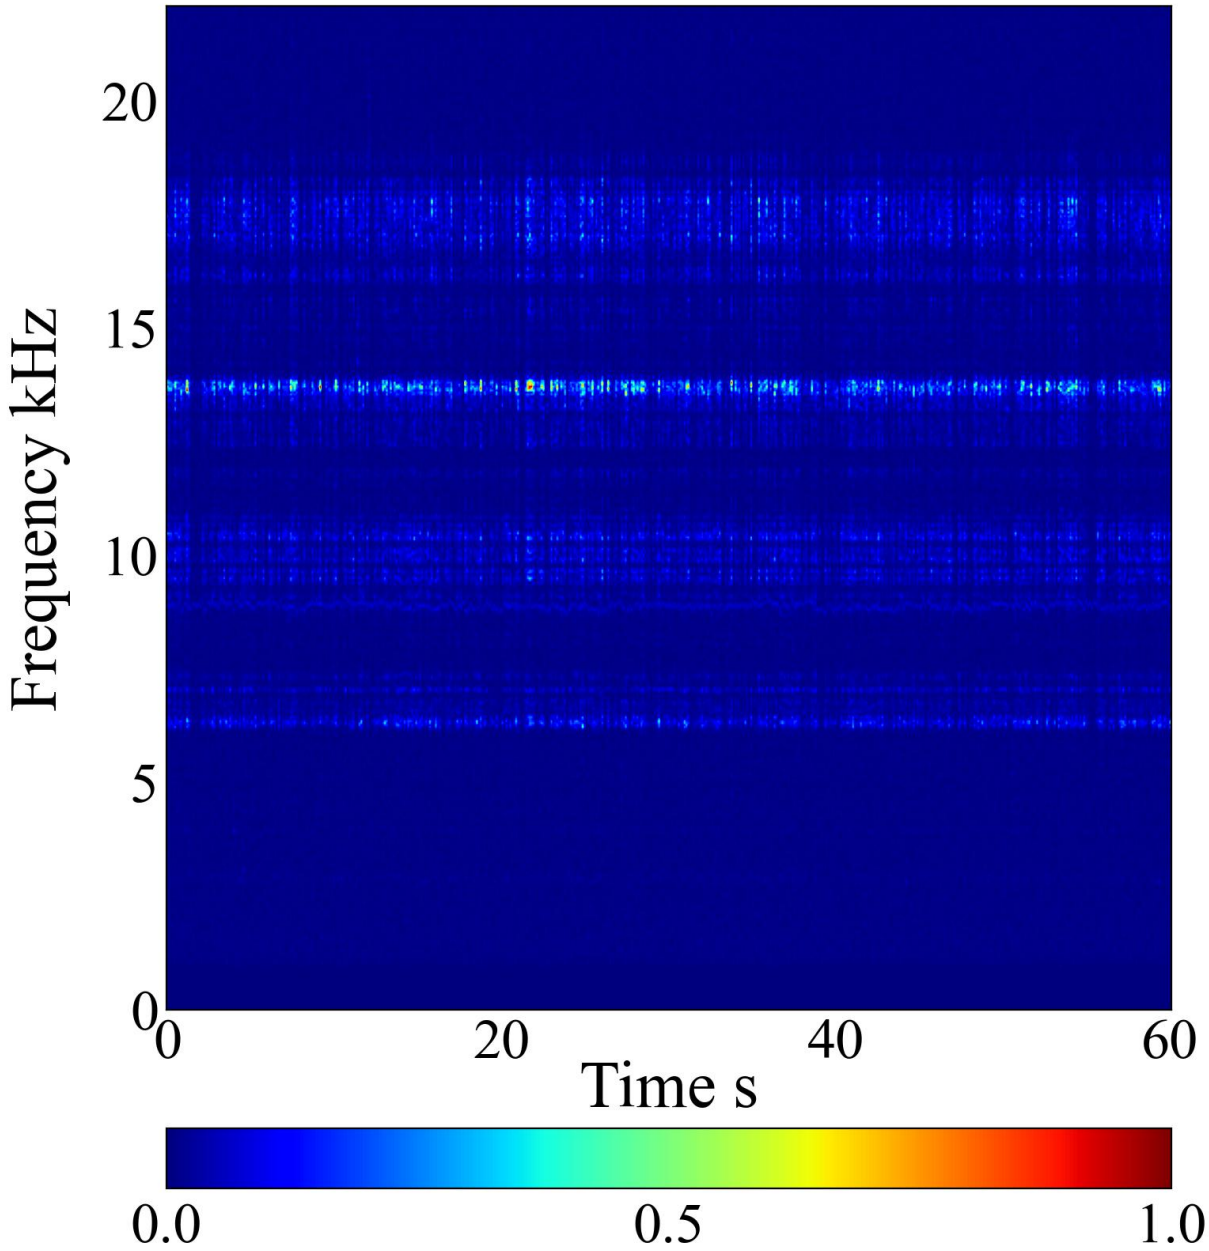


Fig. 2.4.2 STFT of pipe flow.

本実験における気液二相噴流音，水流動音の特徴周波数帯は，3000 Hz 〜 20000 Hz であることが分かる．これは先行研究の結果 [20] と一致する．これを踏まえ，データセットを作成する．

第 3 章

深層学習

3.1 データセット構築手法

3.1.1 信号対ノイズ比 (SNR) に基づく TFR の作成

SFR の SG 内は水流動音や沸騰音が支配的なノイズ環境下であり, SG 伝熱管破損時に発生する異常音にはバックグラウンドノイズが重畳する [29]. そのため, 本研究では SNR に基づいて, 次式により増幅したホワイトノイズおよび管内流動音を気液二相噴流音 (異常音) に重畳させることで，ノイズ環境下で発生する気液二相噴流音を再現する．

$$s'_{\mathrm{J}}(t) = s_{\mathrm{J}}(t) + \alpha\, s_{\mathrm{W}}(t) \tag{3.1.1}$$

ここで，$s_{\mathrm{W}}(t)$ はノイズの時間信号，$s'_{\mathrm{J}}(t)$ は気液二相噴流音の時間信号， α は水流動音の増幅分を表す係数である．また，次式の SNR を満たすように α は決定される．

$$\mathrm{SNR} = 10\log_{10}\left(\frac{P_{\mathrm{signal}}}{\alpha^2\, P_{\mathrm{noise}}}\right) \tag{3.1.2}$$

ここで，P_{noise} はバックグラウンドノイズ (ホワイトノイズ，水流動音) の時間平均強度，P_{signal} は着目信号 (気液二相噴流音) の強度である．ホワイトノイズは，Python 上で生成した疑似乱数に基づくガウス性白色雑音を気泡噴流音に加算することで付加した．管内流動音ノイズの付加においては，2 分間の気泡噴流音データを 1 分間ずつに分割し，各区間に対して 1 分間の管内流動音を加算することでノイズを重畳した．この処理により，ノイズ環境が時間的に不連続とならないよう配慮した．本研究では，SNR = 0, -4, -8, -12, -16, -20 dB の計 6 条件の学習データを作成した．

3.2 深層学習のモデル構築

本節では，2 次元特徴量を扱う CNN の構築方法について述べる．まず CNN の構成を説明し, 次に最適化手法やエポック数, 特徴量のデータ数について示す．なお，本研究のモデル構築及び最適化は TensorFlow のライブラリである Keras を用いて行っており, 各プログラム・ライブラリのバージョンは次表の通りである．

Table 3.2.1 Library names and versions.

ライブラリ	バージョン
Python	3.9.18
Keras	2.9.0
Liblosa	0.10.1
Matplotlib	3.7.2
NumPy	1.26.1
OpenCV	4.8.1.78
scikit-learn	1.3.0
seaborn	0.13.0
TensorFlow	2.9.1

3.2.1 活性化関数

活性化関数とは，ニューラルネットワークのニューロンにおいて，入力信号の総和から出力を決定するための関数である．本研究では，ReLU 関数，Softmax 関数，Linear 関数を用いた．

ReLU 関数

ReLU 関数は次のように与えられる．

$$f(x_i) = \begin{cases} x_i \ (0 \leq x_i) \\ 0 \ (0 \geq x_i) \end{cases} \tag{3.2.1}$$

Softmax 関数

Softmax 関数は次のように定義されている．

$$f(x_i) = \frac{e^{x_i}}{\sum_j^n e^{x_j}} \tag{3.2.2}$$

Linear 関数

Linear 関数は次のように定義されている．

$$f(x_i) = x_i \tag{3.2.3}$$

3.2.2 最適化手法

今回使用した CNN モデルのいずれも最適化には Adam を用いた．Adam による更新は次式で行われる．

$$w_{ij} \leftarrow wij - \alpha \frac{\hat{m}_{ij}}{\sqrt{\hat{v}_{ij}} + \epsilon} \tag{3.2.4}$$

ここで，w_{ij} は重み行列，α は学習率，ϵ は分母が 0 にならないように含めた微小項である．また，$\hat{m}_{ij}$，$\hat{v}_{ij}$ は

$$\hat{m}_{ij} = \frac{m}{1-\beta_1}\ ,\ \hat{v} = \frac{v}{1-\beta_2} \tag{3.2.5}$$

であり，m_{ij},v_{ij} は次式により表される．

$$m_{ij} \leftarrow \beta_1 m + (1-\beta_1)\frac{\partial L}{\partial w_{ij}} \tag{3.2.6}$$

$$v_{ij} \leftarrow \beta_2 m + (1-\beta_2)\left(\frac{\partial L}{\partial w_{ij}}\right)^2 \tag{3.2.7}$$

ここで, β_1 , β_2 は移動平均の減衰率であり, L は損失関数である．また, m_{ij} は誤差関数の勾配の移動平均を表しており, v_{ij} は誤差関数の勾配の 2 乗の移動平均を表している．誤差関数とは，正解データと出力された予想データの誤差を評価する関数である．本研究では，誤差関数は，平均二乗誤差 (MAE:Mean Squared Error) とを用いた．

$$\mathrm{MSE} = \frac{1}{N}\sum_{k=1}^{N}(t_k - \hat{y}_k)^2 \tag{3.2.8}$$

ここで，n は出力層のノード数，t_k は出力の真値，y_k は深層学習モデルの予測値である．評価関数とは，学習が終わったモデルの性能を測定するための関数である．本実験では，平均絶対誤差 (MAE:Mean Absolute Error)，決定係数を用いた．平均絶対誤差は，次式により表される．

$$\mathrm{MAE} = \frac{1}{n}\sum_{k=1}^{n} \mid t_k - y_k \mid \tag{3.2.9}$$

決定係数は，次式により表される．

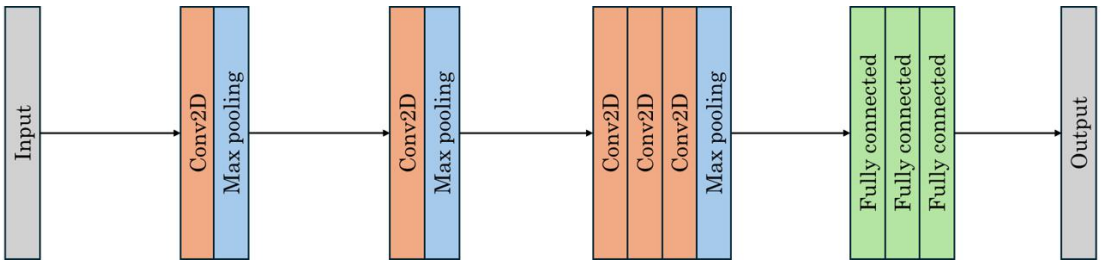
$$\mathrm{R}^2 = 1 - \sum_{k=1}^{n} \frac{(t_k - y_k)^2}{(t_k - \bar{y})^2} \tag{3.2.10}$$

ここで，$\bar{y}$ はデータ全体の平均値である．決定係数 R^2 は回帰モデルの性能評価に広く用いられており，工学分野の振動解析や状態監視においても重要な指標とされている。例えば，ベアリングの劣化評価における振動信号解析では，$R^2 < 0.8$ の回帰結果は当てはまりが不十分として解析対象から除外されている [30]．また，一般的な工学回帰モデルの評価においても，$R^2 > 0.8$ は予測値と実測値が良好に一致している状態（close agreement）を示す目安として扱われている [31]．さらに，機械学習を用いた状態監視・異常検知分野においても，$R^2 > 0.8$ を良好から優れた予測性能と評価する報告がある [32]．

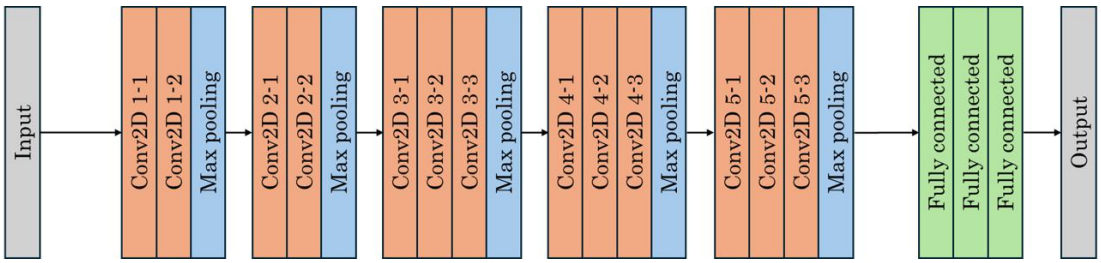
3.2.3　モデル構造

Fig. 3.2.1 に深層学習で用いた CNN モデルを示す．本研究では，AlexNet[13], VGG16[33], ResNet18[34]，ResNet50[34] の 4 種類を用いた．本研究では回帰分析を対象としたため，全結合層の出力を 1 とした．また，学習率は Table3.2.2 のように定めた．また，いずれもバッチサイズは 32，エポック数は 1000 である．なお，Early Stopping を採用し，本研究では 100 エポックの間損失関数の値に改善が見られない場合はその時点で学習を終了し，損失関数が最も低い値を示したエポックでのモデルを保存し，検証に用いた．

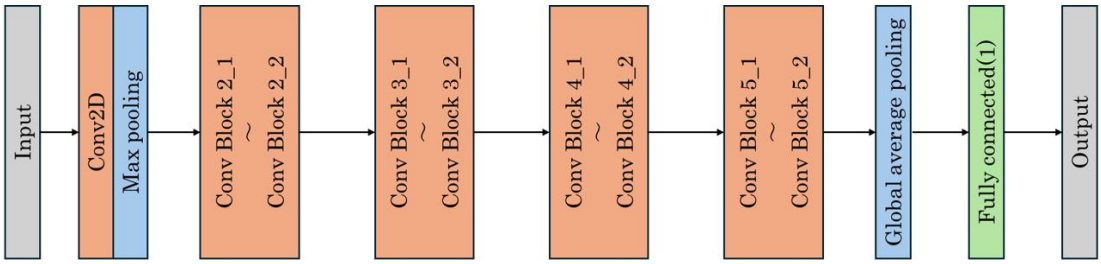
(a) AlexNet



(b) VGG16



(c) ResNet18



(d) ResNet50

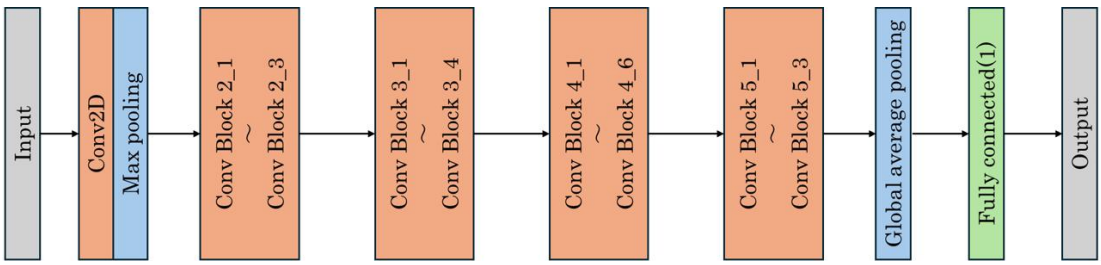


Fig. 3.2.1 Schematic diagrams of typical CNNs: (a) AlexNet, (b) VGG16, (c) ResNet18, and (d) ResNet50.

Table 3.2.2 Learning rates of CNNs.

モデル名	学習率
AlexNet	0.00005
VGG16	0.0001
ResNet18	0.001
ResNet50	0.001

3.3 データセット・ハイパーパラメータの設定

3.3.1 6 孔径の回帰分析におけるデータセット

本項では，6 孔径の回帰分析に用いるデータセットの作成方法について記述する．なお，STFT のパラメータとして，フレーム長を 1161 点，シフト幅を 22 点とした．

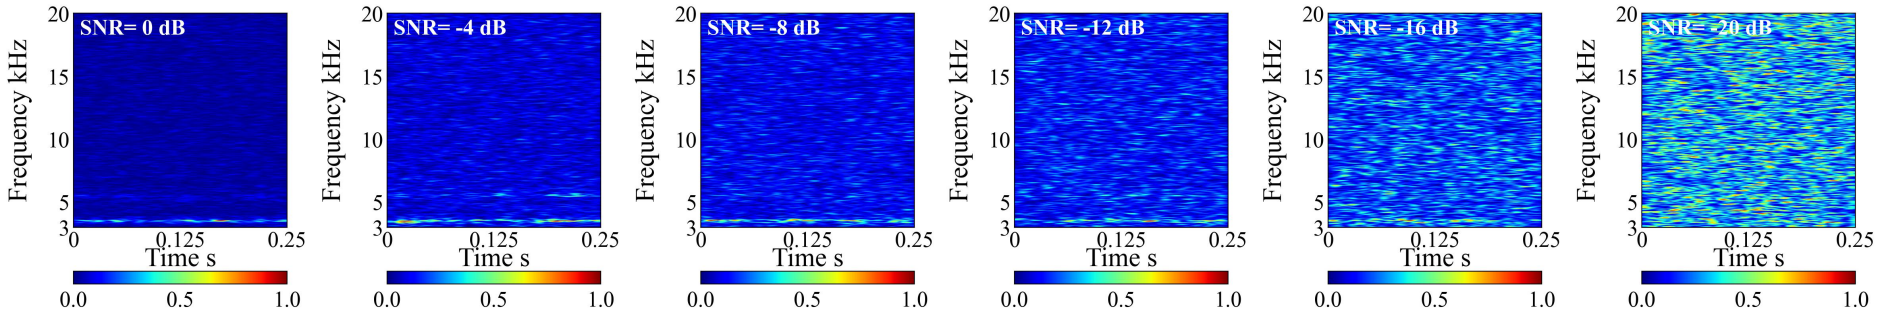
1. カットオフ周波数が 3000 Hz のハイパスフィルタにより，低周波数帯のノイズを除去する．
2. 式 (3.1.1) により，増幅したノイズ音（水流動音またはホワイトノイズ）を各々の気液二相噴流音に重畳させる．
3. ノイズ音が重畳された気液二相噴流音を 0.25 s ごとに等分割し，各孔径に対して 2400 個のセグメントを作成する．
4. 手順 3 により得られた計 14400 個のセグメントに対して，STFT を適用する．
5. 各信号強度分布を最大値で正規化した後，機械学習の前処理として，生成した TFR のサイズを縦 224 ピクセル，横 224 ピクセルにリサイズする．

上記の手順で作成したホワイトノイズを重畳した TFR と水流動音を重畳した TFR の例を Fig. 3.3.1 に示す．これらの図から，ノイズが増幅するほど 3000 Hz 付近の気液二相噴流音の信号強度が相対的に減衰している．また，水流動音を重畳したスペクトログラムにおいては，水流動音 (Fig. 2.4.2) の信号強度分布が，ホワイトノイズを重畳したスペクトログラムにおいては，全帯域に渡る信号強度分布が確認できる．

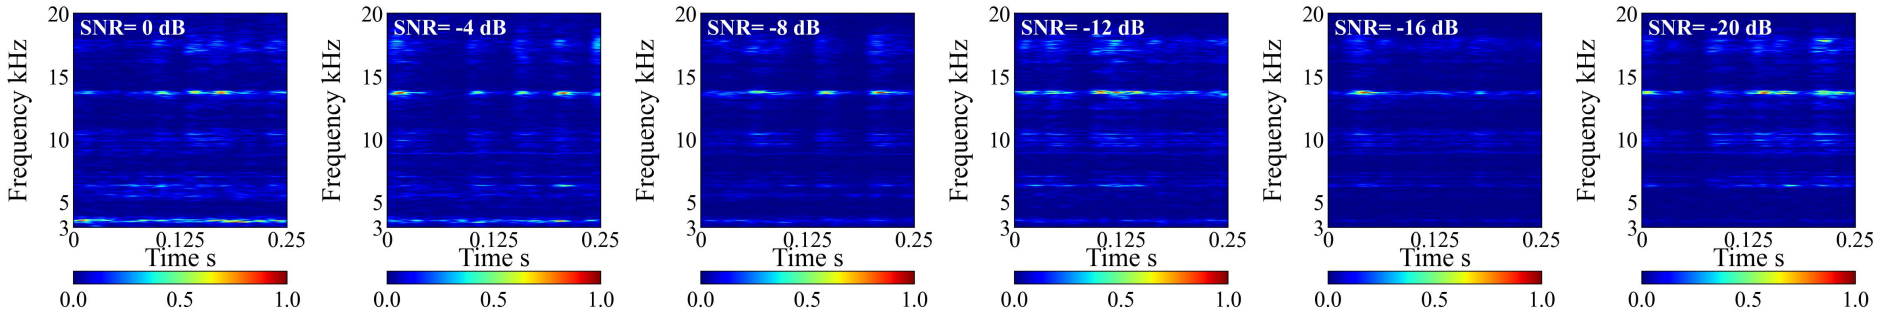
3.3.2 6 孔径 + バックグラウンドノイズの回帰分析におけるデータセット

本項では，6 孔径 + バックグラウンドノイズの回帰分析に用いるデータセットの作成方法について記述する．なお，STFT のパラメータとして，フレーム長 512 点，シフト幅を 16 点とし，CWT のパラメータとして，帯域幅変数 f_b を 3.0，中心周波数変数 f_c を 1.0 とした．

1. カットオフ周波数が 3000 Hz のハイパスフィルタにより，低周波数帯のノイズを除去する．
2. 60 s のノイズ音（水流動音またはホワイトノイズ）を 0.10 s ごとに等分割し，600 個のセグメントを作成する．
3. 式 (3.1.1) により，増幅したノイズ音（水流動音またはホワイトノイズ）を各々の気液



(a) white noise



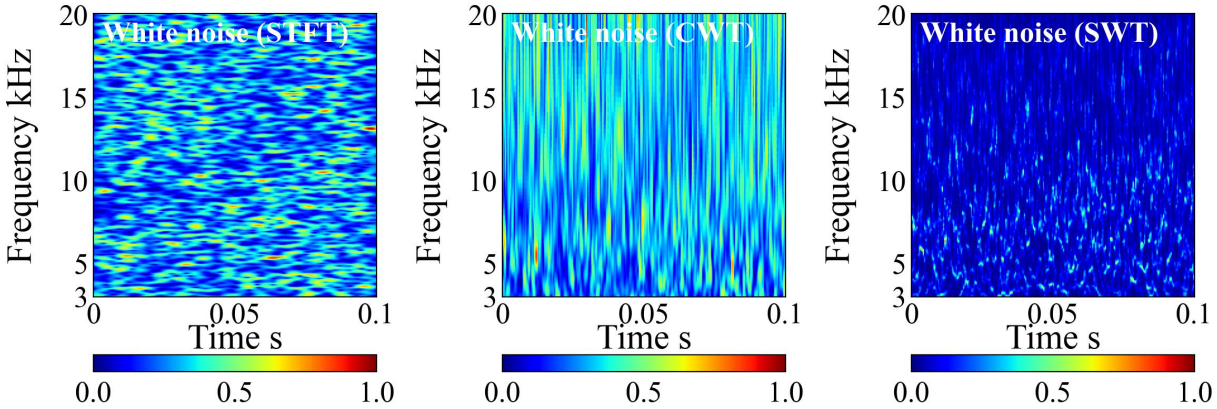
(b) flow noise

Fig. 3.3.1 0.5 MPa，0.1 mm の気泡噴流音にノイズを重畳したスペクトログラム（左から 0, -4, -8, -12, -16, -20 dB）

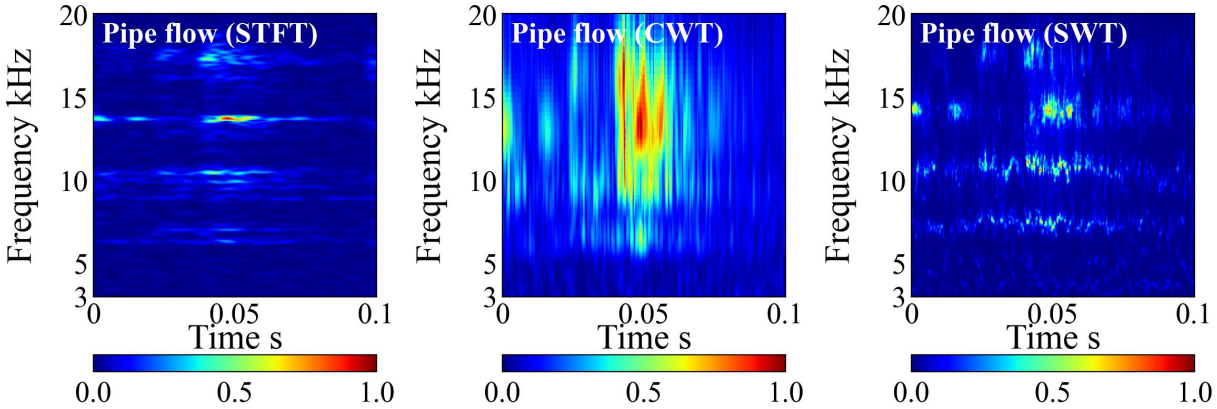
二相噴流音に重畳させる．

4. ノイズ音が重畳された気液二相噴流音を 0.10 s ごとに等分割し，各孔径に対して 2400 個のセグメントを作成し，600 個のセグメントを等間隔に抜き出す．
5. 手順 2，手順 3 により得られた計 4200 個のセグメントに対して，STFT，CWT，SWT をそれぞれ適用する．
6. 各信号強度分布を最大値で正規化した後，機械学習の前処理として，生成した TFR のサイズを縦 224 ピクセル，横 224 ピクセルにリサイズする．

上記の手順で作成したホワイトノイズを重畳した TFR と水流動音を重畳した TFR の例を Fig. 3.3.2 〜 Fig. 3.3.4 に，ホワイトノイズ TFR と水流動音 TFR を Fig. 3.3.5 に示す．これらの図から，Fig. 3.3.1 と同様に，3000 Hz 付近の気泡二相噴流音の信号強度が減衰していることが確認できる．また，Fig.2.3.1 と同様に，CWT は STFT と比較して信号強度分布が周波数方向に広がっており，SWT は CWT の信号強度分布をより狭めたものであることが確認できる．

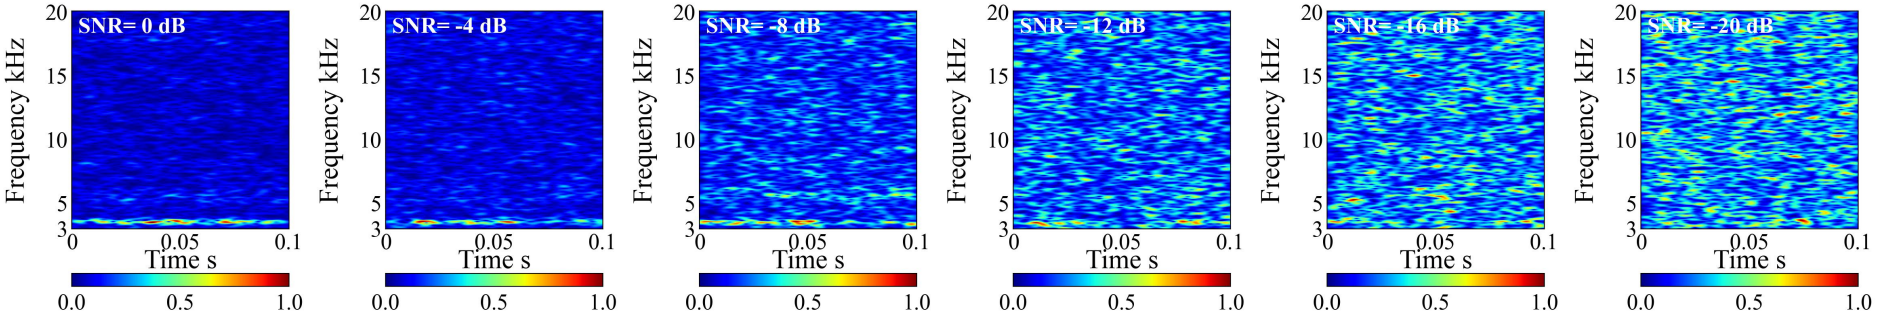


(a) white noise

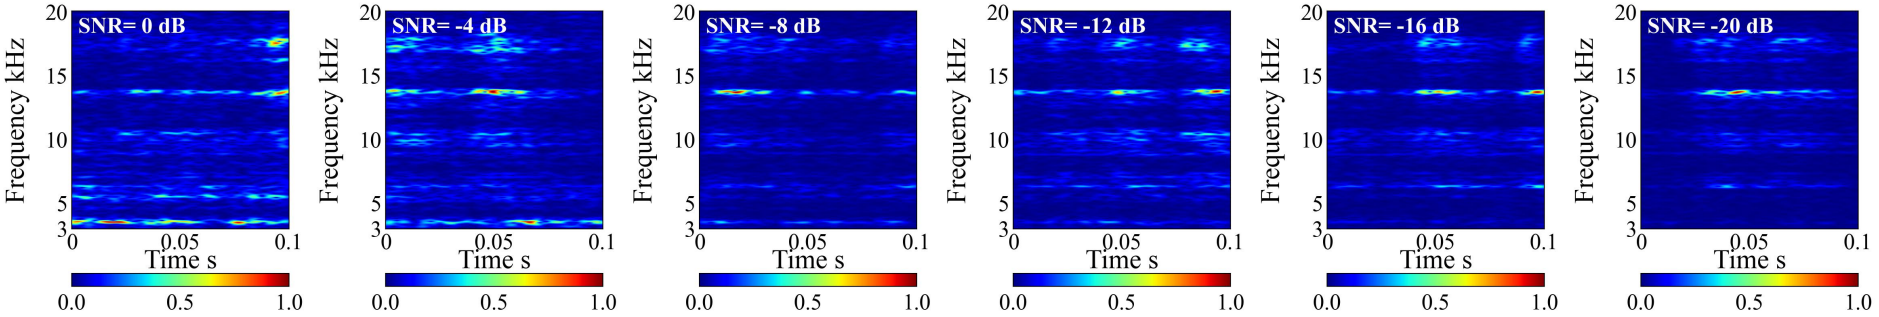


(b) pipe flow sound

Fig. 3.3.5 TFRs of background noise.

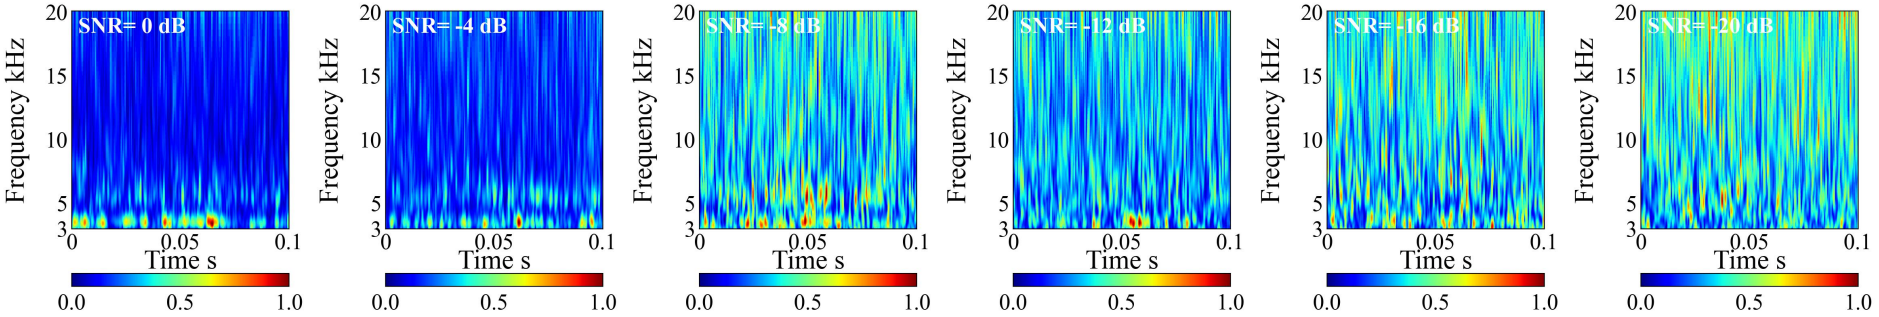


(a) white noise

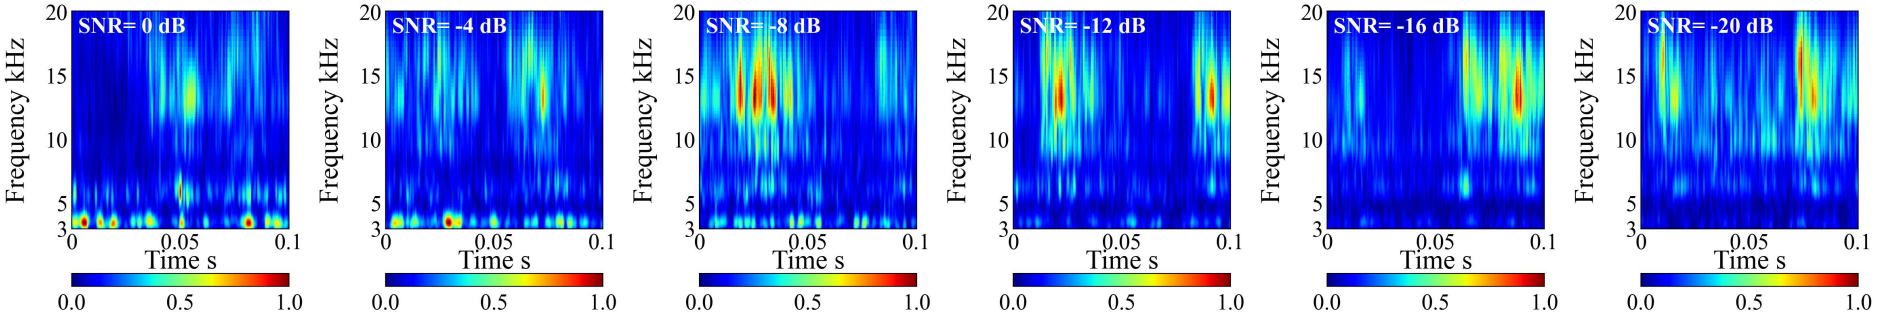


(b) flow noise

Fig. 3.3.2 0.5 MPa，0.1 mm の気泡噴流音にノイズを重畳したスペクトログラム（STFT）

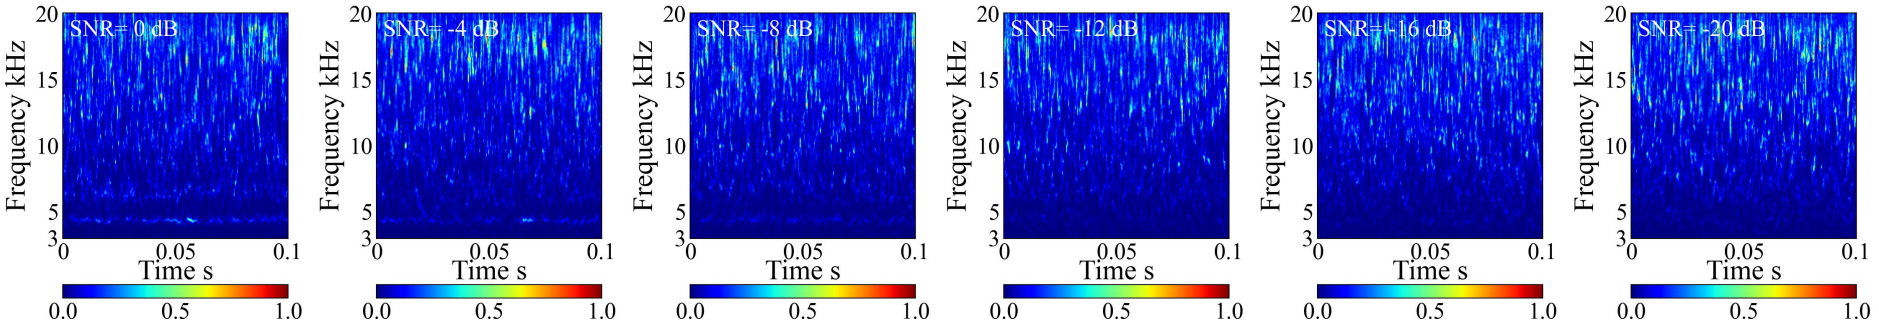


(a) white noise

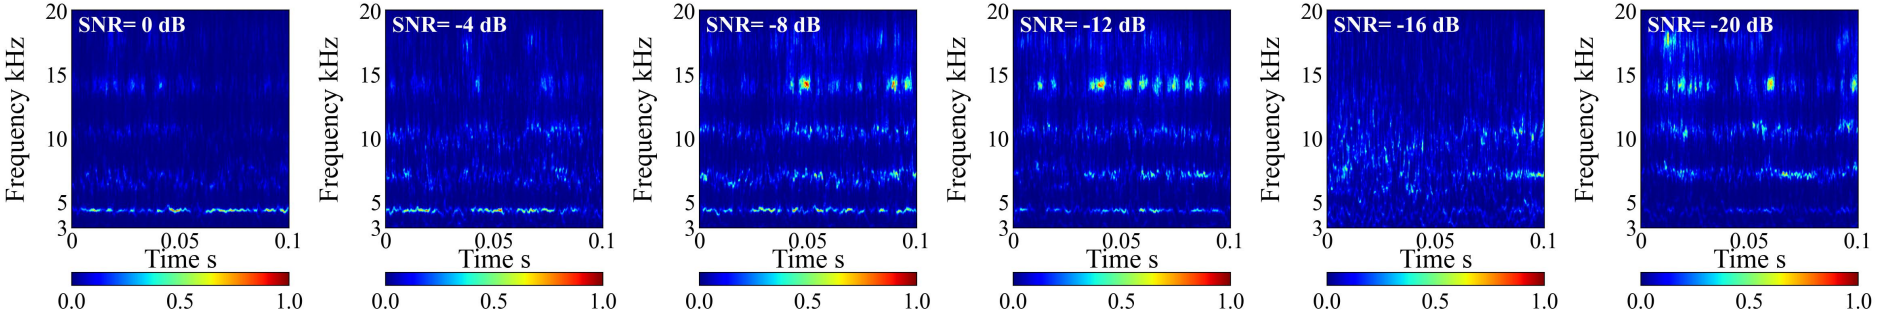


(b) flow noise

Fig. 3.3.3 0.5 MPa，0.1 mm の気泡噴流音にノイズを重畳したスペクトログラム（CWT）



(a) white noise



(b) flow noise

Fig. 3.3.4 0.5 MPa，0.1 mm の気泡噴流音にノイズを重畳したスペクトログラム（SWT）

3.3.3 k-分割交差検証

本研究では，k-分割交差検証を用いた．k-分割交差検証とは，深層学習に用いるデータを k 個に分割し，その中の 1 つをテストデータに用いるとき, k 個のデータ全てがテストデータとして 1 回ずつ用いられるように k 回深層学習のモデル構築を行って，性能の平均をとる手法である．今回は, Fig. 3.3.6 のように，訓練データ・検証データ・テストデータを 16:4:5 の割合とした．また，学習の偏りをなくすため，5 個に分割したデータには気泡噴流音 3 種類が全て均等に含まれるようにした．



Fig. 3.3.6 The method of cross validation.

第 4 章

学習結果と考察

4.1　6 孔径の回帰分析

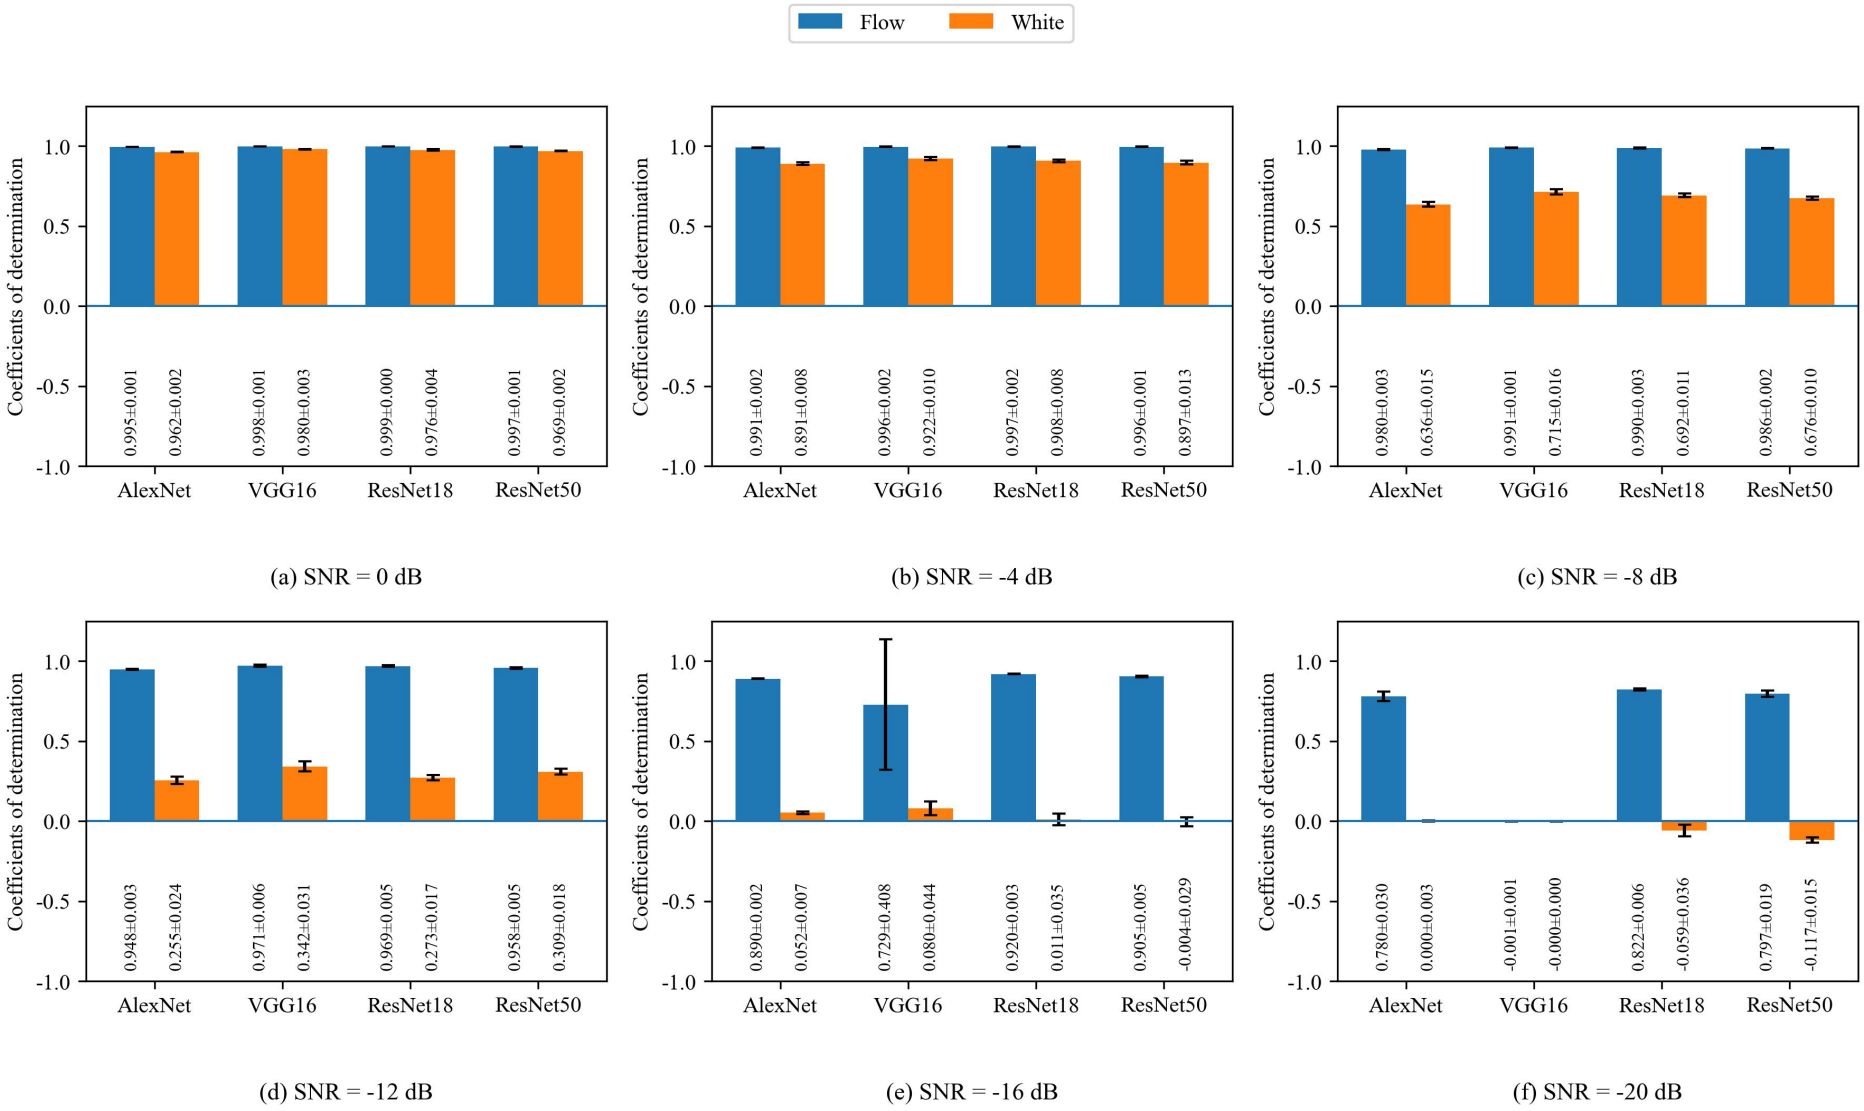
先に示した CNN モデルと TFR を用いた k-分割交差検証 (k=5) により決定係数で性能評価を行った結果の例を Fig. 4.1.1 に示す．棒グラフの値は平均値，エラーバーの値は標準偏差とした．

決定係数に着目すると，水流動音を重畳したスペクトログラムで構築したモデルは，SNR = − 12 dB 程度まで高い決定係数が維持された一方，ホワイトノイズを重畳したスペクトログラムで構築したモデルでは − 8 dB 付近から急激な性能劣化が生じた．また，モデル間の差異に関しては，AlexNet が比較的低い決定係数を示したこと以外に大きな違いは見られなかった．

4.2　6 孔径 + バックグラウンドノイズの回帰分析

先に示した CNN モデルと TFR を用いた k-分割交差検証 (k=5) により決定係数で性能評価を行った結果の例を Fig. 4.2.1，Fig. 4.2.2 に示す．棒グラフの値は平均値，エラーバーの値は標準偏差とした．

決定係数に着目すると，水流動音を重畳したスペクトログラムで構築したモデルは，三種の TFR のうち STFT が最も高い値を示した一方，ホワイトノイズを重畳したスペクトログラムで構築したモデルでは，SWT が最も高い値を示した．この差異は，各時間–周波数表現手法の特性と，重畳されたノイズの性質との関係に起因すると考えられる．水流動音は特定の周波数帯にエネルギーが集中し，時間的にも一定の構造を有する．このようなノイズ環境下では，時間および周波数分解能が一定で安定した表現を与える STFT によって，気液二相噴流音に由来する周波数帯域のエネルギー分布が比較的明瞭に保持されるため，CNN は水流動音を背景成分として学習しつつ，孔径に依存した特徴を安定的に抽出できたと考えられる．一方，ホワイトノイズは全周波数帯域に一様に分布し，時間的・周波数的に構造を持たない無



(a) SNR = 0 dB

(b) SNR = -4 dB

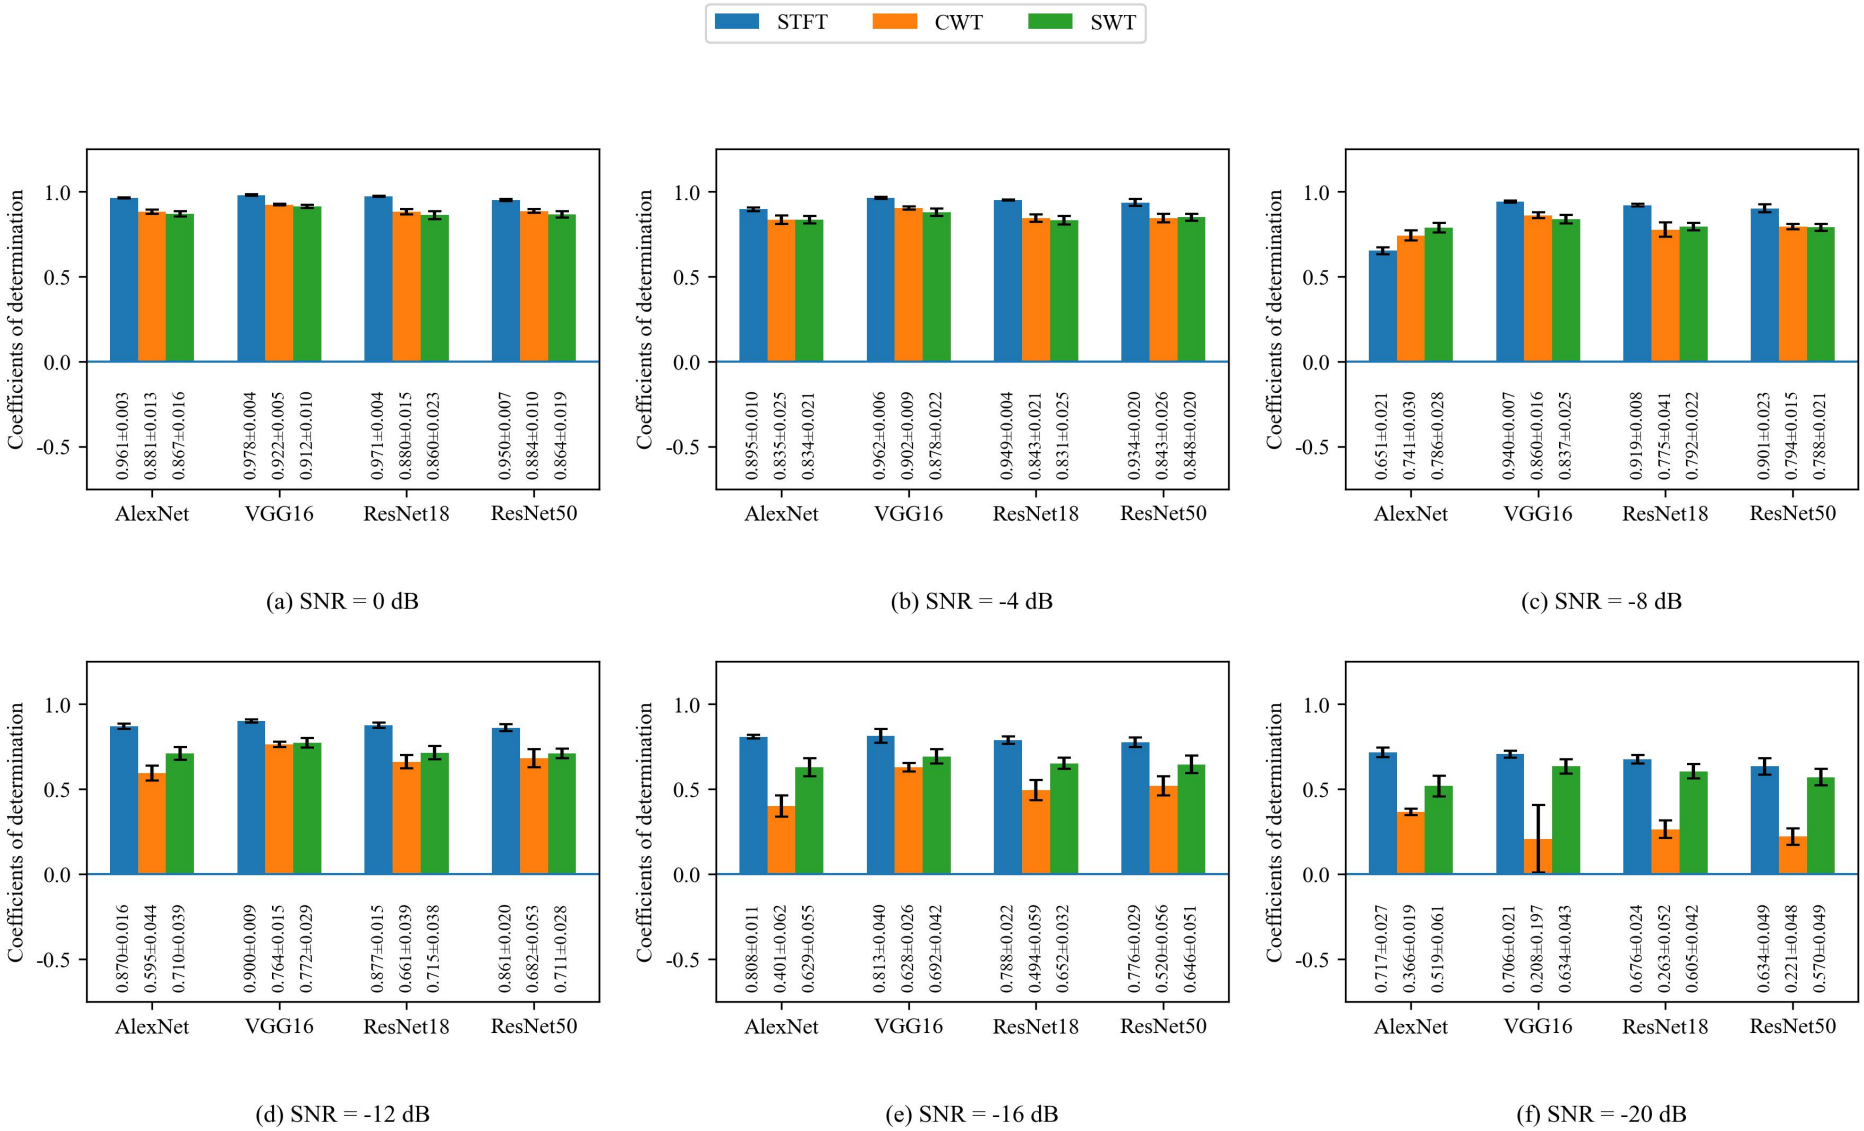
(c) SNR = -8 dB

(d) SNR = -12 dB

(e) SNR = -16 dB

(f) SNR = -20 dB

Fig. 4.1.1 Coefficients of determination (0.5MPa).



(a) SNR = 0 dB

(b) SNR = -4 dB

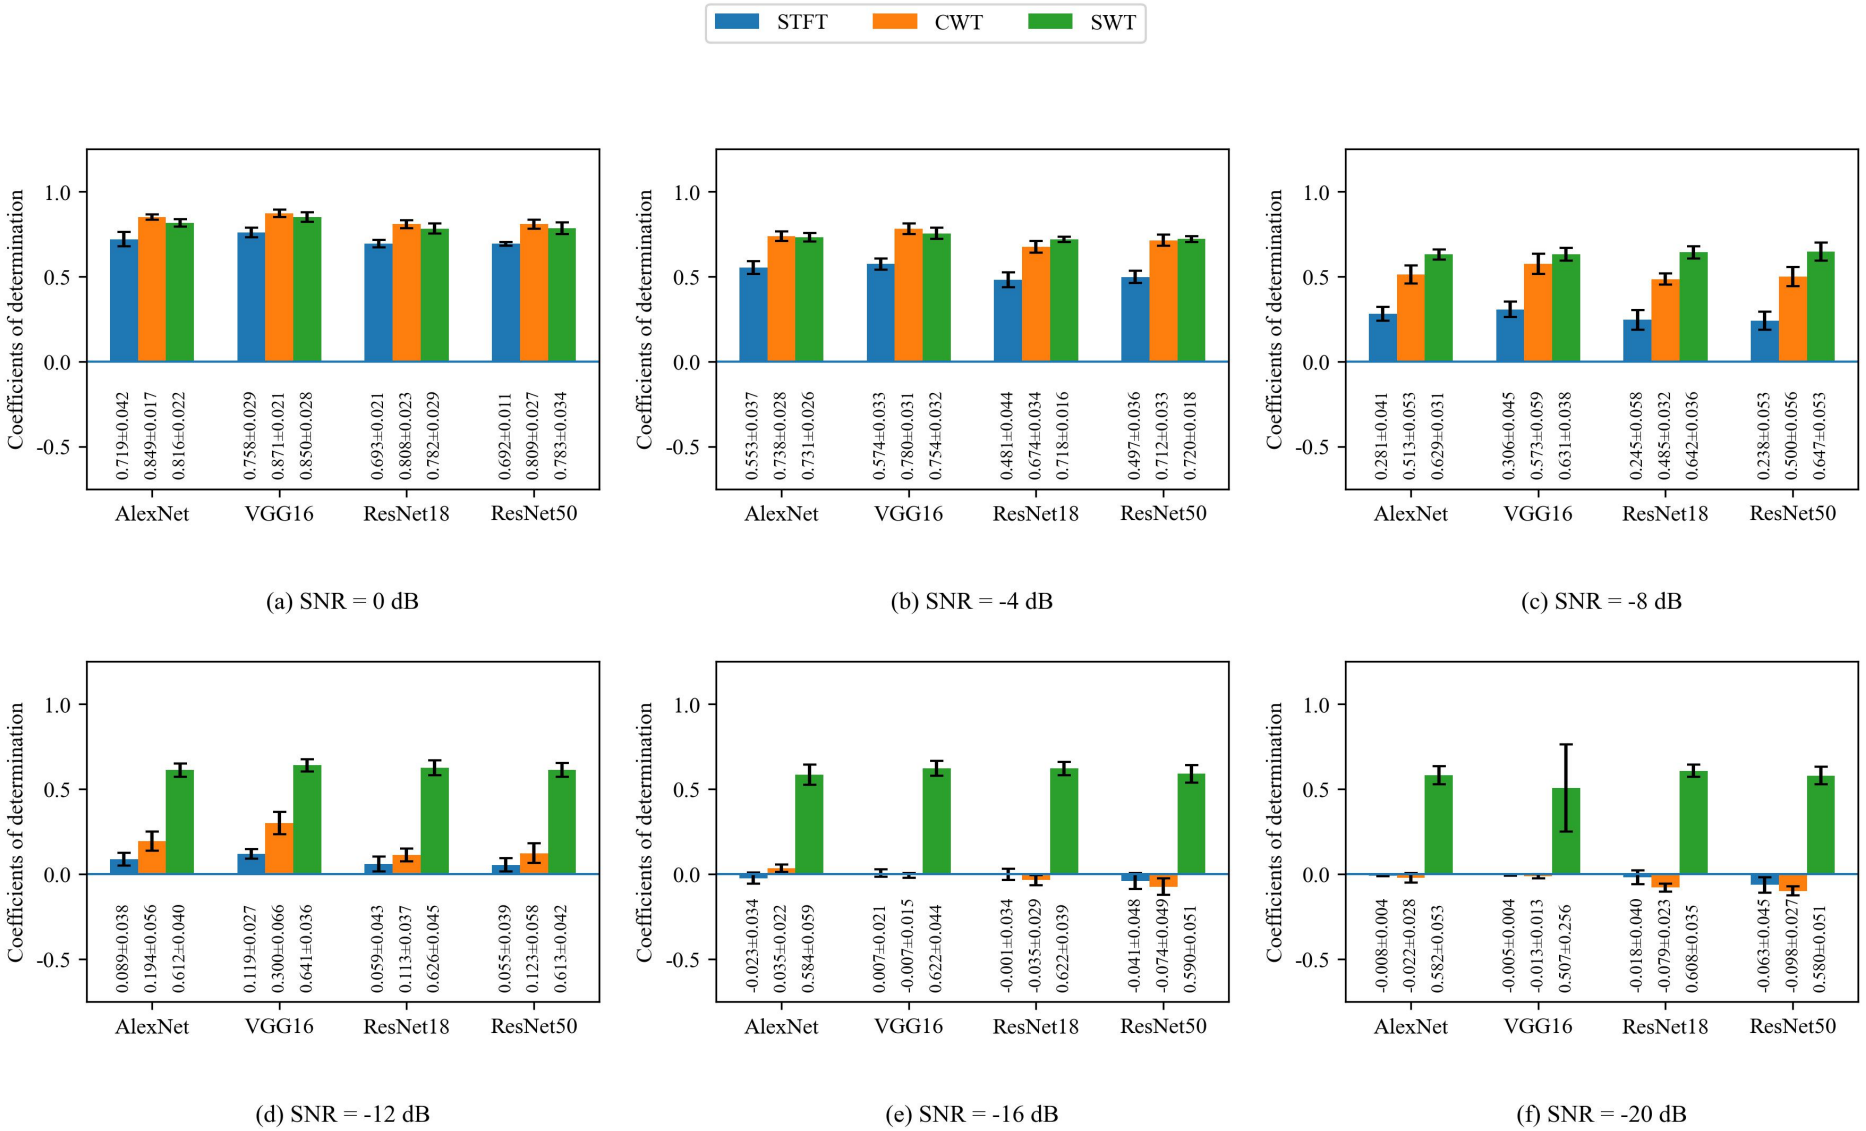
(c) SNR = -8 dB

(d) SNR = -12 dB

(e) SNR = -16 dB

(f) SNR = -20 dB

Fig. 4.2.1 Coefficients of determination in the case of pipe flow sound (0.5MPa).



(a) SNR = 0 dB

(b) SNR = -4 dB

(c) SNR = -8 dB

(d) SNR = -12 dB

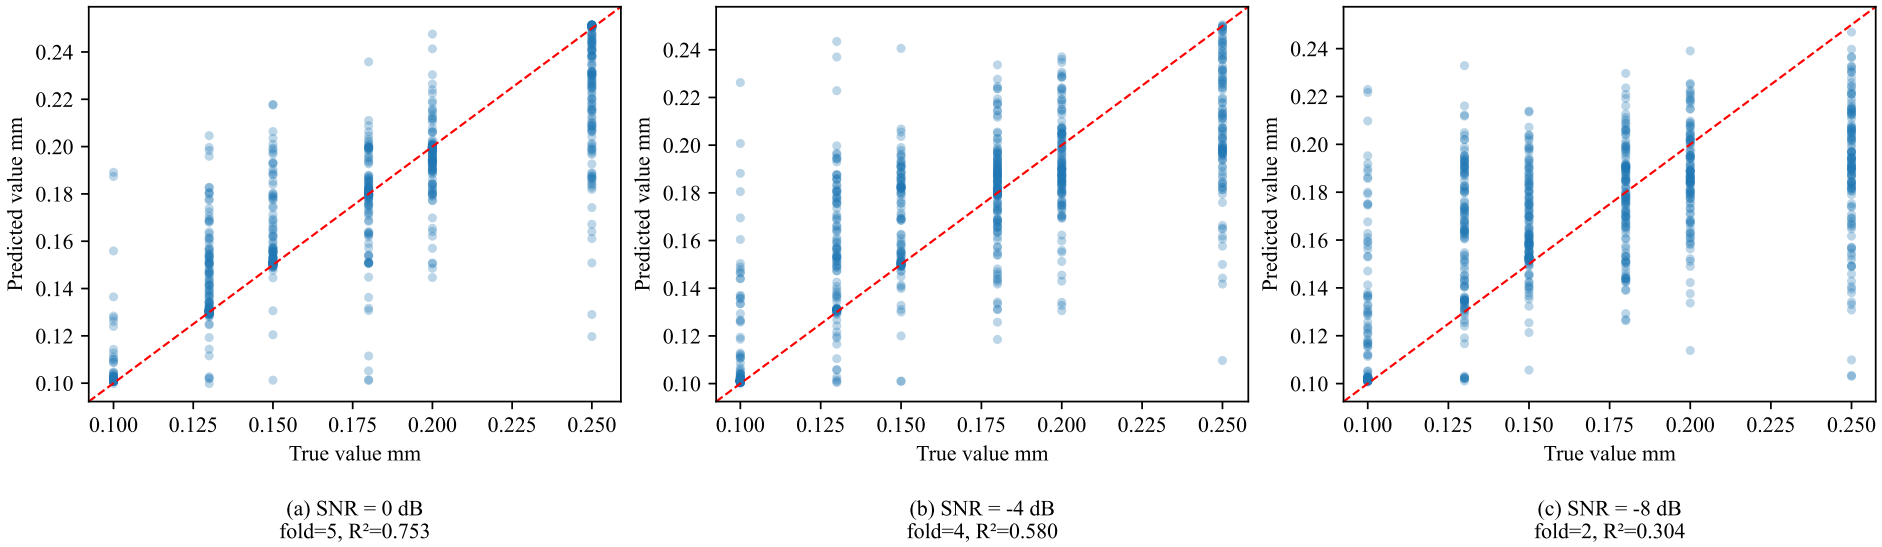
(e) SNR = -16 dB

(f) SNR = -20 dB

Fig. 4.2.2 Coefficients of determination in the case of white noise (0.5MPa).

相関な雑音である．SWT は，連続ウェーブレット変換で得られた時間–スケール表現を瞬時周波数に基づいて再配置することで，周波数方向に分散したエネルギーを集中させる特性を有するため，ホワイトノイズ環境下においても，気液二相噴流音に起因する局所的な周波数成分が相対的に強調され，低 SNR 条件下でも有効な特徴が保持されたと考えられる．モデル間の差異に関しては，0 〜 -12 dBd では，VGG16 がわずかに高い決定係数を示したこと以外に大きな違いは見られなかったものの，VGG16 は-16 dB で不安定な結果を示し，-20 dB で他モデルより低い決定係数を示した．これは，VGG16 の単純に層を積み重ねた構造によって勾配が消失し，学習が行えなかったと考えられる．また，0.5MPa における VGG16 の回帰分析の結果をプロットした図を Fig. 4.2.3 〜 4.2.8 に示す．なお，各 dB ごとに fold1 〜 5 の決定係数の平均を算出し，最も平均に近い決定係数を示した fold の散布図を記載した．

ホワイトノイズの場合，SNR 比が低下するに従ってすべてのラベルの予測値が同じ値を示す一方，水流動音ノイズの場合は SNR 比が低下するに従って，異常ありのラベルのみ予測値が正しい値を示した．この差異は，ホワイトノイズは全周波数帯域に一様なエネルギー分布を持つため，特徴的な周波数帯域を持たず，SNR 比が低下するに従って異常音とノイズの違いを識別できなくなる一方，水流動音は特定の周波数帯にエネルギーが集中し，時間的にも一定の構造を有するため，SNR 比が低下しても異常音とノイズの違いが学習されたためだと考える．



(a) SNR = 0 dB
fold=5, R^2=0.753

(b) SNR = -4 dB
fold=4, R^2=0.580

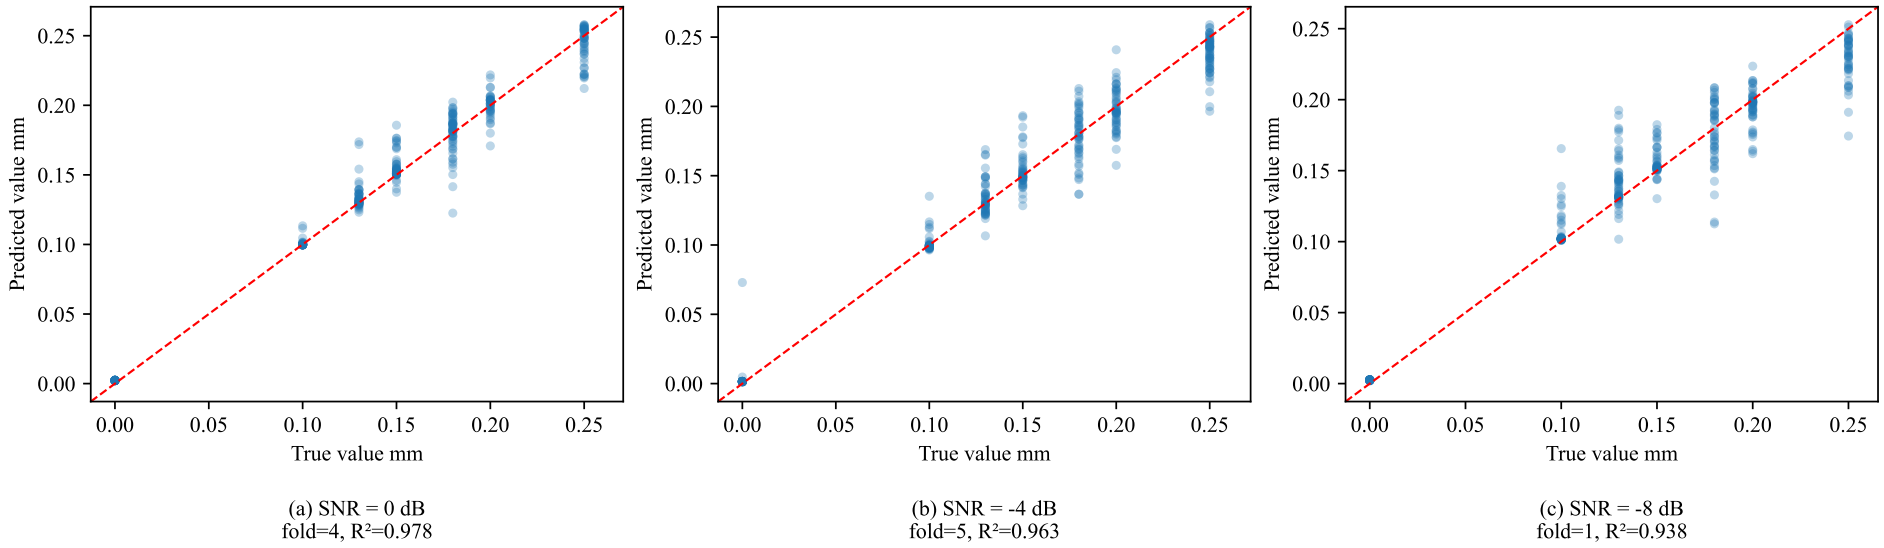
(c) SNR = -8 dB
fold=2, R^2=0.304

(d) SNR = -12 dB
fold=4, R^2=0.120

(e) SNR = -16 dB
fold=5, R^2=0.006

(f) SNR = -20 dB
fold=2, R^2=-0.006

Fig. 4.2.3 Results of regression analysis in the case of white noise (0.5MPa,STFT).



(a) SNR = 0 dB
fold=4, R^2=0.978

(b) SNR = -4 dB
fold=5, R^2=0.963

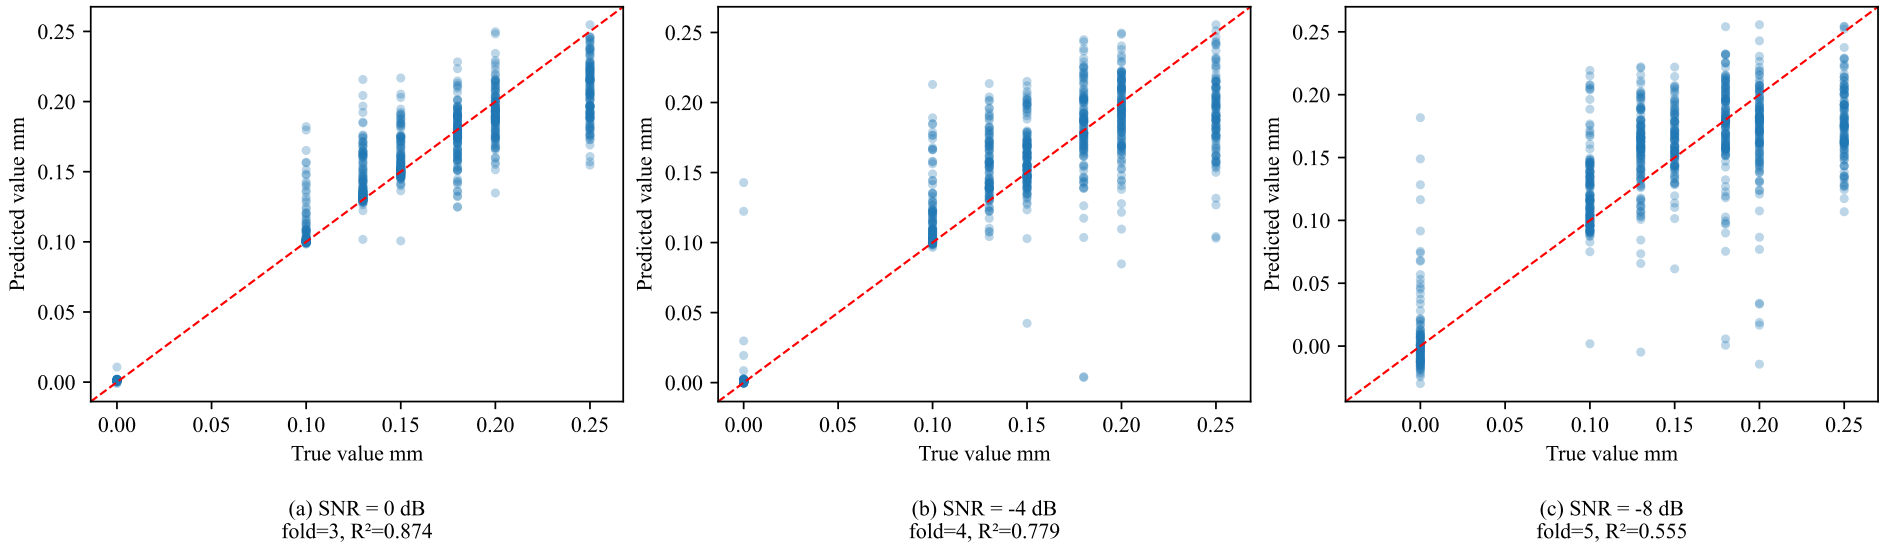
(c) SNR = -8 dB
fold=1, R^2=0.938

(d) SNR = -12 dB
fold=1, R^2=0.903

(e) SNR = -16 dB
fold=1, R^2=0.817

(f) SNR = -20 dB
fold=2, R^2=0.712

Fig. 4.2.4 Results of regression analysis in the case of pipe flow sound (0.5MPa,STFT).



(a) SNR = 0 dB
fold=3, R^2=0.874

(b) SNR = -4 dB
fold=4, R^2=0.779

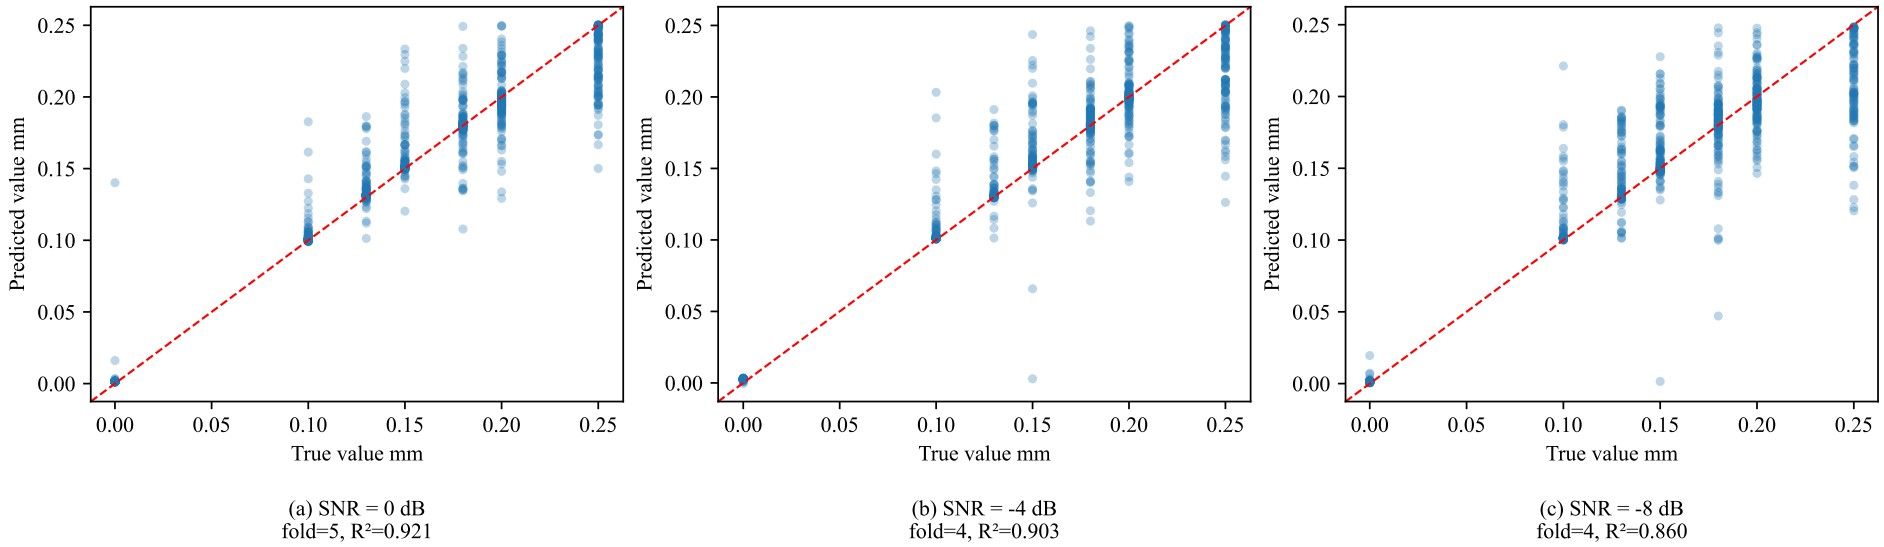
(c) SNR = -8 dB
fold=5, R^2=0.555

(d) SNR = -12 dB
fold=2, R^2=0.285

(e) SNR = -16 dB
fold=2, R^2=-0.007

(f) SNR = -20 dB
fold=2, R^2=-0.010

Fig. 4.2.5 Results of regression analysis in the case of white noise (0.5MPa,CWT).



(a) SNR = 0 dB
fold=5, R^2=0.921

(b) SNR = -4 dB
fold=4, R^2=0.903

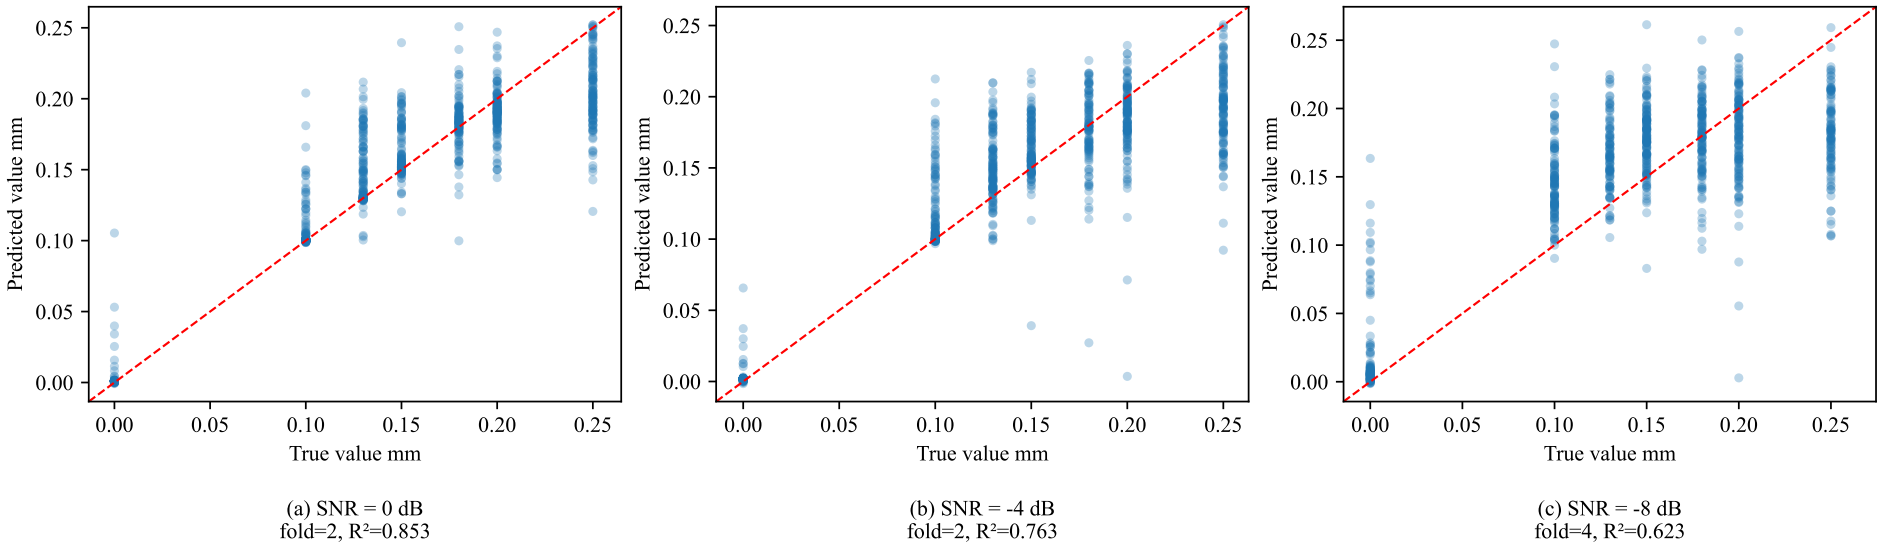
(c) SNR = -8 dB
fold=4, R^2=0.860

(d) SNR = -12 dB
fold=4, R^2=0.763

(e) SNR = -16 dB
fold=4, R^2=0.620

(f) SNR = -20 dB
fold=2, R^2=0.331

Fig. 4.2.6 Results of regression analysis in the case of pipe flow sound (0.5MPa,CWT).



(a) SNR = 0 dB
fold=2, R^2=0.853

(b) SNR = -4 dB
fold=2, R^2=0.763

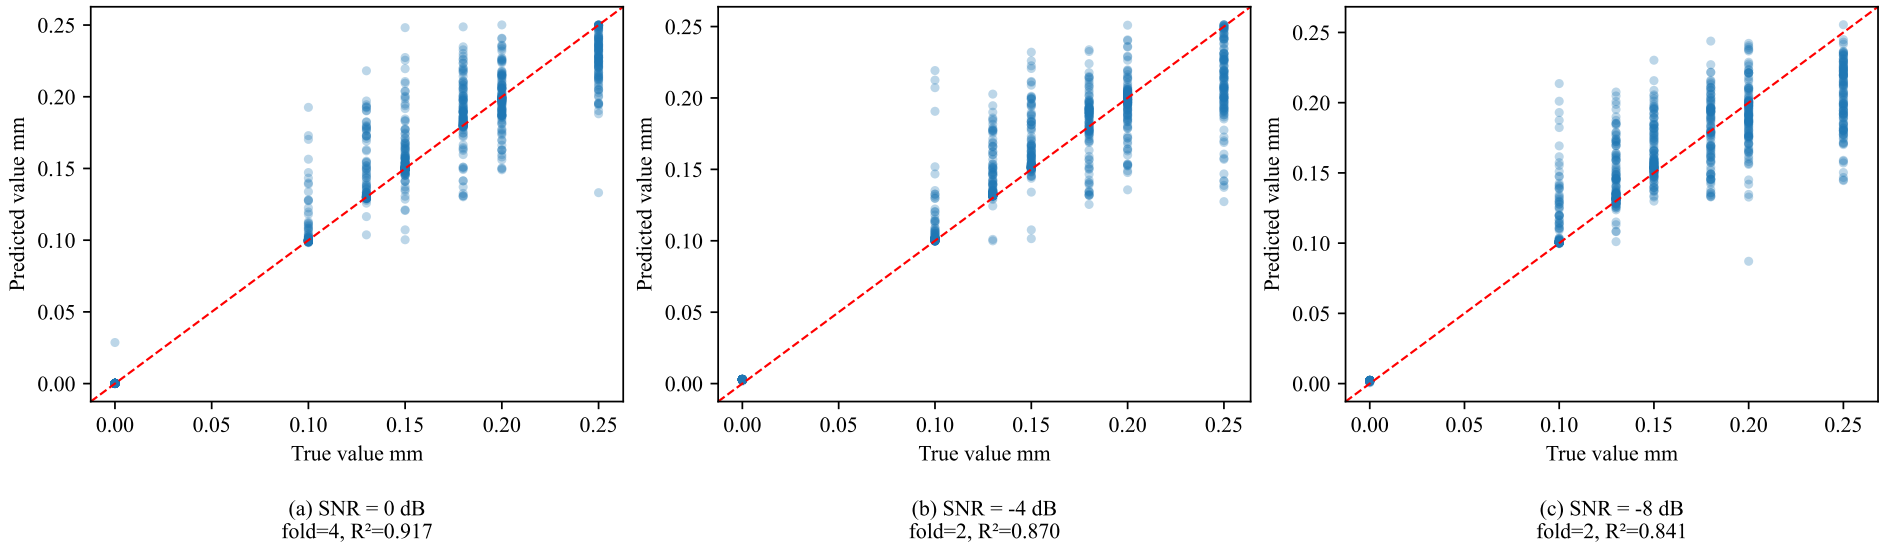
(c) SNR = -8 dB
fold=4, R^2=0.623

(d) SNR = -12 dB
fold=2, R^2=0.633

(e) SNR = -16 dB
fold=2, R^2=0.602

(f) SNR = -20 dB
fold=5, R^2=0.577

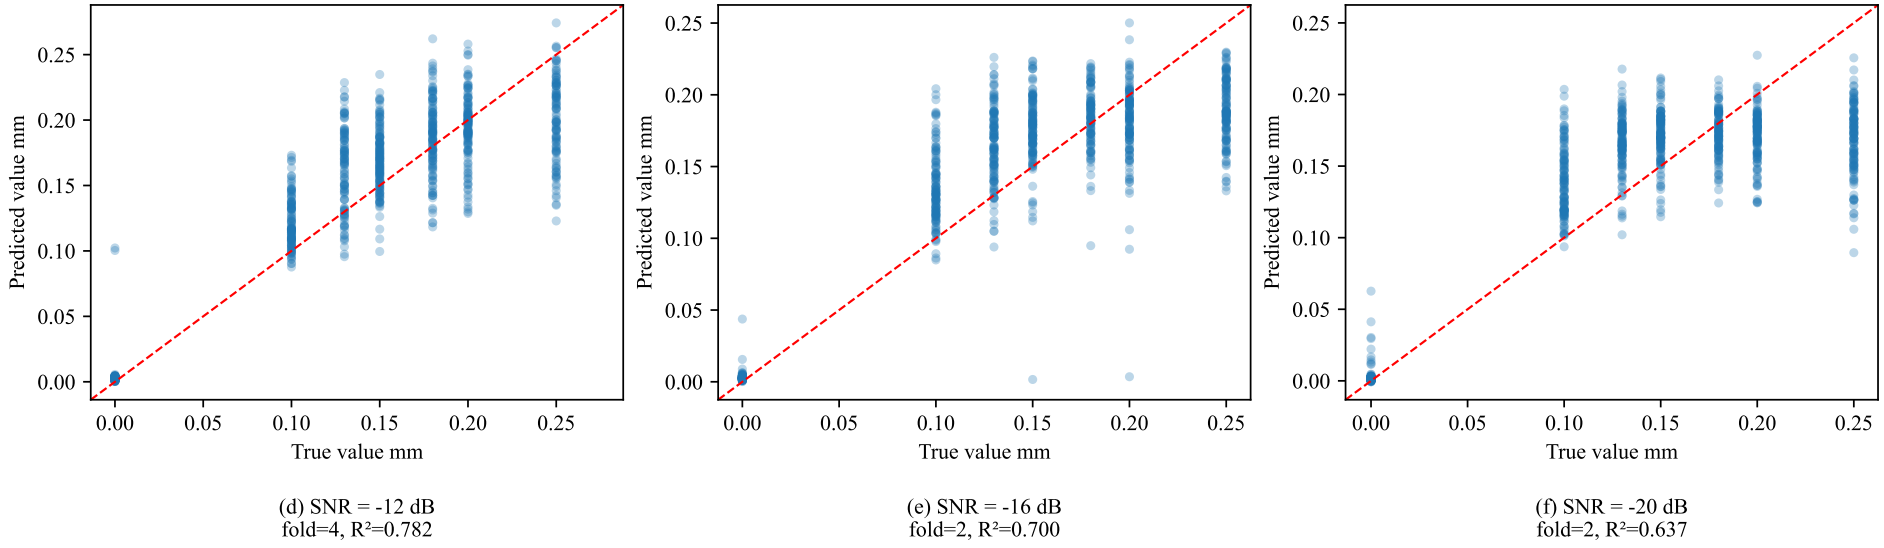
Fig. 4.2.7 Results of regression analysis in the case of white noise (0.5MPa,SWT).



(a) SNR = 0 dB
fold=4, R^2=0.917

(b) SNR = -4 dB
fold=2, R^2=0.870

(c) SNR = -8 dB
fold=2, R^2=0.841



(d) SNR = -12 dB
fold=4, R^2=0.782

(e) SNR = -16 dB
fold=2, R^2=0.700

(f) SNR = -20 dB
fold=2, R^2=0.637

Fig. 4.2.8 Results of regression analysis in the case of pipe flow sound (0.5MPa,SWT).

第 5 章

結言

本研究では，ナトリウム冷却高速炉の蒸気発生器内における伝熱管破損検知を念頭に，基礎的な空気-水系において，異常音を気泡噴流音で模擬し，音響法と深層学習を組み合わせた異常検知手法の開発を試みた．また深層学習の気泡噴流音検知への応用では，音響データから 3 種類の 2 次元特徴量を用意し，4 種類の CNN モデルを用いて回帰分析を予測させることで深層学習モデルの性能評価を行った．

5.1　まとめ

水流動音を重畳した STFT 特徴量を用いて構築した VGG16 モデルは，SNR が -12 dB 以上の場合において放出孔径 0.10，0.13, 0.15, 0.18, 0.20，0.25 mm の場合の気泡噴流音 6 種を 0.9 以上の決定係数で予測することを実証した．これは，定常的かつ異常音と周波数帯域が異なるノイズ環境下において，音響データを TFR に変換し，CNN で回帰分析を予測させる手法の有効性を確認した．また，水流動音ノイズを異常なし (0 孔径) として行った回帰分析については，STFT を用いて学習した VGG16 モデルが最も高い決定係数を示し，SNR -12 dB 以上の場合に 0.9 以上の決定係数を示した．一方，ホワイトノイズを異常なし (0 孔径) として行った回帰分析では SWT を用いて学習した VGG16 モデルが最も高い決定係数を示した．これらの結果から，水流動音を重畳した TFR を用いたモデル構築においては一定以上の結果を残すことが出来たが，ホワイトノイズを重畳した TFR を用いたモデル構築においては，判別に苦戦する結果となった．しかし，ホワイトノイズを重畳した TFR の結果から，SWT は広範囲にわたるノイズに対して頑健性を持つ可能性が示唆された．以上から，STFT と VGG16 を用いた回帰分析は，異常音とバックグラウンドノイズの特徴周波数帯域が異なる場合において異常検知に有用である可能性が示唆された．また，SWT は広範囲にわたるノイズに対して頑健性を持つ可能性が示唆された．

5.2 今後の展望

本研究では，水流動音を重畳した TFR を用いたモデル構築においては一定以上の結果を残すことが出来たが，ホワイトノイズを重畳した TFR を用いたモデル構築においては，改善の余地がある．しかし，ホワイトノイズを重畳した TFR の結果から，SWT は広範囲にわたるノイズに対して頑健性を持つ可能性が示唆されたため，今後は，実機環境で想定されうる多様なノイズを考慮して，より詳細なノイズ耐性の検証を行うことで，実機環境で有効な異常検知手法の検討をさらに重ねることができる．また，6 孔径 + バックグラウンドノイズの回帰分析については，6 孔径の回帰分析よりデータセット数が少なかったため，データセット数をそろえて学習を行うことでバックグラウンドノイズを 0 孔径として追加することで生まれる影響をより詳細に議論することが出来る．

謝辞

本研究を行う上で，植木祥高准教授には研究を行う機会や環境を与えていただきました．また，研究に際しましても様々な知識やご指導を賜りました．心より感謝申し上げます．

そして，プロジェクト研究員である荒邦章研究員には研究方針についてのご相談や研究に関するご指導及びご助言をいただき，研究生活を支えていただき深く感謝申し上げます．

最後に，研究生活をともにし，研究報告会での意見交換や助言をいただいた植木研究室の皆様に深く感謝申し上げます．

参考文献

[1] IEA ほか. World energy outlook 2022. 2022.

[2] K. Shoji, S. Yoshihiko, M. Takatsugu, K. Shigenobu, U. Nariaki, K. Yoshio, A. Kazumi, and T. Mikio. Development of advanced loop-type fast reactor in japan. *Nuclear Technology*, Vol. 170, No. 1, pp. 133–147, 2010.

[3] M. Hori. Sodium/water reactions in steam generators of liquid metal fast breeder reactors. *Atomic Energy Review*, Vol. 18, No. 3, pp. 707–778, 1980.

[4] C. Yoshitaka. Acoustic leak detection system for sodium-cooled reactor steam generators using delay-and-sum beamformer. *Journal of Nuclear Science and Technology*, Vol. 47, No. 1, pp. 103–110, 2010.

[5] Hartwell and W. Robert. The enrico fermi atomic power plant. In *Proc. IAEA Conf. Operating Experience of Power Reactors*, pp. 151–187, 1963.

[6] R. Currie, G. Linekar, and D. Edge. The under sodium leak in the pfr superheater 2 in february 1987. In *Proceedings of the specialists' meeting on steam generator failure and failure propagation experience, held in Aix-en Provence, France, 26-28 September 1990*, No. IWGFR–78, pp. 107–132, 1990.

[7] J. Alanche, M. Hugla, and L. Martin. Phenix steam generator na/h2o reaction incidents. In *Proceedings of the specialists' meeting on steam generator failure and failure propagation experience, held in Aix-en Provence, France, 26-28 September 1990*, No. IWGFR–78, pp. 133–142, 1990.

[8] V. M. Poplavsky. An analysis of main processes at small water-into-sodium leaks in the bn-350 and bn-600 npp steam generators. In *Proceedings of the specialists' meeting on steam generator failure and failure propagation experience, held in Aix-en Provence, France, 26-28 September 1990*, No. IWGFR–78, pp. 99–106, 1990.

[9] I. Poletaev, M. P. Tokarev, and K. S. Pervunin. Bubble patterns recognition using neural networks: Application to the analysis of a two-phase bubbly jet. *International Journal of Multiphase Flow*, Vol. 126, p. 103194, 2020.

[10] F. Lide, L. Yujiao, L. Qinghua, L. Xiaoting, L. Ran, and W. Xiaojie. Flow noise characterization of gas–liquid two-phase flow based on acoustic emission. *Measurement*, Vol. 46, No. 10, pp. 3887–3897, 2013.

[11] Y. LeCun, Y. Bengio, and G. Hinton. Deep learning. *Nature*, Vol. 521, No. 10, p. 436–444, 2015.

[12] P. Covington, J. Adams, and E. Sargin. Deep neural networks for youtube recommendations. In *Proceedings of the 10th ACM Conference on Recommender Systems*, p. 191–198, New York, NY, USA, 2016. Association for Computing Machinery.

[13] A.Krizhevsky, Ilya I. Sutskever, and G. E. Hinton. Imagenet classification with deep convolutional neural networks. *Commun. ACM*, Vol. 60, No. 6, p. 84–90, May 2017.

[14] M. Nijat, L. Johannes, E. Andreas, E. David, F. Peter, and L. Peter. Time series classification using deep learning for process planning: A case from the process industry. *Procedia Computer Science*, Vol. 114, pp. 242–249, 2017.

[15] T. Vijaya V. T Kumar, R. Shunmuga Sundar, Tilak Purohit, and V. Ramasubramanian. End-to-end audio-scene classification from raw audio: Multi time-frequency resolution cnn architecture for efficient representation learning. In *2020 International Conference on Signal Processing and Communications (SPCOM)*, pp. 1–5, 2020.

[16] K. J. Piczak. Environmental sound classification with convolutional neural networks. In *2015 IEEE 25th International Workshop on Machine Learning for Signal Processing (MLSP)*, pp. 1–6, 2015.

[17] R. Emna, K. Ali, M. Fabrice, A. Said, and O. Alice. Mfcc-based recurrent neural network for automatic clinical depression recognition and assessment from speech. *Biomedical Signal Processing and Control*, Vol. 71, p. 103107, 2022.

[18] G. Hinton, L. Deng, D. Yu, G. E. Dahl, A. Mohamed, N. Jaitly, A. Senior, V. Vanhoucke, P. Nguyen, T. N. Sainath, and B. Kingsbury. Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups. *IEEE Signal Processing Magazine*, Vol. 29, No. 6, pp. 82–97, 2012.

[19] J. Salamon, C. Jacoby, and J. P. Bello. A dataset and taxonomy for urban sound research. In *Proceedings of the 22nd ACM International Conference on Multimedia*, MM '14, p. 1041–1044. Association for Computing Machinery, 2014.

[20] N. Mikami, Y. Ueki, M. Shibahara, K. Aizawa, and K. Ara. State sensing of bubble jet flow based on acoustic recognition and deep learning. *International Journal of Multiphase Flow*, Vol. 159, p. 104340, 2023.

[21] N. Mikami, Y. Ueki, M. Shibahara, K. Aizawa, and K. Ara. Cnn-based acoustic identification of gas–liquid jet: Evaluation of noise resistance and visual explanation using grad-cam. *International Journal of Multiphase Flow*, Vol. 171, p. 104688, 2024.

[22] K.M.Kemal, G. İnan, D. Alper, and A. Mehmet. Comparison of stft and wavelet transform methods in determining epileptic seizure activity in eeg signals for real-time application. *Computers in Biology and Medicine*, Vol. 35, No. 7, pp. 603–616, 2005.

[23] H. Fırat, Y. Hanefi, and S. Selami. Determination of carotid disease with the application of

stft and cwt methods. *Computers in Biology and Medicine*, Vol. 37, No. 6, pp. 785–792, 2007.

[24] {Amir Homayoon} Najmi and John Sadowsky. The continuous wavelet transform and variable resolution time-frequency analysis. *Johns Hopkins APL Technical Digest (Applied Physics Laboratory)*, Vol. 18, No. 1, pp. 134–139, jan 1997.

[25] H. Ping, L. Pan, and S. Huiqi. Feature extraction of acoustic signals based on complex morlet wavelet. *Procedia Engineering*, Vol. 15, pp. 464–468, 2011. CEIS 2011.

[26] A. Rahaman and R. A. Wheeler. Wavelet transforms for determining time-dependent vibrational frequencies. *Journal of Chemical Theory and Computation*, Vol. 1, No. 5, pp. 769–771, 2005. PMID: 26641893.

[27] D. Luczak. Mechanical vibrations analysis in direct drive using cwt with complex morlet wavelet. *Power Electronics and Drives*, Vol. 8, No. 1, pp. 65–73, 2023.

[28] D. Ingrid, L. Jianfeng, and W. Hau-Tieng. Synchrosqueezed wavelet transforms: An empirical mode decomposition-like tool. *Applied and Computational Harmonic Analysis*, Vol. 30, No. 2, pp. 243–261, 2011.

[29] D. A. Greene, G. J. A. M. Meijer, F. F. Ahlgren, and J. K. V. Westerbrugge. Background noise measurements on prototype of snr 300 steam generator at hengelo. *International Conference of Liquid Metal Technology for Energy Systems*, pp. 2121–2130, 1980.

[30] Y. Ye, X. Zhang, and H. Li. Performance degradation assessment of spindle bearings based on vibration signals. *Sensors*, Vol. 23, No. 11, pp. 1–18, 2023.

[31] Y. Zhang and J. Wang. Prediction performance evaluation of engineering regression models using r-squared. *Applied Sciences*, Vol. 11, No. 21, pp. 1–15, 2021.

[32] X. Li, Y. Chen, and H. Zhao. Real-time anomaly detection for condition monitoring systems using machine learning. *Journal of Risk and Financial Management*, Vol. 13, No. 11, p. 534, 2025.

[33] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.

[34] H. Kaiming, Z. Xiangyu, R. Shaoqing, and S. Jian. Deep residual learning for image recognition, 2015.