

令和 6 年度 卒業論文

CNN アンサンブル学習に基づく音響識別による
プール沸騰の発生検知

2025 年 1 月

指導教員

植木 祥高 准教授

東京理科大学 先進工学部
電子システム工学科 植木研究室

8121048 柴崎 陸

要旨

Na 高速炉の炉心における冷却材沸騰事象の早期検知と推移把握を目的とし、音響識別によるプール沸騰の発生検知及び推移把握に適合する深層学習モデルの構築および性能評価を行った。本研究では、炉心局所異常に伴う異常検知技術の基礎知見の取得と基本的成立性を示すことを目標に、水を対象としたサブクール沸騰時に生じる音響データを取得し、時間 - 周波数表現の特徴量を学習させた回帰型 CNN モデルを構築した。本モデルの予測熱流束を基に沸騰開始点を閾値とした ROC 曲線による沸騰発生検知性能を評価した結果、検知手法の有効性を検証した。また、ホワイトノイズや水流動音といった基礎的なノイズ環境下においても、複数の CNN モデルを重み付き平均アンサンブル学習を通じて、熱流束回帰分析ならびに沸騰発生検知の性能向上が得られることを示した。

Abstract

To enable early detection and monitoring of coolant boiling events in the core of a sodium-cooled fast reactor (SFR), we constructed and evaluated the performance of a deep learning model suitable for detecting and tracking the occurrence of Pool boiling through acoustic identification. This study aimed to acquire fundamental knowledge and demonstrate the basic feasibility of anomaly detection technologies associated with localized core abnormalities. Using water as the medium, acoustic data generated during subcooled boiling were collected, and a regression-based Convolutional Neural Network (CNN) model was developed by training on time-frequency representation features. Based on the predicted heat flux from the model, the performance of the boiling detection was evaluated using a Receiver Operating Characteristic (ROC) curve, with the boiling onset point as the threshold. The results verified the effectiveness of the detection method. Furthermore, in basic noise environments such as white noise and water flow noise, the performance of heat flux regression analysis and boiling onset detection was improved through weighted ensemble learning of multiple CNN models.

目次

第 1 章	緒言	1
1.1	研究背景	1
1.2	研究目的	3
1.3	本論文の構成	3
第 2 章	プール沸騰実験	4
2.1	実験装置	4
2.2	実験方法	6
第 3 章	回帰分析による熱流束予測の手法	7
3.1	周波数解析手法	7
3.2	データセット作成	8
3.3	深層学習モデル	9
3.4	CNN モデルと回帰分析	10
3.5	回帰分析	11
3.6	アンサンブル学習	12
3.7	ROC 曲線	13
第 4 章	ROC 曲線による検知手法の結果と考察	17
4.1	プール沸騰実験の妥当性の検証	17
4.2	回帰分析による熱流束予測とノイズ耐性, アンサンブル学習の評価	18
4.3	100% 分類性能を持つ沸騰開始点予測に関する結果と考察	24
第 5 章	結言	28
5.1	まとめ	28
5.2	今後の展望	28
	謝辞	30
	参考文献	31
付録 A	沸騰曲線の計算方法	34
A.1	白金温度の推定手法	34
A.2	沸騰曲線の作成と相関式との比較手法	35
付録 B	スペクトログラムの例	36

付録 C	Adam の更新式	37
付録 D	100% 分類可能な熱流束の模式図	38
付録 E	実験 1 の離散的な音圧スペクトル	39
付録 F	実験 1 の離散的な音圧スペクトル	40
付録 G	回帰分析の補足結果	42
G.1	SNR=no_noise	42
G.2	SNR=0	44
G.3	SNR=-4	46
G.4	SNR=-8	48
G.5	SNR=-12	50
G.6	SNR=-16	52
G.7	SNR=-20	54

第 1 章

緒言

1.1 研究背景

近年、ロシアによるウクライナ侵攻やイスラエル・パレスチナ情勢の悪化等の影響により、エネルギー資源の安定供給に対する懸念が増大し、サプライチェーン全体の観点からも「エネルギーセキュリティの確保」が世界的にますます重要な課題となっている。日本においては、電力広域的運営推進機関が 2024 年 1 月に公表した今後 10 年間の電力需要の予測によれば、データセンターや半導体工場の新増設により、産業部門の電力需要が大幅に増加することが予測されている [1]。また、2020 年 10 月の「2050 年カーボンニュートラル宣言」に基づいて制定された「カーボンニュートラルに伴うグリーン成長戦略」では、カーボンニュートラルを実現するためのエネルギー政策及びエネルギー需給の体系が示された [2]。このカーボンニュートラル宣言を踏まえて改定された第 6 次エネルギー基本計画では、原子力が「重要なベースロード電源」と位置付けられている。原子力発電はカーボンフリーかつ大規模・安定電源で、エネルギーセキュリティ上の観点も含めて重要であり、2050 年カーボンニュートラルの達成に向けて原子力発電の活用は必須と認識されている [3]。その中で、原子力エネルギーの持続可能性を確保するためには、閉じた燃料サイクルを実現可能な高速炉が必要不可欠であり、現在最も実用化に近い炉系は、Fig. 1.1.1 に示すナトリウム冷却高速炉（SFR: Sodium-cooled Fast Reactor）である [4]。




Fig. 1.1.1 Sodium-Cooled Fast Reactor

ナトリウム冷却高速炉が従来の原子炉より優れている点として、中性子の減速が少ない点、熱除去能力に優れており炉心の出力密度を高くすることができる点、大気圧下の沸点が約 800°C と高く冷却系を低圧にできる点、系統温度の差を多くとり空気を最終ヒートシンクとした自然循環による崩壊熱除去が容易である点、構造材との共存性が優れている点などが挙げられる。その一方、ナトリウムは化学的に活性であり、水や空気と激しく反応する点や、不透明であることによって目視あるいは光学的な手段でナトリウム中の構造物の検査ができない点等、還元雰囲気で構造材料を腐食させる懸念は小さいものの、解決すべき課題がある [4]。

実際に発生した SFR の事故事例としては、1966 年にアメリカで起きたエンリコ・フェルミ炉 1 号機 (以下、フェルミ炉) の炉心溶融事故が挙げられる。フェルミ炉には、炉心溶融が起こって融けた燃料が下部プレナム内に流れ落ちた際に一ヶ所に溜まり再臨界を起こすのを防止するために、下部プレナムの中央に円錐型の構造物が設けられ、融けた燃料を分散させるようになっていた。この構造物は、安全審査の過程で炉心溶融事故に対する追加対策として、融けた燃料が直接圧力容器に触れないように、下部プレナム表面はジルコニウムカバーが急遽取り付けられていた。これが原因で出力を上げるにつれてジルコニウムが破れカバーが外れてしまい、燃料集合体の入り口ノズルにおいて流路閉塞が発生し、ナトリウム流量が低下したことで、燃料集合体は冷却不足によって溶融した [5]。そこで局所閉塞に次いで発生するナトリウムの核沸騰音の早期検知ができれば、安全に原子炉を停止させることが可能となり、炉心溶融などの深刻な事故を防ぐことができる。

本研究では、こうした局所閉塞の発生により冷却材の流量減少が生じ、炉心の冷却不十分による炉心溶融が起こる場合を想定する。このような局所的なナトリウム流路閉塞は、重大

な事態（局所的または全体的なナトリウムの沸騰）に至るまで温度センサーや流量計で検出されない可能性がある点で、最も重要な初期事象と言える [6]。ゆえに、炉心溶融が起こり重大な炉心の損傷に至る前に起こる可能性のある、燃料集合体内でのナトリウム沸騰の早期検知システムが組み込まれれば、局所閉塞の最初の兆候を迅速に捉え対応し、重大な事故を発生させないことに繋がる。

現在まで、原子炉内の沸騰音に関する機械学習ならびに深層学習の分野では、複数の研究が行われてきている [7][8][9]。これらの研究に関して、多層パーセプトロンやランダムフォレスト、畳み込みニューラルネットワークの回帰モデルによる熱流束予測や、同じく CNN による熱流束のラベル分類等が先行研究としてある [10][11]。

1.2 研究目的

本研究では、炉心局所異常に伴う異常検知技術の開発において、機械学習に基づく異常検知手法とアンサンブル学習を組み合わせたアプローチを提案し、高精度な沸騰開始点予測手法の確立を目的とする。先行研究における熱流束分類および回帰分析の知見を基に、特に沸騰-未沸騰状態の分類精度向上に焦点を当てる。具体的には、機械学習モデルの性能評価において ROC 曲線（Receiver Operating Characteristic Curve）による評価を行うとともに、予測値の分析に基づいて 100% 分類可能な熱流束値を決定する。また、この値を用いて沸騰開始点から膜沸騰遷移までを全体とした事象進展割合の定量的評価を行う。さらに、アンサンブル学習を適用することで予測の安定性と精度の向上を図る。これらの手法の有効性を検証するため、可視化データと音圧変化の時刻歴応答データを用いた検証を行う。また、実機環境を想定し、異なる信号対ノイズ比（SNR: Signal-to-Noise Ratio）における予測性能の検証を通じて、提案手法のノイズ耐性について評価する。

1.3 本論文の構成

本論文の構成として、まず第 2 章ではプール沸騰を対象とした音圧データ録音実験の手順について述べる。第 3 章では、回帰分析を用いた熱流束予測の手法について、周波数解析からデータセット作成、特徴量抽出、深層学習モデルの設計、評価指標の導入、さらにアンサンブル学習や ROC 曲線によるモデル性能の評価手法までを詳細に解説する。第 4 章では、ROC 曲線による検知手法に関する結果と考察を、プール沸騰実験の妥当性検証、100% 分類性能の熱流束予測、ノイズ耐性評価、アンサンブル学習の効果、および沸騰開始点予測に関する結果を中心に論じる。最後に第 5 章では、以上を踏まえた本研究の結論と今後の展望について述べる。

第 2 章

プール沸騰実験

本実験では、第 1 章で述べたナトリウム冷却高速炉の炉心で生じる異常時の沸騰の早期検知を想定し、プール沸騰を対象とした音圧データの録音実験を行った。特に、沸騰が飽和温度に達する前のサブクール沸騰状態を観察した。本実験では、サブクール度を 20°C に設定し、白金細線表面を伝熱面として、超純水を冷却材として使用した。電圧を白金細線に印加し、これを熱源とした。実験で測定された沸騰-未沸騰音データに対して短時間フーリエ変換を用いた周波数解析を行い、機械学習による手法構築と検証のための入力データとした。

2.1 実験装置

実験装置の概要図を Fig. 2.1.1 に示す。本実験では超純水 (電気伝導率: 0.066 mS/m) を入れた水槽 (ビーカー) をホットプレートの上に乗せ、水槽内に熱電対と電極を設置し、その周りにハイドロフォン、補助ヒーター、攪拌棒を位置調整しつつ配置した。このうち、電極の間には白金細線を弛まないように水平に張り、直流電源で印加電圧を変化させることで熱源として機能させた。用いた白金細線の直径は 0.3 mm 、長さは 4.0 cm とした。実験では白金細線に電圧を印加した後の白金表面から発生する気泡を観察した。

また、シャント抵抗は実験中に流れる電流の値を測定するために設置した。電圧計を用いてシャント抵抗に印加されている電圧値 $V_{\text{shunt}} [\text{V}]$ 、白金細線に印加されている電圧値 $V_{\text{Pt}} [\text{V}]$ を測定、白金細線付近に設置した熱電対を用いて水温を測定し、その結果をデータロガーに記録した。

水槽内の温度に関してホットプレートと補助ヒーターを用いて一定の温度に保つように調整し、攪拌棒を用いて水槽内の温度が均一になるように調整した。攪拌棒の回転速度は、測定前の脱気時間中は 350 rpm 、測定中は 120 rpm とした。また、沸騰音の計測にはハイドロフォンを用いた。このハイドロフォンのサンプリング周波数は、 44100 Hz とした。




Fig. 2.1.1 Schematic diagram of pool boiling experiment

また，本研究のプール沸騰実験で用いた実験器具の概要は Table 2.1.1 に示す．

Table 2.1.1 Experimental equipments used in pool boiling sound

装置	型番	メーカー
音測定用 PC	W202N	ASUS
A/D 変換器 (ハイドロフォン)	Spectra DAQ-200	ACO
ハイドロフォン	TYPE 7800	ACO
白金細線 0.3 mm	Pt-351325	ニラコ
直流電源	PSW-720L30	TEXIO
熱電対	T-35 (Type : SN, Class : 2)	SANKO
データロガー	34972A	KEYSIGHT
データ保存用 PC	Vostro	DELL
気圧計	testo622	testo
補助ヒーター	DSS83 (搭載調節計 SR83)	シマデン
ホットプレート	EHP-170N	AS ONE
シャント抵抗	NP-538	東京精電
水槽	ビーカー 010020-5000	柴田化学
電極	材質:SUS340	
攪拌棒	TORNADO SM-102	AS ONE

2.2 実験方法

実験手順を以下に示した.

1. 気圧計で実験室内の気圧を測定し, 記録した.
 2. 超純水 4 L をビーカーに入れ, 回転速度を 350 rpm に調整した攪拌棒で水温を均一に保ちつつ, ホットプレートと補助ヒーターを用いて飽和蒸気温度 T_{sat} まで加熱し, 到達後 30 分間脱気を行った.
 3. 補助ヒーターを停止した後, 条件のサブクール度 (バルク温度: 80 °C) まで自然冷却し, その条件の温度の $\pm 1^\circ\text{C}$ で安定させた.
 4. 主に補助ヒーターを用いて水温を安定させつつ, 白金細線に電圧無印加状態で沸騰音を 60 秒間計測した.
 5. 直流電源を用いて白金細線に 0.1 V~2.5 V まで印加電圧を 0.1 V 刻みで増加させ, その時の沸騰音を 1 分間それぞれ計測した.
 6. 同条件の実験として, 1~5 の操作を計 3 回行った.
- 3 回分の実験の異なる条件をまとめた表を以下に示す.

Table 2.2.1 Experimental conditions

実験番号	大気圧 hPa	超純水の初期温度 °C	超純水の電気伝導率 mS/m
1	1016.3	22.3	0.066
2	1014.4	23.1	0.075
3	1018.1	22.9	0.069

第 3 章

回帰分析による熱流束予測の手法

3.1 周波数解析手法

本研究では周波数解析手法として、短時間フーリエ変換（STFT：Short Time Fourier Transform）を用いた。ここで、 $x(t)$ を離散時間信号とする。 $x(t)$ を離散時間信号とし、これを短時間の時間区間に分割してその周波数構造を分析するために、 $0 \leq t \leq N-1$ の範囲で 0 でない値を持ち、それ以外では 0 となる関数 $w_a(t)$ を $x(t)$ に乗じることを考える。 $w_a(t)$ は分析窓関数と呼ばれる。よく用いられる分析窓としては、Hamming 窓、Hanning 窓、Blackman 窓などが挙げられる。本研究では Hanning 窓を用いた。これらの式を下に示す。

$$w_a(t) = 0.54 - 0.46 \cos\left(\frac{2\pi t}{N}\right) \quad (3.1.1)$$

$$w_a(t) = 0.5 - 0.5 \cos\left(\frac{2\pi t}{N}\right) \quad (3.1.2)$$

$$w_a(t) = 0.42 - 0.5 \cos\left(\frac{2\pi t}{N}\right) + 0.08 \cos\left(\frac{4\pi t}{N}\right) \quad (3.1.3)$$

短時間フーリエ変換では、

$$x_m(t - mS) = w_a(t - mS)x(t) \quad (3.1.4)$$

のように分析窓関数 $w_a(t)$ を mS だけシフトして乗じることで、離散時間信号 $x(t)$ の $mS \leq t \leq (mS + N - 1)$ 部分を切り出し、切り出した時間区間の先頭に時間原点を移動した有限長信号を定義する。この時間区間、あるいは切り出された有限長信号は、時間フレーム、あるいは単にフレームと呼ばれ、 m は時間フレームのインデックス、 S はフレームシフト量、 N はフレーム長を表す。新たな時間変数を $n = t - mS$ と置くと、 $x_m(n)$ は $0 \leq n \leq N-1$ でのみ 0 でない値を持つことになる。こうして分割された有限長信号に離散フーリエ変換（Discrete Fourier Transform; DFT）を適用することで、短時間フーリエ変換

$$X(m, k) = \sum_{n=0}^{N-1} x_m(n) e^{-j \frac{2\pi kn}{N}} \quad (3.1.5)$$

が定義される。ここで、 $x_m(n)$ は m フレーム目の信号、 N はフレーム長、 k は離散周波数のインデックスを表す。

3.2 データセット作成

3 回の実験で得た音響データを収集し、STFT を用いてデータセットの作成を行った。具体的な処理を以下に示す。また、各 SNR (0, -4, -8, -12, -16, -20 dB) に対するスペクトログラムの例は付録に示す。

3.2.1 データの前処理

まず、各電圧値ごとの 60 秒間の音響データを読み込んだ。各音響データはサンプリングレート 44100 Hz で読み込まれ、その後、カットオフ周波数 500 Hz のハイパスフィルタを適用し、低周波成分を除去した。この処理により、対象とする高周波成分が強調された信号が得られる。

3.2.2 水流動音の追加

さらに、異なる SNR の条件を再現するため、水流動音を音響データに重畳させた。使用した水流動音は同じサンプリングレートで読み込み、流量が $125 \text{ m}^3/\text{h}$ 、レイノルズ数 $\text{Re} = 3.2 \times 10^5$ を用いた [12]。ノイズの重畳プロセスは以下の手順で行った。

まず、元の信号 $y_{\text{signal}}(i)$ の平均二乗値 (P_{signal}) を計算する。

$$P_{\text{signal}} = \frac{1}{N} \sum_{i=1}^N y_{\text{signal}}(i)^2 \quad (3.2.1)$$

式 (3.2.1) において、 N は信号 $y_{\text{signal}}(i)$ のサンプル数を表す。次に、ノイズ信号についても元の信号と同様に平均二乗値 (P_{noise}) を決定する。その後、所望の SNR に基づいてスケール係数 α を計算する。

$$\text{SNR} = 10 \log_{10} \left(\frac{P_{\text{signal}}}{\alpha^2 \cdot P_{\text{noise}}} \right) \quad (3.2.2)$$

式 (3.2.2) からスケール係数 α を計算し、最終的にノイズを含めた信号は以下のように計算される。

$$y_{\text{observed}}(i) = y_{\text{signal}}(i) + \alpha \cdot y_{\text{noise}}(i) \quad (3.2.3)$$

具体的には、SNR 0 dB, -4 dB, -8 dB, -12 dB, -16 dB and -20 dB の各条件でノイズを付加した信号を生成した。また、比較のためノイズを加えない条件も含めた。

3.2.3 STFT による特徴量抽出

ノイズ処理後の信号は, 0.5 秒ごとに区切られたチャンク (データフレーム) に分割され, 各チャンクに短時間フーリエ変換 (Short-Time Fourier Transform; STFT) が適用された. STFT は式 (3.1.5) に従って計算された. 得られた振幅スペクトログラムは, データ範囲を $[0, 1]$ に正規化した後, 224×224 ピクセルにリサイズされ, 画像データとして保存した.

3.3 深層学習モデル

本節では, 深層学習モデルで使用した活性化関数, 最適化アルゴリズム, ネットワークアーキテクチャの概要を述べ, 実験で使用した手法を紹介する. なお, 本研究では, Python 3.9.19 を用いており, 使用した各ライブラリのバージョンは Table 3.3.1 に示した.

Table 3.3.1 Library names and versions

ライブラリ	バージョン
pandas	1.4.4
NumPy	1.26.4
librosa	0.10.2
SciPy	1.13.1
scikit-learn	1.4.2
TensorFlow	2.9.1
Matplotlib	3.8.4

3.3.1 活性化関数

本研究では活性化関数として ReLU 関数と Softmax 関数を使用した. これら 2 つの関数の定義式を以下に示す.

ReLU 関数

ReLU 関数の定義式を以下に示す.

$$f(x_i) = \begin{cases} x_i & (x_i \geq 0) \\ 0 & (x_i \leq 0) \end{cases} \quad (3.3.1)$$

Softmax 関数

Softmax 関数の定義式を以下に示す.

$$f(x_i) = \frac{e^{x_i}}{\sum_j^n e^{x_j}} \quad (3.3.2)$$

3.3.2 最適化アルゴリズム

本研究では各モデルの最適化アルゴリズムとして Adam (Adaptive Moment Estimation) を使用した。Adam は確率的勾配降下法 (SGD) を基に、学習率を動的に調整することで効率的に学習を実現するアルゴリズムである。Adam の更新式は付録に示す。

Adam の特徴として、勾配の一次モーメントおよび二次モーメントの推定値を用いてパラメータ更新を行うため、収束性が向上しやすいことが挙げられる。さらに、各パラメータに適応的な学習率を割り当てることで、スケールの異なる勾配に対しても効果的に学習を進めることができる [13]。

3.4 CNN モデルと回帰分析

本節では機械学習に用いた 3 つの CNN モデルの概要を述べる。AlexNet, ResNet50, および VGG16 は、物体認識や画像分類を含む多くのコンピュータビジョンタスクにおいてベンチマークモデルとして広く利用されており、さまざまなデータセットで高いパフォーマンスを示している。これらのモデルは、医学画像解析、特に脳腫瘍の分類においても非常に高い精度を発揮するため、基盤モデルとして頻繁に使用されている [14]。

3.4.1 AlexNet

AlexNet は、深層学習をコンピュータビジョンの問題に適用することが可能であることを初めて示したアーキテクチャで、2012 年に提案された。AlexNet は 5 層の畳み込み層と 3 層の全結合層で構成されており、ImageNet コンペティションにおいて圧倒的な成績を収めた。特に、ReLU 活性化関数やデータ拡張技術、ドロップアウトなどの技術を採用することで、過学習を防ぎつつ高い精度を実現した。AlexNet は、深層学習の実用化を推進し、その後の多くの深層学習モデルの発展に大きな影響を与えた。

3.4.2 ResNet50

ResNet50 は、2015 年に提案され、残差接続 (Residual Connection) の概念を導入することで、深層学習における革新を起こした。残差接続により、ネットワークは非常に深い構造を持ちながらも、勾配消失問題を緩和し、効率的に学習することが可能となる。ResNet50 は 50 層の深さを持ち、ショートカット接続を使用して一部の層をスキップし、ネットワークの学習を加速させる。このアーキテクチャは、画像認識タスクにおいて非常に高い性能を示し、他の深層学習モデルに比べて非常に優れた一般化能力を持っている。

3.4.3 VGG16

VGG16 は、2014 年に提案された深層畳み込みニューラルネットワークアーキテクチャで、画像分類タスクにおいて最先端の性能を示した。このアーキテクチャは 16 層のネットワークから構成されており、13 層の畳み込み層と 3 層の全結合層を持っている。VGG16 の主な特徴は、 3×3 の小さな畳み込みフィルターを使用している点で、これによりネットワークは比較的シンプルな構造を維持しつつ、より複雑な特徴を学習することができる。この設計は、転送学習や他の深層学習タスクの基盤モデルとして非常に有用であり、現在も多くのアプリケーションで使用されている。

3.5 回帰分析

前節で紹介した CNN モデルは、分類タスクだけでなく回帰タスクにも応用可能である。本節では、熱流束の予測を目的とした回帰分析に AlexNet, ResNet50, および VGG16 を用いた実験について述べる。回帰分析は、目的変数と説明変数の間の関係性を定量的に分析する手法であり、今回の研究では熱流束を目的変数として設定した。

3.5.1 熱流束の計算

熱流束は、白金細線に印加される電圧 V_{Pt} と電流 I を用いて以下の式で計算される。

$$q = \frac{V_{Pt} I}{\pi d L} \quad (3.5.1)$$

ここで、 d は白金細線の直径 (0.3 mm)、 L は白金細線の長さ (40 mm) である。また、白金電圧 V_{Pt} はデータロガーで測定した値を用い、電流 I はオームの法則を用いて、以下の式で算出した。

$$I = \frac{V_{shunt}}{R_{shunt}} \quad (3.5.2)$$

実験では抵抗値 $R_{shunt} : 1.667 \times 10^{-3} \Omega$ のシャント抵抗を使用した。本研究ではこの熱流束を各電圧値に対して計算し、 q を予測するための単回帰分析のラベルとした。

3.5.2 回帰モデルの設計

前節で示したそれぞれのアーキテクチャを基に、出力層を線形活性化関数として linear を追加した 1 ユニットに変更し、損失関数を分類タスクの categorical crossentropy から回帰タスクに適した mean squared error (MSE) に変更した。このアプローチにより、分類から回帰タスクへの円滑な転用が可能となった。

3.5.3 モデルの評価指標

回帰モデルの性能評価には決定係数 R^2 を使用した。決定係数は、観測データと予測値の適合度を測る指標であり、その定義は以下の通りである。

$$R^2 = \frac{\sum(\hat{y}_i - \bar{y})^2}{\sum(y_i - \bar{y})^2} \quad (3.5.3)$$

ここで、 $\hat{y}_i$ は予測値、 y_i は観測値、 $\bar{y}$ は観測値の平均である。 R^2 の値は 0 から 1 の範囲をとり、1 に近いほどモデルの説明力が高いことを意味する。

3.6 アンサンブル学習

本節では、アンサンブル学習の手法と本実験での適用方法について述べる。アンサンブル学習は、複数の学習器を組み合わせることで予測精度を高める手法である [15]。アンサンブル学習は、単独の学習器よりも優れたパフォーマンスを発揮することが多い。このアプローチの基本は、複数の弱学習器（性能が低いモデル）を組み合わせることで、強力な予測器を作ることである。アンサンブル学習の主な利点は、過学習の防止と一般化能力の向上である。アンサンブル学習では、予測結果を統合する方法がいくつかある。その一つが「重み付き平均」を使用する方法である。重み付き平均は、各学習器の予測結果に重みをつけて平均を取る手法であり、重みを学習器の信頼度に基づいて決定する [16]。信頼度が高いモデルほど、最終的な予測に与える影響が大きくなる。本研究では、複数の学習器として前々節で示した 3 種類の CNN モデルを使用し、重み付き平均によるアンサンブル学習を採用した。具体的には、各学習器から得られた予測値 $y_1, y_2, \dots, y_n$ に対して、それぞれの学習器に対応する重み $w_1, w_2, \dots, w_n$ を乗じて加重平均を求める。このとき重みは研究によって様々な信頼度に基づいて設定されるが、本実験では各学習器の予測値に対応する重みを、各学習器の決定係数 (R^2 score) を基に計算した。各学習器の予測値 y_{pred} と検証データの真値 y_{val} を用いて決定係数を算出し、その値を基に以下の式で誤差率を計算した。

$$\text{error}_i = 1 - R_i^2 \quad (3.6.1)$$

ここで、 R_i^2 は第 i 番目の学習器の決定係数である。この誤差率をもとに重みを次のように設定した

$$w_i = \frac{1}{\text{error}_i} \quad (3.6.2)$$

その後、これらの重みを正規化し、 $\sum_{i=1}^n w_i = 1$ を満たすように調整した。最後に、正規化された重み $w_1, w_2, \dots, w_n$ を各学習器の予測値 $y_1, y_2, \dots, y_n$ に乗じて加重平均を求め、最終的なアンサンブルの予測値 y_{ensemble} を以下の式により算出した。

$$y_{\text{ensemble}} = \sum_{i=1}^n w_i y_i \quad (3.6.3)$$

最終的な重み付き平均を用いた予測は以下のように計算される。

$$\hat{y} = \frac{y_{\text{ensemble}}}{\sum_{i=1}^n w_i} \quad (3.6.4)$$

ここで、 $\hat{y}$ は最終的な予測値、 y_i は各学習器から得られた予測値、 w_i はそれぞれの学習器の重みである。重み付き平均の利点は、精度が高い学習器がより多くの影響を与えるため、全体の予測精度を向上させることができる点である。

3.7 ROC 曲線

本節では、ROC 曲線に関して述べ、本実験で用いた手法を述べる。ROC 曲線は、分類モデルの性能を評価するための図であり、特に二項分類問題においてよく使用される。ROC 曲線は、分類器の感度（True Positive Rate）と 1 - 特異度（False Positive Rate）の関係を視覚的に示すものである [17]。感度は、実際に正のクラスに属するデータのうち、どれだけ正しく予測できたかを示し、特異度は、実際に負のクラスに属するデータのうち、どれだけ正しく予測できたかを示す。横軸に 1 - 特異度（False Positive Rate, FPR）を、縦軸に感度（True Positive Rate, TPR）を取ることで描かれる。モデルが完全にランダムな予測を行う場合、ROC 曲線は対角線に沿った直線となる。一方で、良いモデルほどこの直線から離れた上に位置し、感度と特異度の両方で高い性能を発揮する。

AUC（Area Under the Curve）は、ROC 曲線の下に囲まれた面積を表す指標であり、モデルの全体的な性能を示す [18]。AUC は 0 から 1 の範囲で、1 に近いほど優れた分類性能を持つことを示す。AUC の値が 0.5 の場合、モデルはランダムな予測と同等の性能であり、0.5 未満の場合は逆に負のクラスと正のクラスを誤って分類する傾向がある。

ROC 曲線と AUC は、特に不均衡なデータセットにおいて有用であり、クラスの不均衡が大きい場合でも、単に正解率に依存することなく、モデルの性能を適切に評価できる。

3.7.1 ROC 曲線の計算方法

ROC 曲線を描画するためには、モデルが予測した各サンプルの予測確率を使用して、感度と特異度を計算する。具体的には、予測確率を閾値に基づいてクラスラベルに変換し、これに対する真陽性（TP）、偽陽性（FP）、真陰性（TN）、偽陰性（FN）の数を数える。この情報を元に、異なる閾値に対する感度と特異度を求め、これらの値をプロットすることで ROC 曲線を描くことができる。

$$\text{True Positive Rate} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{False Positive Rate} = \frac{\text{FP}}{\text{FP} + \text{TN}} \quad (3.7.1)$$

このようにして、ROC 曲線を描くためにさまざまな閾値を設定し、その結果を基に性能を評価することができる。

本研究では、AlexNet, ResNet50, VGG16 を使用した回帰モデルを訓練し、それぞれの予測結果に基づいて ROC 曲線を描画する方法を採用している。ここで従来の ROC 曲線を描画方法と異なる点は、ラベル変換のため閾値を 1 つしか使用しないことである。その 1 つの閾値には、実験中に得られた核沸騰開始点の熱流束の値を使用した。核沸騰開始点の熱流束の求め方とその妥当性については第 4 章に示した。これにより、回帰分析の予測熱流束が閾値より高いときは陽性（沸騰）、低いときは陰性（未沸騰）のラベルに分類し、1 つの閾値に基づいた ROC 曲線を描画して評価することができる。具体的には、以下の処理を実施している。

1. 各モデルの訓練には、それぞれ最適な異なるバッチサイズと学習率が設定され、指定されたエポックの間、訓練が行われる。
2. 訓練後、検証データに対して各モデルの予測を行い、重み付き平均アンサンブルの重み計算のために決定係数の算出をする。また、その予測結果と式 (3.6.3), (3.6.4) 元に重みを計算してアンサンブル学習時の予測を算出する。
3. 各モデル (AlexNet, ResNet50, VGG16, アンサンブル) で得られた予測結果をもとに、指定された閾値 (THRESHOLD) を使用して 2 値分類を行う。本研究では、3 回の実験データをまとめて学習データとして使用しているため、閾値の熱流束は 3 回の実験ごとの核沸騰開始点の熱流束の平均値を使用した。予測値がこの閾値を超える場合は「沸騰 (1)」, それ以下の場合は「非沸騰 (0)」として分類される。これにより、各モデルの予測結果が 2 クラスに分けられ、その後、ROC 曲線を描画するための基準となる。
4. 分類結果に基づいて、各モデル (AlexNet, ResNet50, VGG16, およびアンサンブルモデル) に対して ROC 曲線を描画し、曲線下面積である AUC (Area Under the Curve) を計算する。
5. 最後に、各単体モデルとアンサンブル学習の決定係数および AUC の結果を比較する。

3.7.2 モデルの設定と構築

データセットは、異なる SNR の条件下で収集された熱流束データで構成され、5 分割交差検証法 (*K*-Fold Cross Validation) を使用して分割された。各モデルにはそれぞれ個別に学習を行い、決定係数が最大となるときの値を最適なパラメータとして設定した。この表を、Table 3.7.1 に示した。

Table 3.7.1 Parameter settings for each model

モデル	バッチサイズ	エポック数	学習率
AlexNet	12	300	0.0001
ResNet50	12	300	0.00005
VGG16	32	300	0.00005

3.7.3 100% 分類性能の熱流束評価

本研究では、アンサンブル学習モデルの予測性能を詳細に分析するため、各分割における回帰分析結果を可視化して評価した。具体的には、3.7.1 節で示した手順後に、以下の手順で分析を行った。また、100% 分類可能な熱流束の決定方法を示した模式図は付録に示した。

1. 同一熱流束に対応する音響データが複数存在するため、それらを同一の塊として用いる。
2. 塊を熱流束の実測値の昇順に並べ替えた後、各塊について以下の条件を満たすものを探索する。
 - 各塊内の予測値が全て閾値を超えているかを判定。
 - 予測値の最小値を記録。
3. すべての予測値が閾値を超える場合、その最小予測値を「100% 分類可能な熱流束値」として記録する。
4. 結果をプロットし、閾値を超えた塊の最小値をグラフに描画する。

3.7.4 性能評価指標

モデル性能の評価には、決定係数、曲線下面積 (AUC)、および劣化率を用いた。劣化率は各モデルの予測性能におけるノイズの影響を定量化するための指標である。劣化率は、基準となるノイズなしの性能指標と比較し、ノイズ条件下での性能低下率として算出した。具体的には、以下の式で定義される。

$$\text{劣化率} = \frac{\text{性能}_{\text{no_noise}} - \text{性能}_{\text{noise}}}{\text{性能}_{\text{no_noise}}} \times 100 (\%) \quad (3.7.2)$$

ここで、性能_{no_noise} はノイズがない場合の決定係数または AUC、性能_{noise} は特定の SNR 条件下での値を示す。この指標は各モデルのノイズ耐性を比較する上で有用である。

また、性能指標の標準誤差を考慮し、劣化率計算に誤差伝搬法を適用する。劣化率の誤差は以下の手順で計算される。まず、劣化率の計算には差分と比の計算が含まれる。差分 $A - B$ の誤差 σ_{A-B} は以下の式で与えられる [19]。

$$\sigma_{A-B} = \sqrt{\sigma_A^2 + \sigma_B^2} \quad (3.7.3)$$

ここで、 σ_A と σ_B はそれぞれの測定値の標準誤差を表す．次に、比 $\frac{A}{B}$ における相対誤差は以下の式で計算される．

$$\frac{\sigma_{A/B}}{|A/B|} = \sqrt{\left(\frac{\sigma_A}{A}\right)^2 + \left(\frac{\sigma_B}{B}\right)^2} \quad (3.7.4)$$

これらの式を組み合わせることで、劣化率の誤差 $\sigma_{\text{劣化率}}$ は以下のように表される．

$$\sigma_{\text{劣化率}} = 100 \times \sqrt{\left(\frac{\sigma_{\text{diff}}}{\text{diff}}\right)^2 + \left(\frac{\sigma_{\text{no_noise}}}{\text{性能}_{\text{no_noise}}}\right)^2}, (\%) \quad (3.7.5)$$

ここで、 σ_{diff} は式 (3.7.3) で計算される差分の誤差、 $\sigma_{\text{no_noise}}$ はノイズなし条件での標準誤差を表す．これにより、劣化率の統計的信頼性を評価できる．

第 4 章

ROC 曲線による検知手法の結果と考察

4.1 プール沸騰実験の妥当性の検証

4.1.1 沸騰曲線による実験データの妥当性検証

本研究では、同一条件下で 3 回のプール沸騰実験を実施した。付録 A に示す計算方法により求めた各条件での沸騰曲線を、Fig. 4.1.1a, Fig. 4.1.1b, および Fig. 4.1.1c に示す。各実験結果に基づき、未沸騰領域および核沸騰領域における熱流束と壁面過熱度の関係を検討し、実験の妥当性を評価した。

Fig. 4.1.1a に示すように、核沸騰初期は熱流束 q が伝熱面過熱度 ΔT_{sat} に対して緩やかに増加した。この時、細線上では離散的な発泡が確認され、かつ発泡間隔が長かった。これは細線の姿勢が上に凸な形状であったため、攪拌棒により近く冷却機能が強く働き、測定時間の多くが未沸騰に近い状態となっていたからだと考えられる。一方で、核沸騰が連続して発生するようになると、熱流束 q が壁面過熱度 ΔT_{sat} に対して急激に増加する直線的な挙動に変化した。同様の傾向が Fig. 4.1.1b および Fig. 4.1.1c にも確認され、Kutateladze の相関式と近い特性をしていることから理論的な沸騰曲線の挙動と一致しているものとし、本研究の測定結果が妥当であると判断した [20]。




Fig. 4.1.1 Boiling curves for all experiments: (a) Experiment 1, (b) Experiment 2, (c) Experiment 3

4.1.2 沸騰開始点の熱流束選択の妥当性検証

目視観察による沸騰開始点の特定

核沸騰は、伝熱面温度から液体の飽和温度を差し引いた伝熱面過熱度がある値を超えたところで生じ、伝熱面上にランダムに分布した発泡点から気泡が発生する沸騰の形態である[21]。本研究では沸騰開始点を特定するため、実験中に各電圧値で撮影した1分間の動画を分析し、蒸気泡が初めて発生した点を核沸騰開始点とした。このタイミングに対応する電圧値を基に熱流束を算出し、沸騰開始点の熱流束として採用の根拠の1つとした。例として、以下の Fig. 4.1.2 は、実験1で初めて気泡が発生した瞬間を捉えたものである。




Fig. 4.1.2 Generation of vapor bubbles at the boiling start point

また目視観察で特定した沸騰開始点の熱流束の妥当性を裏付けるために、取得した音響データのスペクトル解析を行った。例として、実験1の 0.2607 MW m^{-2} の音響データを解析した結果、離散的な音圧スペクトルが確認された。また、その離散的な音圧スペクトルの図は付録に示した。

Fig. E.0.1 より、1100 Hz, 1400 Hz, 2200 Hz 付近にピークが現れていることが確認できた。このことは、蒸気泡が観測されたタイミングでの熱流束が核沸騰開始時に対応する物理量であることを示している。したがって、本研究で採用した沸騰開始点の熱流束選択手法は、実験的および理論的観点から妥当であると判断できる。


4.2 回帰分析による熱流束予測とノイズ耐性、アンサンブル学習の評価

本節では、回帰分析による熱流束予測の結果について述べ、各モデルの決定係数および AUC を比較することでノイズ耐性を評価する。また、異なる SNR 条件下におけるモデルの性能劣化の傾向を分析し、アンサンブル学習の有効性について議論する。


4.2.1 回帰分析による各 SNR 条件の結果

例として、Fig. 4.2.1 に、SNR が no_noise, 0, -4, -8, -12, -16, -20 の7種類の条件下で実施した回帰分析の同一 Fold の結果を示す。ここで、SNR がない（ノイズなし）の場合を no_noise


と表記する．各プロットでは，横軸が実測熱流束，縦軸が予測熱流束を表している．




(a) SNR = no_noise




(b) SNR = 0




(c) SNR = -4




(d) SNR = -8



(e) SNR = -12



(f) SNR = -16



(g) SNR = -20

Fig. 4.2.1 Regression analysis results under SNR conditions (Fold2)

4.2.2 モデルごとの決定係数と AUC の比較

本節では、全ての回帰分析結果をモデルごとに比較し、決定係数と AUC を用いた性能評価を行った。これにより、モデル間の予測精度および分類性能の違いを定量的に比較した。

まず、各単一モデルとアンサンブルモデルの 5 分割交差検証による決定係数および AUC を比較した結果をそれぞれ Table 4.2.1, 4.2.2 に示す。

Table 4.2.1 Comparison of coefficients of determination of models by SNR

SNR	AlexNet	ResNet50	VGG16	Ensemble
no_noise	0.9974 ± 0.0009	0.9975 ± 0.0007	0.9974 ± 0.0006	0.9986 ± 0.0005
0	0.9979 ± 0.0002	0.9974 ± 0.0006	0.9975 ± 0.0006	0.9987 ± 0.0002
-4	0.9913 ± 0.0010	0.9911 ± 0.0014	0.9919 ± 0.0009	0.9938 ± 0.0010
-8	0.9862 ± 0.0007	0.9865 ± 0.0015	0.9873 ± 0.0020	0.9901 ± 0.0012
-12	0.9678 ± 0.0034	0.9750 ± 0.0021	0.9778 ± 0.0019	0.9807 ± 0.0009
-16	0.9366 ± 0.0040	0.9312 ± 0.0146	0.9505 ± 0.0018	0.9544 ± 0.0026
-20	0.8871 ± 0.0077	0.8792 ± 0.0056	0.9019 ± 0.0038	0.9101 ± 0.0045

Table 4.2.2 Comparison of AUC of models by SNR

SNR	AlexNet	ResNet50	VGG16	Ensemble
no_noise	0.9918 ± 0.0056	0.9950 ± 0.0022	0.9929 ± 0.0023	0.9962 ± 0.0026
0	0.9951 ± 0.0018	0.9923 ± 0.0045	0.9928 ± 0.0014	0.9968 ± 0.0017
-4	0.9800 ± 0.0071	0.9828 ± 0.0042	0.9815 ± 0.0036	0.9838 ± 0.0067
-8	0.9677 ± 0.0037	0.9741 ± 0.0059	0.9731 ± 0.0034	0.9774 ± 0.0031
-12	0.9473 ± 0.0092	0.9639 ± 0.0069	0.9611 ± 0.0055	0.9648 ± 0.0064
-16	0.9272 ± 0.0094	0.9379 ± 0.0091	0.9360 ± 0.0096	0.9378 ± 0.0084
-20	0.9107 ± 0.0069	0.9081 ± 0.0111	0.9104 ± 0.0062	0.9165 ± 0.0070

Table 4.2.1, 4.2.2 では、5 分割交差検証の結果から算出された平均値と標準誤差を含んでいる。決定係数の表はモデルの回帰性能を示しており、高い決定係数は予測値が実測値をよく再現していることを意味する。一方、AUC 値の表は、モデルの分類性能を表しており、高い AUC 値はモデルが沸騰・未沸騰の分類を正確に行えることを示している。いずれの指標も、SNR が低下（ノイズ増加）するにつれて性能が劣化する傾向を示すが、アンサンブルモデルは単一モデルに比べてノイズ耐性が高いことが確認された。

次に、決定係数と AUC をモデルごとにグラフ化し、ノイズ耐性を視覚的に比較した。

決定係数の比較

Fig. 4.2.2 は、各モデルの決定係数の SNR 条件ごとに比較した結果を示している。




Fig. 4.2.2 Comparison of coefficients of determination in each model

このグラフから、SNR が低下してもアンサンブルモデルが他のモデルに比べて高い決定係数を維持していることが分かる。また、SNR が大きくなるにつれてアンサンブル学習の効果がより顕著に表れていると考えられる。

AUC の比較

Fig. 4.2.3 は各モデルにおける AUC の SNR 条件ごとの比較の図を示している。




Fig. 4.2.3 Comparison of AUC in each model

Fig. 4.2.2 と同様に、特に SNR が高い条件下では、アンサンブル学習を用いたモデルが他のモデルを上回る性能を示している。

アンサンブル学習の性能をより定量的に評価するため、Fig. 4.2.2, 4.2.3 のノイズ条件ごとの劣化率を計算し、それぞれ Table 4.2.3, 4.2.4 に示した。劣化率の式 (3.7.2) と誤差伝搬の式 (3.7.5) により再計算した結果を以下の表に示す。

Table 4.2.3 Degradation rate of determination coefficients

SNR	AlexNet %	ResNet50 %	VGG16 %	Ensemble %
no_noise	0.000 $\pm$ 0.000	0.000 $\pm$ 0.000	0.000 $\pm$ 0.000	0.000 $\pm$ 0.000
0	-0.050 $\pm$ 0.078	0.010 $\pm$ 0.092	-0.010 $\pm$ 0.085	-0.010 $\pm$ 0.050
-4	0.612 $\pm$ 0.135	0.642 $\pm$ 0.149	0.551 $\pm$ 0.107	0.481 $\pm$ 0.106
-8	1.123 $\pm$ 0.114	1.103 $\pm$ 0.156	1.013 $\pm$ 0.185	0.851 $\pm$ 0.121
-12	2.968 $\pm$ 0.308	2.256 $\pm$ 0.199	1.965 $\pm$ 0.177	1.793 $\pm$ 0.099
-16	6.096 $\pm$ 0.362	6.647 $\pm$ 1.321	4.702 $\pm$ 0.163	4.426 $\pm$ 0.235
-20	11.060 $\pm$ 0.697	11.860 $\pm$ 0.507	9.575 $\pm$ 0.344	8.862 $\pm$ 0.407

Table 4.2.4 AUC degradation rate

SNR	AlexNet %	ResNet50 %	VGG16 %	Ensemble %
no_noise	0.000 $\pm$ 0.000	0.000 $\pm$ 0.000	0.000 $\pm$ 0.000	0.000 $\pm$ 0.000
0	-0.333 $\pm$ 0.527	0.271 $\pm$ 0.478	0.010 $\pm$ 0.264	-0.060 $\pm$ 0.307
-4	1.190 $\pm$ 0.909	1.225 $\pm$ 0.456	1.148 $\pm$ 0.421	1.244 $\pm$ 0.663
-8	2.430 $\pm$ 0.526	2.101 $\pm$ 0.579	1.994 $\pm$ 0.406	1.888 $\pm$ 0.407
-12	4.487 $\pm$ 0.938	3.126 $\pm$ 0.695	3.202 $\pm$ 0.558	3.152 $\pm$ 0.645
-16	6.513 $\pm$ 0.953	5.744 $\pm$ 0.914	5.730 $\pm$ 0.967	5.863 $\pm$ 0.845
-20	8.176 $\pm$ 0.697	8.734 $\pm$ 1.116	8.309 $\pm$ 0.624	8.001 $\pm$ 0.704

誤差を考慮した分析結果から、SNR = 0 付近で興味深い知見が得られた。一部のモデルにおいて若干の性能向上（負の劣化率）が観察され、これは軽度のノイズが正則化効果として機能していた可能性を示唆している。例えば、AlexNet の決定係数の劣化率は $-0.050 \pm 0.078\%$ であり、誤差の範囲内で 0 との区別がつかないものの、この現象には注目に値する特徴があると言える。この正則化効果は、主に以下の 2 つのメカニズムによって生じたと推測される。まず、適度なノイズの付加により、モデルは個々のデータポイントへの過度な適合が抑制され、より一般的なパターンの抽出に焦点を当てるようになる。これは過学習の抑制として機能し、モデルの汎化性能の向上に寄与する。また、ノイズによる入力データの微小な変動は特徴空間の実質的な拡大をもたらし、モデルは類似した入力に対してより安定した予測を行

うよう学習を進める。このプロセスは、訓練データ拡張としても解釈できる。ただし、本実験では SNR が -4 dB 以下のすべてのモデルにおいて単調な性能劣化が観察されており、正則化の効果は限定的である可能性が示唆される。SNR が 0 dB 付近の軽度なノイズ条件下では、正則化によって性能向上が見られるものの、その効果は統計的に有意とは言い切れない。SNR が低下するにつれて正則化の効果は減衰し、SNR が -4 dB 以下になると、むしろ性能劣化を引き起こす要因となっている。これは、低 SNR 環境下ではノイズの影響が大きくなり、正則化によって過剰な平滑化が行われるためと考えられる。

低 SNR 環境 (-16 dB, -20 dB) に目を向けると、アンサンブルモデルの優位性が統計的に有意であることが確認された。特に決定係数において、SNR = -20 dB でのアンサンブルモデル ($8.862 \pm 0.407\%$) と AlexNet ($11.06 \pm 0.697\%$) の間には、誤差を考慮しても明確な差が存在する。このことから、異なるアーキテクチャの特徴を組み合わせることで、ノイズに対する頑健性が向上することが示唆された。

4.3 100% 分類性能を持つ沸騰開始点予測に関する結果と考察

本節では、前節の回帰分析結果 (Fig. 4.2.1) の一部を活用し、沸騰および未沸騰の状態を 100% 検知可能とする熱流束を算出する。次に、この値を定量的に評価する手法として、実験データおよび物性値を基に Ivey-Morris の相関式を使用し、各実験条件における限界熱流束を算出する。その後、沸騰開始点の実測値および限界熱流束の間で予測された 100% 検知可能な熱流束の値が占める相対位置を % で表記する。また、これらの結果を沸騰曲線上にプロットすることで、視覚的な評価も行う。

4.3.1 物性値

限界熱流束の計算には Ivey-Morris の相関式を使用し、以下の物性値を用いた (水温 80°C, 系の圧力は Table 2.2.1 の大気圧を使用)。

なお、Ivey-Morris の相関式の計算には、液温 80°C の時の物性値を使用した。Ivey-Morris の相関式は以下の式 (4.3.1) で表される。

$$\frac{(q_{CHF})_{sub}}{(q_{CHF})_{sat}} = 1 + 0.1 \left(\frac{\rho_v}{\rho_l} \right)^{\frac{1}{4}} \frac{C_{pl} \rho_l \Delta T_{sub}}{\Delta h \rho_v} \quad (4.3.1)$$

4.3.2 限界熱流束と予測沸騰開始点の相対位置の計算

限界熱流束の計算

各電圧値に対して、式 (4.3.1) を用いて限界熱流束を計算した。そして計算値の平均を、その実験における代表的な限界熱流束値として使用した。

Table 4.3.2 に示した各実験の限界熱流束の計算結果を基に、これらの値を平均して、代表

Table 4.3.1 Physical properties (T_{water} : 80°C)

	物性値
蒸発潜熱 L_{lv} J/kg	2.308×10^6
液体のプラントル数 Pr	2.229
液体の密度 ρ_l kg/m ³	9.718×10^2
蒸気の密度 ρ_v kg/m ³	0.2937
液体の熱伝導率 k_l W/(m · K)	0.667
液体の動粘度 ν_l m ² /s	3.646×10^{-7}
表面張力 σ N/m	6.267×10^{-2}
ラプラス係数 l_a	2.566×10^{-3}
重力加速度 g ms ²	9.7975
液体の粘性率 μ_l Pa · s	3.54×10^{-4}
係数 C_{sf} (水-白金)	0.013
液体の定圧比熱 C_{pl} J/(kg · K)	4.20×10^3

Table 4.3.2 Critical heat flux calculation results with Ivey-Morris correlation (5 significant digits)

ΔT_{sat}	実験 1 MW m ⁻²	実験 2 MW m ⁻²	実験 3 MW m ⁻²
0	1.8176	1.7909	1.7909
1	1.8185	1.7828	1.7777
2	1.8196	1.7777	1.7772
3	1.8188	1.5202	1.5202
4	1.8178	1.9005	1.9005
5	1.8184	1.8630	1.8630
6	1.8199	1.8560	1.8560
7	1.8211	1.8561	1.8561
8	1.8225	1.8521	1.8521
9	1.8239	1.8518	1.8518
10	1.8255	1.8520	1.8520
11	1.8270	1.8513	1.8513
12	1.8285		1.8203
平均値	1.8214	1.8133	1.8155
全体平均	1.8167		

的な限界熱流束値を算出した。このようにした理由は、実験 1、実験 2、実験 3 のデータが共通の条件で収集されたものであり、それらを 1 つのデータセットとして扱っていたためである。

これにより、沸騰開始点の熱流束の実測値（平均値）と限界熱流束（平均値）を基準とし、それらを 100% として、予測モデルによる沸騰開始点の熱流束がどの程度の割合に位置するかを評価できるようになった。

4.3.3 予測沸騰開始点の相対位置の計算

前述の沸騰開始点の熱流束の実測値（平均値）と限界熱流束（平均値）はそれぞれ、 0.2927 MW/m^2 、 1.8167 MW/m^2 であった。各ノイズ条件ごとの沸騰開始点の熱流束の予測結果を Table 4.3.3 に示した。また、各ノイズごとの沸騰開始点の予測結果と計算式を用いて算出した相対位置の割合を Table 4.3.4 に示し、Fig. 4.1.1 に示す各実験の沸騰曲線上に相対位置を描画した図を Fig. F.0.1a, F.0.2a, F.0.3a として付録に示した。予測結果は 5 分割交差検証を行い、その平均値を採用した。相対位置の計算には式 (4.3.2) を使用した。

$$\text{Position}(\%) = \frac{\text{予測値} - \text{実測値}}{\text{限界熱流束平均値} - \text{実測値}} \times 100 \quad (4.3.2)$$

Table 4.3.3 Details of the prediction results from 5-fold cross-validation

SNR	split1	split2	split3	split4	split5	平均	標準偏差
no_noise	0.549	0.313	0.416	0.313	0.36	0.3902	0.09838
0	0.353	0.353	0.416	0.353	0.353	0.3656	0.02817
-4	0.416	0.353	0.367	0.36	0.47	0.3932	0.04956
-8	0.47	0.47	0.3361	0.407	0.47	0.4306	0.05947
-12	0.47	0.47	0.533	0.47	0.477	0.484	0.02756
-16	0.477	0.477	0.533	0.477	0.533	0.4994	0.03067
-20	0.533	0.533	0.533	0.533	0.533	0.533	0

Table 4.3.4 Predicted value and relative position of each noise

SNR	予測平均値 MW m^{-2}	相対位置 %
no_noise	0.3902	6.398
0	0.3656	4.784
-4	0.3932	6.595
-8	0.4306	9.049
-12	0.4840	12.55
-16	0.4994	13.56
-20	0.5330	15.77

算出した相対位置の結果から、沸騰開始点の予測位置は限界熱流束の約 4.78% から 15.77% の範囲に収まることが確認された。この結果は、限界熱流束までに 84.23% 以上の余裕があることを示しており、予測モデルの実用性と安全性の観点から有望である可能性がある。

注目すべき点として、ノイズがない条件 (no_noise) の場合、相対位置が 6.398% と低い値を示しており、モデルの精度が高い可能性が示唆された。さらに、SNR=0 においても相対位置が 4.784% と最小値を記録しており、ノイズ耐性が一定のレベルで保持されている可能性がある。また、ノイズ強度が増加するにつれて、相対位置が漸増する傾向が観察された。特に、SNR=-8 以降の条件では相対位置が顕著に増加し、SNR=-20 では最大値 15.77 に達した。これは、ノイズの影響により予測精度がやや低下した可能性を反映していると考えられる。

これらの結果は、予測モデルが沸騰開始点を早期に検知する能力を備えていることを示唆するだけでなく、ノイズ条件下でも安定した性能を発揮する可能性を示している。また、相対位置が限界熱流束の 20% 未満に制御されていることから、モデルの適用範囲が広い可能性がある。

第 5 章

結言

5.1 まとめ

本研究では、炉心局所異常に伴う異常検知技術の開発において、機械学習とアンサンブル学習を組み合わせた沸騰開始点予測手法の確率と性能評価を行った。研究目的に基づき、ROC 曲線による分類精度評価と 100% 検知可能な熱流束値の決定を通じて、以下の主要な知見を得た。

第一に、沸騰開始点の早期検知能力を定量的に評価し、限界熱流束の 4.78% から 15.77% の範囲で異常を検知可能であることを明らかにした。この結果は、システムが限界熱流束まで 84.23% 以上の余裕を持つことを意味し、炉心局所異常の早期検知技術として高い安全性と信頼性がある可能性を示唆している。特にノイズがない条件下では相対位置が 6.398% と低い値を記録し、提案モデルの高い予測精度を確認した。

第二に、ROC 曲線分析および AUC 評価により、アンサンブルモデルの優位性を実証した。SNR の低下に伴う性能劣化が観察される中、アンサンブルモデルは異なるアーキテクチャの特徴を組み合わせることで、特に低 SNR 環境 (-16 dB, -20 dB) において高い頑健性を示した。具体的には、決定係数の劣化率を他のモデルが 11% 前後を示す中約 8.9% に抑制し、AUC においても約 8% の劣化率に留めた。この結果は、可視化データと音圧変化の時刻歴応答データを用いた検証において、提案手法のノイズ耐性を明確に示している。

これらの知見は、本研究で提案した深層学習を用いた熱流束予測手法が、異なるノイズ環境下における機械学習モデルの挙動を詳細に捉え、基礎的な実験において十分な性能と信頼性を有することを実証している。

5.2 今後の展望

本研究における今後の展望として、いくつかの重要な課題と改善点が挙げられる。まず、広範な実験条件下での性能検証が期待される。現行の検証条件に加えて、例えばサブクール度や白金細線の形状パラメータ、溶存ガスの影響など、さまざまな運転条件を考慮することで、システムの汎用性と信頼性を高めることが可能である。

次に、100% 分類性能では、予測アルゴリズムのファインチューニングや、リアルタイム性の向上が課題である。現行のモデルは良好な結果を示しているものの、ハイパーパラメータの最適化や最新モデルの導入による更なる性能向上の余地がある。

最後に、アンサンブル学習の重み付け方法の最適化やモデルの変更がある。異なるタイプのモデルを選択的に組み合わせることで、アンサンブル学習の効果を最大化できる可能性が

ある.

謝辞

本論文の作成にあたり，多くの方々にご指導ご鞭撻を賜りました．

植木祥高准教授には，定期的に議論を行う場を設けていただき，研究方針についてのご相談や研究に関する様々な知識，さらには学会参加においてもお力添えなど，数多くのご助言を賜りました．ここに深謝の意を表します．

さらに，東京理科大学植木研究室プロジェクト研究員の荒邦章様には，原子力機構の取り組みについて専門的な知識を賜りました．ここに深謝の意を表します．

最後に，植木研究室の皆様には研究進捗報告会において数多くのご意見，ご助言を賜りました．ここに深謝の意を表します．

参考文献

- [1] 経済産業省資源エネルギー庁. エネルギー白書 2024 について, 2024. 令和 5 年度エネルギーに関する年次報告.
- [2] 佐藤純一. カーボンニュートラルに向けた水素の役割と社会実装に向けた取り組み. 電気学会誌, Vol. 144, No. 8, pp. 520–523, 2024.
- [3] 神崎寛. エネルギー基本計画改定を踏まえたプラントメーカーによる原子力事業展開活動. 日本原子力学会誌 ATOMO Σ, Vol. 64, No. 7, pp. 390–392, 2022.
- [4] 上出英樹, 伊藤隆哉, 小竹庄司. 第 4 世代原子炉の開発動向. 日本原子力学会誌 ATOMO Σ, Vol. 60, No. 9, pp. 562–566, 2018.
- [5] 二見常夫. 原子力発電所の事故・トラブル 分析と教訓. 丸善出版, 2012.
- [6] K. Gast and D. Smidt. Cooling disturbances in the core of sodium-cooled fast reactors as causes of fast failure propagation. *Nuclear Engineering and Design*, Vol. 14, No. 1, pp. 12–22, 1970.
- [7] Siwei Qi, Bin Han, Xiaoliang Zhu, Bao-Wen Yang, Tianyang Xing, Aiguo Liu, and Shenghui Liu. Machine learning in critical heat flux studies in nuclear systems: A detailed review. *Progress in Nuclear Energy*, Vol. 179, p. 105535, 2025.
- [8] Alex Viklander. Analyzing core stability in boiling water reactors : A comparative evaluation of auto-regressive and machine learning approaches, 2024.
- [9] Erdem Alic, Mehmet Das, and Onder Kaska. Heat flux estimation at pool boiling processes with computational intelligence methods. *Processes*, Vol. 7, No. 5, 2019.
- [10] Christy Dunlap, Hari Pandey, Ethan Weems, and Han Hu. Nonintrusive heat flux quantification using acoustic emissions during pool boiling. *Applied Thermal Engineering*, Vol. 228, p. 120558, 2023.
- [11] Christy Dunlap, Changgen Li, Hari Pandey, Ying Sun, and Han Hu. A temporal–spatial framework for efficient heat flux monitoring of transient boiling. *IEEE Transactions on Instrumentation and Measurement*, Vol. 73, pp. 1–12, 2024.
- [12] Nao Mikami, et al. Cnn-based acoustic identification of gas–liquid jet: Evaluation of noise resistance and visual explanation using grad-cam. *International Journal of Multiphase Flow*, Vol. 171, p. 104688, 2024.
- [13] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [14] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. *Communications of the ACM*, Vol. 60, pp. 84 – 90, 2012.
- [15] Eduardo Valle, Michel Fornaciali, Afonso Menegola, Julia Tavares, Flávia Vasques Bittencourt, Lin Tzy Li, and Sandra Avila. Data, depth, and design: Learning reliable models for

skin lesion analysis, 2019.

- [16] 修功上田. アンサンブル学習. 情報処理学会論文誌コンピュータビジョンとイメージメディア (CVIM) , Vol. 46, No. SIG15(CVIM12), pp. 11–20, oct 2005.
- [17] Charles E. Metz. Basic principles of roc analysis. *Seminars in Nuclear Medicine*, Vol. 8, No. 4, pp. 283–298, 1978.
- [18] Andre M. Carrington, Douglas G. Manuel, Paul W. Fieguth, Tim Ramsay, Venet Osmani, Bernhard Wernly, Carol Bennett, Steven Hawken, Olivia Magwood, Yusuf Sheikh, Matthew McInnes, and Andreas Holzinger. Deep roc analysis and auc as balanced average accuracy, for improved classifier selection, audit and explanation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 45, No. 1, p. 329–341, January 2023.
- [19] 林茂雄, 馬場涼, 小澤美奈子. 計測における 誤差解析入門. 東京化学同人, 2013.
- [20] 安喰春華, 中島駿, 大久保英敏. 沸騰曲線の誕生. 公開研究会・講演会技術と社会の関連を巡って: 技術史から経営戦略まで: 講演論文集, Vol. 2017, p. 325, 2017.
- [21] 西川兼康, 藤田恭伸, 縄田豊. 飽和核沸騰熱伝達に及ぼす圧力の影響に関する研究. 日本機械学会論文集, Vol. 42, No. 361, pp. 2879–2891, 1976.
- [22] JIS 規格 c1604-2013 測温抵抗体.

付録

付録 A

沸騰曲線の計算方法

A.1 白金温度の推定手法

熱流束と過熱度を用いて沸騰曲線のグラフを作成する時に加熱面表面温度 T_w に相当する白金温度 T [$^{\circ}\text{C}$] を求める必要がある。直接測定は困難であるため白金温度の推定は、JIS 規格の $0^{\circ}\text{C} \sim 850^{\circ}\text{C}$ における関係式を使用した [22]。

$$R_T = R_0(1 + AT + BT^2) \quad (1.1.1)$$

ここで、 $A = 3.9083 \times 10^{-3} ^{\circ}\text{C}^{-1}$ 、 $B = -5.775 \times 10^{-7} ^{\circ}\text{C}^{-2}$ である。また、ここで用いる白金抵抗値や熱流束は実験で 60 s 間録音した時にデータロガーで記録したシャント電圧 V_{shunt} [V] と白金電圧 V_{Pt} [V] が定常状態になった範囲を平均したデータから算出した。

はじめに、本文中の式 (3.5.1) より熱流束を算出した。

白金細線と水温 (バルク温度) との温度差を考慮し、また熱伝達係数 h を用いて Newton の冷却則より、式 (1.1.1) は、式 (1.1.2) と変形できた。ただし q の具体的な値は式 (3.5.1) で算出された。

$$R_T = R_{\text{bulk}} + \frac{R_0 A}{h} q \quad (1.1.2)$$

式 (1.1.2) より、 R_{bulk} は白金の抵抗値 R_T と熱流束 q の関係のグラフを外挿することで算出された。ただし、式 (1.1.2) の熱流束 q の範囲は未沸騰領域に限定し、グラフは最小二乗法で線形近似したものとした。

バルク温度 T_{bulk} はデータロガーで記録した水温をサブクール沸騰実験の実験時間で時間平均した値であり、外挿することで得られた R_{bulk} とともに $T = T_{\text{bulk}}$ として式 (1.1.1) に代入すると 0°C における白金抵抗値 R_0 が算出された。

また、式 (1.1.1) を T の式で整理したとき、式 (1.1.3) となった。この式に算出した値を代入することで各印加電圧時の白金温度 T が算出された。

$$T = \frac{-A + \sqrt{A^2 - 4B(1 - \frac{R_T}{R_0})}}{2B} \quad (1.1.3)$$

A.2 沸騰曲線の作成と相関式との比較手法

前節で熱流束と過熱度を用いて沸騰曲線のグラフを作成するのに必要な白金温度 T [°C] を推定した．過熱度 ΔT_{sat} [K] は，伝熱面温度 T_w と飽和温度 T_{sat} の差で求める．飽和温度 T_{sat} は式 (1.2.1) で算出した．

$$T_{\text{sat}} = 0.268P + 72.8 \quad (1.2.1)$$

以上の式を用いて，本研究では沸騰曲線を描画し，実験の妥当性を検証した．

付録 B

スペクトログラムの例

データセットとして使用したスペクトログラムの例として、実験 1 の沸騰開始点でのスペクトログラムを各 SNR 条件について示す。




Fig. B.0.1 Spectrograms for each SNR condition at the boiling start point in Experiment 1

付録 C

Adam の更新式

Adam の更新式を下に示す.

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \frac{\partial L}{\partial \mathbf{W}_t}, \quad (3.0.1)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) \left(\frac{\partial L}{\partial \mathbf{W}_t} \right)^2, \quad (3.0.2)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}, \quad (3.0.3)$$

$$\mathbf{W}_{t+1} = \mathbf{W}_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \quad (3.0.4)$$

ここで, $\mathbf{W}_t$ は t ステップ目の重みパラメータ, $\frac{\partial L}{\partial \mathbf{W}_t}$ は損失関数の勾配, η は学習率, m_t および v_t はそれぞれ勾配の一次モーメントおよび二次モーメントの推定値, β_1, β_2 はモーメント推定の減衰率, ϵ は数値安定性を向上させるための微小定数である.

付録 D

100% 分類可能な熱流束の模式図

100% 分類可能な熱流束の決定方法を示した模式図を下に示す.




Fig. D.0.1 100% Method of determining lower detection limit

付録 E

実験 1 の離散的な音圧スペクトル

目視観察による沸騰開始点の特定における，実験 1 の音響データを解析して得られた離散的な音圧スペクトルを下に示す．





Fig. E.0.1 Sound pressure spectrum around 0.2607 MW m^{-2} in Experiment 1

付録 F


実験 1 の離散的な音圧スペクトル

各実験の沸騰曲線上に相対位置を描画した図を下に示す.




(a) Experiment 1

(b) Comparison of boiling curves and predicted boiling start points for Experiment 1



(a) Experiment 2

(b) Comparison of boiling curves and predicted boiling start points for Experiment 2



(a) Experiment 3

(b) Comparison of boiling curves and predicted boiling start points for Experiment 3

付録 G

回帰分析の補足結果

回帰分析による各 SNR 条件のその他の結果を以下に示す.

G.1 SNR=no_noise




Fig. G.1.1 SNR = no_noise (split=1)




Fig. G.1.2 SNR = no_noise (split=3)




Fig. G.1.3 SNR = no_noise (split=4)




Fig. G.1.4 SNR = no_noise (split=5)

G.2 SNR=0




Fig. G.2.1 SNR = 0 (split=1)




Fig. G.2.2 SNR = 0 (split=3)




Fig. G.2.3 SNR = 0 (split=4)




Fig. G.2.4 SNR = 0 (split=5)

G.3 SNR=-4




Fig. G.3.1 SNR = -4 (split=1)




Fig. G.3.2 SNR = -4 (split=3)




Fig. G.3.3 SNR = -4 (split=4)




Fig. G.3.4 SNR = -4 (split=5)

G.4 SNR=-8




Fig. G.4.1 SNR = -8 (split=1)




Fig. G.4.2 SNR = -8 (split=3)




Fig. G.4.3 SNR = -8 (split=4)




Fig. G.4.4 SNR = -8 (split=5)

G.5 SNR=-12




Fig. G.5.1 SNR = -12 (split=1)




Fig. G.5.2 SNR = -12 (split=3)




Fig. G.5.3 SNR = -12 (split=4)




Fig. G.5.4 SNR = -12 (split=5)

G.6 SNR=-16




Fig. G.6.1 SNR = -16 (split=1)




Fig. G.6.2 SNR = -16 (split=3)




Fig. G.6.3 SNR = -16 (split=4)




Fig. G.6.4 SNR = -16 (split=5)

G.7 SNR=-20




Fig. G.7.1 SNR = -20 (split=1)




Fig. G.7.2 SNR = -20 (split=3)




Fig. G.7.3 SNR = -20 (split=4)




Fig. G.7.4 SNR = -20 (split=5)