



先進工学研究科 電子システム工学専攻

音響工学特論

第 7 回

植木 祥高

東京理科大学 先進工学部
電子システム工学科

授業計画

- #01 インTRODクシヨン
- #02 機械学習の歴史と動向
- #03 機械学習分野の問題・具体的手法
- #04 Pythonのプログラミング基礎
- #05 音響収録の基礎
- #06 ニューラルネットワークの基礎 ①
- #07 ニューラルネットワークの基礎 ②**
- #08 ニューラルネットワークの実装 ①
- #09 ニューラルネットワークの実装 ②
- #10 ニューラルネットワークの実装 ③
- #11 ディープラーニングの概要と動向
- #12 音響データを用いた機械学習 ①
- #13 音響データを用いた機械学習 ②
- #14 プレゼンテーション
- #15 到達度評価

※ 評価：60%

※ 評価：40%

(機械学習・音響工学の知識と習得度を評価)

ニューラルネットワークの基礎

- ニューラルネットワーク内にて行われる
誤差逆伝播とニューラルネットワークの重みの更新について
理解しよう

ニューラルネットワークの基礎

- 前回までのおさらい

ニューラルネットワークの入力に対する出力

- 次なるステップ


ニューラルネットワークの出力と訓練データの比較
(誤差の算出)

ニューラルネットワークの学習

- ノードが答えとして生成する値と既知である真の答え（教師データ）との誤差が発生
- 誤差発生時にどのように重みを更新すれば良いのか


複数のノードからの重みの学習

- 誤差の大小に応じて、重みを更新
- 2つ以上のノードが出力に影響する場合、どのように重みを更新すれば良いのか




複数のノードからの重みの学習

- 誤差を均等に分配




- 大きな重みを持つ接続に優先的に分配

(誤差逆伝播)




複数のノードからの重みの学習

- 誤差を均等に分配




- 大きな重みを持つ接続に優先的に分配

※ 誤差逆伝播




2つのノードからの重みの学習



- 2つの出力ノードから、それぞれ誤差を算出
- 各出力ノードの接続に対して誤差を分配

2つのノードからの重みの学習



理想的な出力値
(教師データ)

t_1


t_2

誤差 = 教師データ - 出力

$$e_1 = t_1 - o_1$$

$$e_2 = t_2 - o_2$$

2つのノードからの重みの学習



誤差を重みに応じて分配


$w_{1,1}$ を改善するために使用する e_1 の割合

$$\frac{w_{11}}{w_{11} + w_{21}}$$

$w_{2,1}$ を改善するために使用する e_1 の割合


$$\frac{w_{21}}{w_{11} + w_{21}}$$

2つのノードからの重みの学習




2つのノードからの重みの学習

誤差逆伝播



2つのノードからの重みの学習


誤差逆伝播を使って分配された誤差を再結合



$e_{hidden,1}$ = w_{11} と w_{12} のリンクに分配された誤差の和

$$= e_{output,1} * \frac{w_{11}}{w_{11} + w_{21}} + e_{output,2} * \frac{w_{12}}{w_{12} + w_{22}}$$

2つのノードからの重みの学習




$e_{\text{hidden},1}$ = w_{11} と w_{12} のリンクに分配された誤差の和


$$= e_{\text{output},1} * \frac{w_{11}}{w_{11} + w_{21}} + e_{\text{output},2} * \frac{w_{12}}{w_{12} + w_{22}}$$

2つのノードからの重みの学習

さらに、誤差逆伝播を使って分配された誤差を再結合




行列計算による誤差逆伝播




$$\text{error}_{\text{output}} = \begin{pmatrix} e_1 \\ e_2 \end{pmatrix}$$

行列計算による誤差逆伝播



$$\text{error}_{\text{hidden}} = \begin{pmatrix} \frac{w_{11}}{w_{11} + w_{21}} & \frac{w_{12}}{w_{12} + w_{22}} \\ \frac{w_{21}}{w_{21} + w_{11}} & \frac{w_{22}}{w_{22} + w_{12}} \end{pmatrix} \cdot \begin{pmatrix} e_1 \\ e_2 \end{pmatrix}$$

行列計算による誤差逆伝播



$$\text{error}_{\text{hidden}} = \begin{pmatrix} \frac{w_{11}}{w_{11} + w_{21}} & \frac{w_{12}}{w_{12} + w_{22}} \\ \frac{w_{21}}{w_{21} + w_{11}} & \frac{w_{22}}{w_{22} + w_{12}} \end{pmatrix} \cdot \begin{pmatrix} e_1 \\ e_2 \end{pmatrix}$$

行列計算による誤差逆伝播

$$\text{error}_{\text{hidden}} = \begin{pmatrix} \frac{w_{11}}{w_{11} + w_{21}} & \frac{w_{12}}{w_{12} + w_{22}} \\ \frac{w_{21}}{w_{21} + w_{11}} & \frac{w_{22}}{w_{22} + w_{12}} \end{pmatrix} \cdot \begin{pmatrix} e_1 \\ e_2 \end{pmatrix}$$

↓ 正規化因子（重みの分母）を無視して簡易化

$$\text{error}_{\text{hidden}} = \begin{pmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{pmatrix} \cdot \begin{pmatrix} e_1 \\ e_2 \end{pmatrix}$$

行列計算による誤差逆伝播

$$error_{hidden} = \begin{pmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{pmatrix} \cdot \begin{pmatrix} e_1 \\ e_2 \end{pmatrix}$$



↓ 転置行列にて表現

$$error_{hidden} = w_{hidden_output}^T \cdot error_{output}$$

- 誤差逆伝播は行列の積にて表現される
- ネットワークの大きさに依らず同一の取り扱い可能
- プログラム可能



重みの更新

勾配降下法 . . . 勾配の大小に基づき重みを更新




重みの更新

勾配降下法 . . . 勾配の大小に基づき重みを更新



勾配降下法


最適解と局所解



- 最適化手法 (Optimizer) の選択は重要
- 勾配降下法にも複数の手法あり
- 誤差の最小化を図る

勾配降下法

誤差の最小化 (最適解の探索)




重みの更新

誤差関数の勾配

$$\frac{\partial E}{\partial w_{jk}} = \frac{\partial}{\partial w_{jk}} \sum_n (t_n - o_n)^2$$

ノードkに接続しているリンクに対する重み w_{jk}



重みの更新

誤差関数の勾配

$$\frac{\partial E}{\partial w_{jk}} = \frac{\partial}{\partial w_{jk}} \sum_n (t_n - o_n)^2$$

$$\frac{\partial E}{\partial w_{jk}} = \frac{\partial E}{\partial o_k} \cdot \frac{\partial o_k}{\partial w_{jk}}$$

誤差関数の勾配

$$\frac{\partial E}{\partial w_{jk}} = \frac{\partial}{\partial w_{jk}} \sum_n (t_n - o_n)^2$$

$$= \frac{\partial E}{\partial o_k} \cdot \frac{\partial o_k}{\partial w_{jk}}$$

$$= -2(t_k - o_k) \cdot \frac{\partial o_k}{\partial w_{jk}}$$

$$= -2(t_k - o_k) \cdot \frac{\partial}{\partial w_{jk}} \text{sigmoid}(\sum_j w_{jk} \cdot o_j)$$

o_j 直前の隠れ層のノードからの出力

誤差関数の勾配

$$\frac{\partial E}{\partial w_{jk}} = -2(t_k - o_k) \cdot \frac{\partial}{\partial w_{jk}} \text{sigmoid}(\sum_j w_{jk} \cdot o_j)$$

O_j 直前の隠れ層のノードからの出力

$$\frac{\partial}{\partial x} \text{sigmoid}(x) = \text{sigmoid}(x) (1 - \text{sigmoid}(x))$$

$$\begin{aligned} \frac{\partial E}{\partial w_{jk}} &= -2(t_k - o_k) \cdot \text{sigmoid}(\sum_j w_{jk} \cdot o_j) (1 - \text{sigmoid}(\sum_j w_{jk} \cdot o_j)) \cdot \frac{\partial}{\partial w_{jk}} (\sum_j w_{jk} \cdot o_j) \\ &= -2(t_k - o_k) \cdot \text{sigmoid}(\sum_j w_{jk} \cdot o_j) (1 - \text{sigmoid}(\sum_j w_{jk} \cdot o_j)) \cdot o_j \end{aligned}$$

誤差関数の勾配

簡略化した隠れ層と出力層の重みの誤差関数の勾配

$$\frac{\partial E}{\partial w_{jk}} = -(t_k - o_k) \cdot \text{sigmoid}(\sum_j w_{jk} \cdot o_j) (1 - \text{sigmoid}(\sum_j w_{jk} \cdot o_j)) \cdot o_j$$

入力層と隠れ層の重みの誤差関数の勾配

$$\frac{\partial E}{\partial w_{ij}} = -(e_j) \cdot \text{sigmoid}(\sum_i w_{ij} \cdot o_i) (1 - \text{sigmoid}(\sum_i w_{ij} \cdot o_i)) \cdot o_i$$

重みの更新

α 学習率

$$\text{新しい } w_{jk} = \text{古い } w_{jk} - \alpha \cdot \frac{\partial E}{\partial w_{jk}}$$

誤差関数の勾配

行列表現


$$\frac{\partial E}{\partial w_{jk}} = -(t_k - o_k) \cdot \text{sigmoid}(\sum_j w_{jk} \cdot o_j) (1 - \text{sigmoid}(\sum_j w_{jk} \cdot o_j)) \cdot o_j$$

$$\begin{pmatrix} \Delta w_{1,1} & \Delta w_{2,1} & \Delta w_{3,1} & \dots \\ \Delta w_{1,2} & \Delta w_{2,2} & \Delta w_{3,2} & \dots \\ \Delta w_{1,3} & \Delta w_{2,3} & \Delta w_{j,k} & \dots \\ \dots & \dots & \dots & \dots \end{pmatrix} = \begin{pmatrix} E_1 * S_1 (1-S_1) \\ E_2 * S_2 (1-S_2) \\ E_k * S_k (1-S_k) \\ \dots \end{pmatrix} \cdot \begin{pmatrix} o_1 & o_2 & o_j & \dots \end{pmatrix}$$

↑ 次の層からの値
 ↑ 直前の層からの値


$$\Delta W_{jk} = \alpha \cdot E_k \cdot O_k (1 - O_k) \cdot O_j^T$$

重みの更新



$$\frac{\partial E}{\partial w_{jk}} = -(t_k - o_k) \cdot \text{sigmoid}(\sum_j w_{jk} \cdot o_j) (1 - \text{sigmoid}(\sum_j w_{jk} \cdot o_j)) \cdot o_j$$

重みの更新の計算例



$$\frac{\partial E}{\partial w_{jk}} = \underbrace{-(t_k - o_k)}_{0.8} \cdot \underbrace{\text{sigmoid}(\sum_j w_{jk} \cdot o_j)}_{2.0 \times 0.4 + 3.0 \times 0.5} \cdot \underbrace{o_j}_{0.4}$$

重みの更新の計算例


誤差関数の勾配

$$\frac{\partial E}{\partial w_{jk}} = \underbrace{-(t_k - o_k)}_{0.8} \cdot \underbrace{\text{sigmoid}(\sum_j w_{jk} \cdot o_j)}_{2.0 \times 0.4 + 3.0 \times 0.5} (1 - \underbrace{\text{sigmoid}(\sum_j w_{jk} \cdot o_j)}) \cdot \underbrace{o_j}_{0.4}$$


重みの更新

$$\text{新しい } w_{jk} = \text{古い } w_{jk} - \alpha \cdot \frac{\partial E}{\partial w_{jk}}$$

シグモイド関数の勾配




ランダムな重みの初期化



- 重みが大きいと活性化関数に大きな信号が
- シグモイド関数の場合、重みの更新が少ない（勾配小）
- ランダムでかつ小さい値が初期化するのが良い

練習問題




$$\frac{\partial E}{\partial w_{jk}} = \underbrace{-(t_k - o_k)}_{0.8} \cdot \underbrace{\text{sigmoid}(\sum_j w_{jk} \cdot o_j)}_{\substack{2.0 \times 0.4 \\ + \\ 3.0 \times 0.5}} \cdot \underbrace{(1 - \text{sigmoid}(\sum_j w_{jk} \cdot o_j))}_{0.4} \cdot o_j$$

$$\text{新しい } w_{jk} = \text{古い } w_{jk} - \alpha \cdot \frac{\partial E}{\partial w_{jk}}$$

- 今回取り上げた単一ノードの重み更新についてNumPyを用いた行列計算を行い、同一の結果を得られるか確認せよ
(ただし学習率は0.1とせよ)
- 更新した重みを用いて、再度勾配を計算して重みを更新せよ。
- ただし、ここでは O_j と e_1 は固定として計算すること。
※ 本来の誤差逆伝播では更新された重みにて再度誤差の評価が必要

発展問題#1



- 練習問題を改良して出力層が2ノードの場合における重みの更新を実装せよ
- 任意の大きさの出力層ノード数に対応できるように変更せよ

$$\frac{\partial E}{\partial w_{jk}} = -(t_k - o_k) \cdot \text{sigmoid}(\sum_j w_{jk} \cdot o_j) (1 - \text{sigmoid}(\sum_j w_{jk} \cdot o_j)) \cdot o_j$$

$$\text{新しい } w_{jk} = \text{古い } w_{jk} - \alpha \cdot \frac{\partial E}{\partial w_{jk}}$$

発展問題#2

- ノイズ付与前のデータを教師データとし、付与後のデータを入力データとする。また、重み行列をガウス分布に従う乱数で初期化して用いる。

今回の手法を用いて重みの更新をせよ。

ただし、更新した重みを用いて再び誤差を計算し、それを誤差の勾配に用いよ。なお、学習率は適宜変更してよい。

- 複数回、重みの更新を行なって誤差が変化することを確認せよ。

$$\frac{\partial E}{\partial w_{jk}} = -(t_k - o_k) \cdot \text{sigmoid}(\sum_j w_{jk} \cdot o_j) (1 - \text{sigmoid}(\sum_j w_{jk} \cdot o_j)) \cdot o_j$$

$$\text{新しい } w_{jk} = \text{古い } w_{jk} - \alpha \cdot \frac{\partial E}{\partial w_{jk}}$$



Tokyo University of Science